

***INTEGRASI EXPLAINABLE AI (XAI) PADA
CORRELATION LEARNING MECHANISM (CLM)
UNTUK DETEKSI TUMOR OTAK
MENGUNAKAN CITRA CT SCAN***

Laporan Tugas Akhir

Oleh

**Micky Valentino
18299093**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

1 Juli 2026

LEMBAR PENGESAHAN

INTEGRASI EXPLAINABLE AI (XAI) PADA CORRELATION LEARNING MECHANISM (CLM) UNTUK DETEKSI TUMOR OTAK MENGGUNAKAN CITRA CT SCAN

Laporan Tugas Akhir

Oleh

Micky Valentino
18299000

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 1 Juli 2026

Pembimbing

Dr. Ir. John Doe, M.T.

NIP. 123456789

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 1 Juli 2026

Micky Valentino

NIM: 18299093

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II hal. 15
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	...	...	...
5	Penyusunan bahan diskusi	...	...	...
6	Penyusunan kode program	...	...	...
7	Penyusunan formula atau perhitungan matematis	...	...	...
8	Penyusunan konsep desain atau algoritma	...	...	...
9	Penyusunan analisis data	...	...	...
10	Penyusunan kesimpulan atau rekomendasi	...	...	...

Bandung, 1 Juli 2026

Micky Valentino
NIM: 18299093

ABSTRAK

Implementasi Sistem Smart Scale Berbasis IoT dengan Arsitektur Desentralisasi untuk Optimalisasi Rantai Pasok Jeruk di Tingkat Lapak

oleh

John Doe

123456789

Proses manual dalam rantai pasok jeruk di tingkat lapak, yang mencakup sortir, timbang, dan catat, terbukti tidak efisien, memakan waktu, dan rentan terhadap kesalahan. Meskipun solusi berbasis Internet of Things (IoT) dapat mengatasi masalah ini, arsitektur terpusat konvensional berbasis cloud justru menimbulkan masalah baru berupa latensi tinggi yang menghambat alur kerja real-time. Penelitian ini bertujuan untuk merancang dan mengimplementasikan sebuah purwarupa sistem smart scale berbasis IoT dengan pendekatan desentralisasi (edge computing) untuk meminimalkan latensi dan meningkatkan efisiensi operasional. Metode yang digunakan adalah Model Purwarupa, yang diwujudkan dalam bentuk perangkat keras dengan arsitektur prosesor ganda (Raspberry Pi 5 dan ESP32) yang mampu mengintegrasikan fungsi timbang dan analisis kualitas citra secara simultan. Hasil evaluasi menunjukkan bahwa purwarupa dengan arsitektur edge computing yang diimplementasikan mampu memberikan respons 43,5% lebih cepat (latensi rata-rata 18,05 detik) dibandingkan dengan simulasi arsitektur terpusat. Selain itu, sistem ini berhasil meningkatkan efisiensi waktu kerja secara keseluruhan sebesar 58,32% jika dibandingkan dengan metode manual konvensional. Pengujian Penerimaan Pengguna (UAT) yang melibatkan 30 partisipan juga menunjukkan penerimaan yang sangat positif, dengan skor rata-rata untuk kemudahan penggunaan (5,0/5,0), kejelasan antarmuka (4,87/5,0) dan persepsi kinerja (4,95/5,0). Kesimpulannya, implementasi sistem smart scale dengan arsitektur desentralisasi terbukti merupakan solusi yang valid dan efektif untuk menjawab permasalahan latensi dan inefisiensi di lapak. Sistem ini tidak hanya unggul secara teknis dalam hal performa, tetapi juga fungsional dan dapat diterima dengan baik oleh pengguna akhir, serta berpotensi besar untuk modernisasi rantai pasok agribisnis.

Kata kunci: Smart Scale, Internet of Things, Edge Computing, Rantai Pasok Jeruk.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, saya dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul "Implementasi Algoritma XYZ untuk Optimasi Jaringan Komputer". Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Bandung, 20 Mei 2026

Penulis

John Doe

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
DAFTAR PERSAMAAN	xxi
DAFTAR ALGORITMA	xxiii
DAFTAR <i>LISTING</i>	xxv
DAFTAR SIMBOL	xxvii
DAFTAR SINGKATAN	xxxix
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	4
I.3 Tujuan	4
I.4 Batasan Masalah	5
I.5 Metodologi	5
I.6 Sistematika Penulisan	7
II STUDI LITERATUR	9
II.1 Tumor Otak	9
II.1.1 Teknologi Pencitraan Medis Tumor Otak	9
II.1.1.1 MRI	10
II.1.1.2 CT Scan	11
II.2 <i>Artificial Intelligence</i> (AI) dalam Pencitraan Medis	12
II.2.1 <i>Deep Learning</i>	13
II.3 <i>Explainable AI</i> (XAI)	13
II.3.1 Metode <i>Explainable AI</i> (XAI)	14
II.3.1.1 <i>Attribution-based Methods</i>	14
II.3.1.2 <i>Perturbation-based Methods</i>	15
II.3.1.3 <i>Activation-based Methods</i>	15
II.3.1.4 <i>Transformer-based Methods</i>	16
II.4 Evaluasi Model	16
II.4.1 <i>Deep Learning</i>	16
II.4.2 <i>Explainable Artificial Intelligence</i> (XAI)	17
II.5 Penelitian Terkait	20
II.5.1 Pendeteksian Tumor	20
II.5.1.1 <i>Detection and Classification of Brain Tumor Using a Hybrid Learning Model in CT Scan Images</i>	20
II.5.1.2 <i>Deep Neural Network Correlation Learning Mechanism for CT Brain Tumor Detection</i>	21

II.5.1.3	<i>Explainable CNN for brain tumor detection and classification through XAI based key features identification</i>	21
II.5.1.4	<i>Deep-EFNet: An Optimized EfficientNetB0 Architecture with Dual Regularization for Scalable Multi-Class Brain Tumor Classification in MRI</i>	21
II.5.2	XAI	22
II.5.2.1	<i>An XAI-Enhanced EfficientNetB0 Framework for Precision Brain Tumor Detection in MRI Imaging</i>	22
II.5.2.2	<i>Explainable CNN for Brain Tumor Detection and Classification through XAI Based Key Features Identification</i>	22
II.5.3	Kesenjangan	23
III	ANALISIS MASALAH	25
III.1	Analisis Kondisi Saat Ini	25
III.1.1	Alur Diagnosis Tumor Otak	25
III.1.2	Penggunaan AI dalam CT Scan Otak	26
III.2	Analisis Kebutuhan	27
III.2.1	Identifikasi Masalah Pengguna	27
III.2.2	Kebutuhan Fungsional	30
III.2.3	Kebutuhan Nonfungsional	31
III.3	Analisis Pemilihan Solusi	31
III.3.1	Alternatif Solusi	32
IV	PERANCANGAN MODEL PENDETEKSIAN TUMOR OTAK BERBASIS CNN YANG TERINTEGRASI XAI	41
IV.1	<i>Data Understanding</i>	41
IV.2	<i>Data Preparation</i>	43
IV.2.1	<i>Preprocessing Umum</i>	43
IV.2.2	<i>Preprocessing Eksperimen</i>	44
IV.2.3	<i>Augmentasi</i>	45
IV.3	<i>Modelling</i>	47
IV.3.1	<i>Explainable CNN</i>	47
IV.3.2	<i>Explainable CNN</i>	48
IV.3.3	<i>EfficientNetB0</i>	48
IV.3.4	<i>hyperparameter tuning</i>	48
IV.3.5	<i>Explainable AI</i>	49
IV.4	<i>Rancangan Evaluasi</i>	50
IV.4.1	<i>Evaluasi Model</i>	50
IV.4.2	<i>Evaluasi XAI</i>	50
V	IMPLEMENTASI	53
V.1	Lingkungan Implementasi	53
V.1.1	Lingkungan Perangkat Keras	53
V.1.2	Lingkungan Perangkat Lunak	53
V.2	Pengumpulan Data	54

V.3	Pemrosesan Data	56
V.3.1	Pemrosesan Umum	56
V.3.2	Pemrosesan Eksperimen	57
V.3.2.1	Gaussian Denoise dan CLAHE	57
V.3.2.2	Wavelet Denoise dan Intensity Normalization	57
V.4	Implementasi Arsitektur Model Utama (CLM)	57
V.4.1	<i>Convolutional Neural Network</i> (CNN)	57
V.4.2	<i>Artificial Neural Network</i> (ANN)	57
V.4.3	Integrasi Model	57
V.5	<i>Explainable AI</i> (Grad-CAM)	57
V.5.1	Ekstraksi <i>Feature Maps</i> dan Gradien	57
V.5.2	<i>Global Average Pooling</i> dan <i>Weighted Combination</i>	57
V.5.3	Pembangkitan <i>Heatmap</i> (Aktivasi ReLU)	57
VI	EVALUASI	59
VI.1	Metode Evaluasi	59
VI.2	Hasil Evaluasi	59
VI.3	Pembahasan Hasil Evaluasi	59
VI.4	Evaluasi Kesalahan Penulisan yang Sering Terjadi	59
VI.4.1	Penggunaan Kata "di mana" atau "dimana"	59
VI.4.2	Penggunaan Kata "sedangkan" dan "sehingga"	59
VI.4.3	Penggunaan Istilah yang Tidak Baku	60
VI.4.4	Pemisah Desimal dan Ribuan	60
VI.4.5	Daftar atau <i>List</i>	60
VI.4.6	Penggunaan Kata "masing-masing" dan "setiap"	61
VII	PENUTUP	63
VII.1	Kesimpulan	63
VII.2	Saran	63
Lampiran A	KODE PROGRAM	71
Lampiran B	HASIL SURVEI LAPANGAN	73
B.1	Foto Survei Lokasi 1	73
B.2	Foto Survei Lokasi 2	73
B.3	Transkrip Wawancara dengan Narasumber	73

DAFTAR GAMBAR

I.1	Penyebab kematian di dunia Tahun 2023 (Our World in Data 2025) .	2
I.2	<i>Cross-Industry Process for Data Mining</i> (CRISP-DM) (Chapman dkk. 2000)	6
II.1	<i>CT Scan</i> Otak (Abu Kamesh 2024)	10
II.2	Perbandingan <i>CT Scan</i> dan MRI Otak (Mamourian 2020)	12
II.3	Kategorisasi hierarkis metode XAI (Iftikhar dkk. 2025a)	14
II.4	Taksonomi berdasarkan aplikasi XAI (Kadir, Mosavi, dan Sonntag 2023)	18
II.5	Taksonomi berdasarkan metodologi evaluasi (Kadir, Mosavi, dan Sonntag 2023)	18
IV.1	Perancangan Alur Implementasi	41
IV.2	Website Radiopaedia	42
IV.3	Visualisasi mekanisme <i>Correlation Learning Mechanism</i> (CLM) (Woźniak, Siłka, dan Wiecezorek 2021)	47

DAFTAR TABEL

III.1	Matriks Perbandingan Berpasangan Kriteria	35
III.2	Vektor Prioritas Kriteria	35
III.3	Matriks Perbandingan Berpasangan C1 (Akurasi)	35
III.4	Matriks Perbandingan Berpasangan C2 (Interpretability)	36
III.5	Matriks Perbandingan Berpasangan C3 (Efisiensi Komputasi)	37
III.6	Matriks Perbandingan Berpasangan C4 (Kebutuhan Data)	37
III.7	Matriks Perbandingan Berpasangan C5 (Kompleksitas)	38
III.8	Hasil Perhitungan Perbandingan Berpasangan	39
V.1	Pembagian Data Skenario 1	55
V.2	Pembagian Data Skenario 2	55
V.3	Pembagian Data Skenario	56
V.4	Perbandingan Kondisi Dataset Sebelum dan Sesudah <i>Preprocessing</i>	56
V.5	Perbandingan Parameter Dataset Sebelum dan Sesudah <i>Preprocessing</i>	57
VI.1	Contoh penggunaan kata ”sedangkan” dan ”sehingga”	60

DAFTAR PERSAMAAN

DAFTAR ALGORITMA

DAFTAR *LISTING*

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk CTC <i>loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ϵ	<i>Token blank</i> /kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam CTC	75
π_t	<i>Token</i> pada <i>timestep</i> t dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	L1 <i>loss</i> (<i>Mean Absolute Error</i>)	75
$\mathcal{L}_{L2}$	L2 <i>loss</i> (<i>Mean Squared Error</i>)	75
$\mathcal{L}_{CTC}$	CTC (<i>Connectionist Temporal Classification</i>) <i>loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75

$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator dalam GAN</i>	75
D	<i>Discriminator dalam GAN</i>	75
$G(z)$	<i>Output dari generator dengan input z</i>	75
$D(x)$	<i>Output dari discriminator dengan input x</i>	75
$G_{A \rightarrow B}$	<i>Generator dari domain A ke B</i>	75
$G_{B \rightarrow A}$	<i>Generator dari domain B ke A</i>	75
$V(D, G)$	<i>Fungsi nilai (value function) dalam GAN</i>	75
x	<i>Sampel data asli, input citra</i>	75
y	<i>Label atau ground truth, kondisi dalam conditional GAN</i>	75
z	<i>Noise vector atau representasi laten</i>	
$\mathbb{E}$	<i>Ekspektasi atau nilai harapan</i>	75
p_{data}	<i>Distribusi data asli</i>	75
p_z	<i>Distribusi prior (noise)</i>	75
$p(y x)$	<i>Probabilitas bersyarat output y given input x</i>	75
$p_t(\pi_t x)$	<i>Probabilitas token pada timestep t</i>	
$\mathcal{B}$	<i>Fungsi penciutan (collapse function) dalam CTC</i>	75
$\mathcal{B}^{-1}$	<i>Fungsi invers penciutan dalam CTC</i>	75
T	<i>Jumlah timestep atau panjang sequence</i>	
$ x - G(y) _1$	<i>L1 distance antara ground truth dan generated image</i>	75
$ x - G(y) _2$	<i>L2 distance antara ground truth dan generated image</i>	75
$N \times N$	<i>Ukuran patch dalam PatchGAN</i>	
d	<i>Cohen's d (effect size)</i>	75
n	<i>Jumlah sampel</i>	75
p	<i>p-value (nilai probabilitas statistik)</i>	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	1
CNN	<i>Convolutional Neural Network</i>	2
GPU	<i>Graphics Processing Unit</i>	14

BAB I

PENDAHULUAN

I.1 Latar Belakang


Berdasarkan data Our World in Data (2025) yang dapat dilihat pada Gambar I.1, kanker atau tumor ganas menempati urutan kedua sebagai penyebab kematian tertinggi di dunia setelah penyakit kardiovaskular, dengan perkiraan angka kematian mencapai 10,6 juta jiwa. Di dalam kelompok penyakit mematikan tersebut, tumor otak menjadi salah satu tantangan terbesar dalam dunia kesehatan global. Menurut International Agency for Research on Cancer (2024a), terdapat 321.731 kasus baru tumor otak di seluruh dunia, dengan angka kematian mencapai 248.500 kasus. Hal ini menempatkan tumor otak pada peringkat ke-19 dalam jumlah kejadian dan peringkat ke-12 dalam jumlah kematian. Berdasarkan data tersebut, perbandingan antara peringkat jumlah kejadian dan peringkat jumlah kematian pada tumor selain otak tidak berbeda jauh dibandingkan tumor otak. Perbedaan peringkat antara jumlah kejadian dengan jumlah kematian tumor otak ini menunjukkan urgensi diagnosis tumor otak lebih tinggi dibandingkan tumor yang lain.

Di Indonesia, kasus baru tumor otak tercatat sebanyak 5.738 kasus (1,4% dari total kasus kanker), dengan angka kematian mencapai 5.259 kasus (2,2%). Hal ini menempatkan tumor otak pada peringkat ke-15 dalam jumlah kejadian dan peringkat ke-11 dalam jumlah kematian. Selain itu, prevalensi lima tahun dari tumor otak mencapai angka 20.134 atau setara dengan 7,7 per 100.000 penduduk (International Agency for Research on Cancer 2024b). Hal ini mengindikasikan hanya sedikit orang yang masih hidup setelah lima tahun didiagnosis menderita tumor otak. Oleh karena itu, pendeteksian dini tumor otak merupakan hal yang krusial untuk keberhasilan pengobatan dan prognosis pasien (Republik Indonesia, Kementerian Kesehatan 2025).

Menurut Mayo Clinic (2019), untuk melakukan diagnosis tumor otak, diperlukan pemeriksaan neurologis, seperti pemeriksaan penglihatan, pendengaran, keseimbangan, koordinasi, kekuatan, dan refleks. Jika terdapat masalah di satu atau lebih area,

Causes of death, World, 2023

The estimated annual number of deaths from each cause. Estimates come with wide uncertainties, especially for countries with poor vital registration¹.



Data source: IHME, Global Burden of Disease (2025)

OurWorldinData.org/causes-of-death | CC BY

1. Civil Registration and Vital Statistics system A Civil Registration and Vital Statistics system (CRVS) is an administrative system in a country that manages information on births, marriages, deaths and divorces. It generates and stores 'vital records' and legal documents such as birth certificates and death certificates.
 You can read more about how deaths are registered around the world in our article: [How are causes of death registered around the world?](#)

Gambar I.1 Penyebab kematian di dunia Tahun 2023 (Our World in Data 2025)

ini adalah petunjuk untuk melakukan pencitraan medis untuk melihat kondisi lebih lanjut. Terdapat cara yang dapat dilakukan untuk melakukan pencitraan medis pada tumor otak, yaitu pemindaian *CT Scan*, MRI otak, dan pemindaian *Positron Emission Tomography* (PET) otak. Oleh karena itu, pencitraan medis merupakan hal yang penting dalam pendeteksian tumor otak. Dari pencitraan medis tersebut, MRI menunjukkan akurasi diagnostik yang lebih tinggi dibandingkan *CT Scan*, yaitu MRI mendeteksi tumor otak pada 60% kasus dibandingkan dengan 50% oleh *CT Scan*. MRI menunjukkan akurasi diagnostik yang lebih tinggi, terutama untuk lokalisasi lesi dan penilaian parenkim, memperkuat statusnya sebagai standar emas dalam pencitraan tumor otak (Jaffar dkk. 2025).

Berdasarkan Hospetrack (2020), pada tahun 2019, Indonesia memiliki sekitar 750 pemindai *CT Scan* dan pemindai MRI yang jauh lebih rendah di antara 2.764 rumah sakit. Selain itu, disparitas MRI yang ada di Indonesia juga sangat besar. Berdasarkan data pada 2023, Kalimantan Barat hanya memiliki dua sistem MRI dengan jumlah penduduk mencapai lima juta jiwa. Sumatera Barat dengan 5,5 juta penduduk hanya memiliki empat alat kesehatan tersebut (Purnama 2025). Penggunaan MRI juga memiliki ketergantungan terhadap helium. Saat ini, terdapat kelangkaan helium secara global yang berdampak nyata pada penggunaan MRI Indonesia. Saat ini, Indonesia sedang mengembangkan inovasi teknologi MRI dengan desain tanpa helium. Namun, teknologi tersebut masih dalam tahap pengembangan dan belum terbukti dapat menyelesaikan permasalahan kelangkaan MRI di Indonesia (Permana 2025). Oleh karena itu, pendeteksian tumor otak melalui MRI sulit untuk dilakukan

di Indonesia dan salah satu alat pendeteksian tumor otak alternatif yang sudah lebih banyak digunakan adalah *CT Scan*. Sebuah studi dari Budiman dkk. (2024) mengonfirmasi bahwa penggunaan *CT Scan* terbukti sangat efektif dan memberikan dampak positif yang signifikan untuk keperluan deteksi dini tumor otak pada manusia.

Aspek yang penting dalam pendeteksian tumor otak adalah diagnosis yang dilakukan oleh radiolog. Menurut Nuraini (2024), Indonesia memiliki kesulitan akses tenaga radiolog dikarenakan distribusi tenaga medis yang tidak merata. Selain itu, diagnosis yang sering kali menghadapi tantangan dalam hal jumlah tenaga yang memadai untuk memenuhi kebutuhan pemeriksaan pasien yang semakin meningkat. Dengan meningkatnya jumlah kasus medis dan populasi yang terus bertumbuh, jumlah tenaga radiolog yang ada saat ini masih belum cukup untuk memenuhi seluruh permintaan pemeriksaan dengan akurat dan tepat waktu.

Saat ini, salah satu solusi yang ditawarkan untuk mengatasi permasalahan deteksi tumor otak adalah menggunakan teknologi *Artificial Intelligence* (AI). Pada penelitian yang dilakukan oleh Darmiati (2023), terdapat hasil bahwa bantuan AI secara signifikan meningkatkan sensitivitas dan spesifisitas semua radiolog dalam pendeteksian tumor pada payudara, dengan peningkatan median masing-masing sebesar 19,4% dan 12,1%. Penerapan AI secara langsung dalam praktik klinis juga telah dibuktikan keberhasilannya pada penanganan kasus tumor otak.

Salah satu penelitian terkini yang berfokus pada optimalisasi deteksi tumor otak menggunakan *CT Scan* adalah pengembangan *Correlation Learning Mechanism* oleh Woźniak, Siłka, dan Wieczorek (2021). Metode ini mengusulkan mekanisme pembelajaran korelasi baru untuk arsitektur jaringan saraf dalam yang menggabungkan *Convolutional Neural Network* (CNN) dengan arsitektur klasik. Hasil penelitian menunjukkan bahwa model CLM mampu mencapai akurasi sekitar 96%, serta presisi dan *recall* sekitar 95%. Dalam penelitian ini, CLM terbukti efektif dalam meningkatkan akurasi diagnostik pada citra CT tetapi penelitian ini memiliki keterbatasan utama berupa ketiadaan penjelasan hasil yang diberikan oleh model.

Pada AI yang digunakan untuk suplemen diagnostik tanpa transparansi terdapat permasalahan-permasalahan yang dapat terjadi. Berdasarkan Xu dan Shuttleworth (2023), terdapat permasalahan AI yang bersifat *black box* yang berarti dokter, pasien, atau pembuat AI tidak dapat memahami bagaimana AI menghasilkan kesimpulan atau rekomendasi medis. Hal ini dapat menyebabkan potensi kesalahan diagnosis, kehilangan pemahaman penuh terhadap informasi mengenai diagnosis, dan kesulitan dalam melacak identifikasi dan deteksi kesalahan medis. Salah satu solusi kece-

rdasan buatan yang saat ini sedang dikembangkan adalah penggunaan konsep *Explainable AI* (XAI). Berdasarkan Asmita dan Mittal (2025), XAI sangat penting untuk mengatasi ketidakpercayaan pada AI dengan cara meningkatkan transparansi dan interpretasi model *deep learning*. XAI memungkinkan para ahli, seperti radiolog untuk memahami bagaimana AI sampai pada suatu kesimpulan dengan menyoroti fitur-fitur data yang paling berpengaruh. Hal ini secara langsung membangun kepercayaan pada sistem otomatis, membantu kepatuhan terhadap regulasi, dan memperbaiki komunikasi hasil diagnosis kepada pasien.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah disampaikan, diagnosis tumor otak di Indonesia menghadapi tantangan berupa keterbatasan fasilitas MRI, sehingga mendorong penggunaan citra *CT Scan* sebagai alternatif utama. Di sisi lain, penggunaan *Artificial Intelligence* (AI) berbasis *deep learning* sebagai alat bantu diagnosis pada *CT Scan* masih memiliki kelemahan mendasar, yaitu sifat *black box* yang membuat landasan keputusannya tidak transparan. Ketiadaan penjelasan visual atas prediksi model ini menjadi persoalan, karena jika dibiarkan, model AI dengan akurasi tinggi sekalipun akan sulit divalidasi dan diandalkan objektivitasnya secara klinis. Oleh karena itu, penelitian ini mengusulkan pengembangan model *deep learning* untuk klasifikasi tumor otak pada citra *CT Scan* yang diintegrasikan dengan metode *Explainable AI* (XAI) guna memberikan transparansi diagnostik. Berdasarkan pokok persoalan tersebut, rumusan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Sejauh mana tingkat performa klasifikasi model *deep learning* yang dibangun dalam mendeteksi keberadaan tumor otak pada citra *CT Scan*?
2. Apakah integrasi metode *Explainable AI* pada model tersebut mampu menghasilkan representasi visual yang secara relevan dan tepat menyoroti area anomali tumor penyokong keputusan klasifikasi?

I.3 Tujuan

Tujuan utama dari tugas akhir ini adalah mengembangkan dan mengevaluasi arsitektur *deep learning* yang dapat mendeteksi keberadaan tumor otak pada citra *CT Scan* secara akurat sekaligus transparan. Kriteria keberhasilan dari tugas akhir ini diukur melalui dua aspek utama: (1) tercapainya performa klasifikasi model yang terukur secara kuantitatif melalui metrik evaluasi seperti akurasi, presisi, dan *recall*, serta (2) dihasilkannya visualisasi XAI sehingga model tidak lagi bertindak sebagai *black box*. Adapun tujuan dari pelaksanaan tugas akhir ini adalah:

1. Mengembangkan model *deep learning* untuk mengklasifikasikan keberadaan tumor otak pada citra *CT Scan*.

2. Mengembangkan visualisasi pada citra untuk menjelaskan fokus perhatian model saat melakukan klasifikasi.

I.4 Batasan Masalah

Batasan masalah yang dilakukan pada tugas akhir ini adalah:


1. Dalam pelatihan, pengujian, dan validasi data, tugas akhir ini menggunakan data sekunder yang bersifat publik dan tidak melakukan pengambilan data primer dari rumah sakit. *Dataset* yang digunakan merupakan gabungan dari *dataset Unpaired MR-CT Brain Dataset for Unsupervised Image Translation* (Al-Kadi dkk. 2022) yang bersumber dari Jordan University Hospital untuk citra otak dengan tumor, serta *dataset* dari Radiopaedia yang diambil secara manual.
2. Tugas akhir ini menggunakan data gambar otak dengan bidang axial.
3. Tugas akhir tidak akan mencakup pengembangan sistem pendeteksian tumor otak maupun aplikasi berskala produksi yang terintegrasi dengan sistem informasi rumah sakit.
4. Fokus utama klasifikasi adalah untuk mendeteksi keberadaan tumor otak. Klasifikasi lebih lanjut mengenai jenis, stadium, atau keganasan tumor hanya akan dilakukan jika label tersebut tersedia dalam *dataset* yang digunakan.
5. Tugas akhir ini hanya mengevaluasi kemampuan model dalam mendeteksi keberadaan tumor otak, dan tidak menilai atau mengukur dimensi tumor yang terdeteksi.

I.5 Metodologi

Metodologi tahapan pengerjaan tugas akhir ini akan mengadopsi kerangka kerja *Cross-Industry Process for Data Mining* (CRISP-DM) seperti pada Gambar I.2.

Keseluruhan tahapan yang akan dilalui selama pelaksanaan tugas akhir, yang spesifik untuk menyelesaikan persoalan yang diangkat, adalah sebagai berikut.

1. *Business Understanding*
Business Understanding dilakukan untuk mengidentifikasi permasalahan tumor otak yang terjadi di Indonesia dan potensi solusi yang dapat dihadirkan oleh kecerdasan buatan. Proses investigasi dan pengumpulan fakta pada tahap ini dilakukan melalui studi literatur sistematis. Pencarian literatur berfokus pada basis data akademik seperti Google Scholar, Scopus, dan Springer-Link, menggunakan kombinasi kata kunci seperti "tumor otak", "CT Scan", "deep learning", dan "XAI". *Filtering* literatur dilakukan untuk mendapatkan sumber primer yang relevan dan terbaru sehingga menjamin validitas dan



Gambar I.2 *Cross-Industry Process for Data Mining (CRISP-DM)* (Chapman dkk. 2000)

relevansi solusi yang diusulkan. Hal ini dilakukan dengan mencari studi literatur mengenai permasalahan tumor otak yang ada. Setelah itu, dilakukan pencarian solusi-solusi yang sudah berjalan dan yang sedang dikembangkan. Berdasarkan permasalahan dan solusi, dilakukan pendefinisian terhadap tujuan, persyaratan, dan rumusan masalah yang ingin dicapai.

2. *Data Understanding*

Data Understanding dilakukan untuk mengenali dan memeriksa *dataset* untuk mengidentifikasi karakteristik, kualitas, dan wawasan awal. Tahap ini dilakukan dengan mencari *dataset* publik citra *CT Scan* otak, lalu memeriksa data tersebut untuk mengetahui regulasi dalam pengumpulan data tersebut serta memeriksa kualitas data, seperti jumlah data dan distribusi kelas untuk mengidentifikasi potensi masalah dan hal yang harus dilakukan pada data tersebut.

3. *Data Preparation*

Data Preparation bertujuan untuk menghasilkan data yang bersih dan sesuai dengan model yang ingin digunakan. *Data preparation* dilakukan dengan cara membagi data menjadi tiga bagian, yaitu data latih, validasi, dan uji. Setelah itu, dilakukan pembersihan data yang memiliki kualitas rendah atau data *outlier*, *preprocessing* pada citra, dan penyeragaman format data citra sesuai

dengan model yang akan digunakan.

4. *Modeling*

Modeling dilakukan untuk memilih dan menetapkan teknik pemodelan yang ingin dilakukan dan melatihnya menggunakan hasil dari *data preparation*. *Modeling* dilakukan dengan memilih arsitektur model dan teknik XAI yang akan digunakan, membangun model menggunakan data latih, mengatur *hyper-parameter* model untuk meningkatkan performa, dan menilai kinerja model-model yang telah dibuat untuk disimpan pada evaluasi.

5. *Evaluation*

Evaluasi dilakukan untuk memastikan model yang telah dipilih dapat mencapai tujuan penelitian dan menjawab rumusan masalah yang sudah dibuat. Evaluasi dilakukan dengan mengukur performa model CNN secara kuantitatif, seperti metrik akurasi, presisi, dan *recall* serta mengukur performa model XAI secara kuantitatif berdasarkan *ground truth* untuk melihat seberapa signifikan XAI dapat menyoroti area tumor.

6. *Deployment*

Pada pengerjaan Tugas Akhir ini tidak dilakukan tahapan *deployment*.

I.6 Sistematika Penulisan

Tuliskan gambaran umum isi dari setiap bab yang ada dalam laporan tugas akhir. Sistematika penulisan ini memberikan panduan bagi pembaca tentang struktur dan alur pembahasan dalam laporan tugas akhir. Berikut adalah contoh sistematika penulisan yang dapat diikuti:

1. Bab I Pendahuluan: Berisi latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika penulisan laporan tugas akhir .
2. Bab II Studi Literatur: Berisi kajian pustaka yang relevan dengan topik tugas akhir, termasuk teori-teori, konsep-konsep, dan hasil-hasil penelitian sebelumnya yang mendukung pelaksanaan tugas akhir.
3. Bab III Analisis: Berisi penjelasan tentang analisis masalah dan kebutuhan pengguna serta berbagai alternatif solusinya.
4. Bab IV Perancangan: Berisi penjelasan tentang perancangan solusi yang diusulkan, misalnya arsitektur sistem, desain basis data, antarmuka pengguna, dan sebagainya.
5. Bab V Implementasi: Berisi penjelasan tentang proses implementasi solusi yang diusulkan, termasuk langkah-langkah yang diambil, teknologi yang digunakan, dan hasil yang diperoleh.
6. Bab VI Evaluasi: Berisi analisis dan evaluasi terhadap solusi yang diimplementasikan, termasuk metode pengujian, hal-hal yang disiapkan sebelum pe-

ngujian, hasil pengujian, dan penilaian kinerja.

7. Bab VII Kesimpulan dan Saran: Berisi kesimpulan dari hasil pelaksanaan tugas akhir dan saran untuk pengembangan lebih lanjut.
8. Daftar Pustaka: Berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. Lampiran: Berisi dokumen-dokumen pendukung seperti kode program, data lengkap hasil pengujian, rekaman wawancara, dan lain-lain.

BAB II


STUDI LITERATUR

II.1 Tumor Otak

Berdasarkan Mayo Clinic (2023), tumor otak didefinisikan sebagai pertumbuhan abnormal sel yang terjadi di dalam atau di dekat otak. Lokasi tumor dapat bervariasi, mencakup jaringan otak, saraf, kelenjar pituitari, kelenjar pineal, serta membran yang menutupi permukaan otak. Tumor yang bermula di otak disebut tumor otak primer, sedangkan tumor yang menyebar ke otak dari bagian tubuh lain disebut tumor otak sekunder atau metastatik.

II.1.1 Teknologi Pencitraan Medis Tumor Otak

Langkah awal untuk mendiagnosis tumor otak adalah pemeriksaan fisik, tes penglihatan, riwayat medis, dan tes neurologis untuk mengevaluasi fungsi otak serta saraf. Jika tes awal menunjukkan kemungkinan adanya tumor otak, pencitraan diagnostik akan dilakukan dan dianalisis oleh ahli neuroradiologi (Farber 2025). Dalam pencitraan tumor otak, terdapat tiga bidang utama yang bisa dilakukan oleh alat pencitraan seperti pada Gambar II.1 (Hartung dan Cadogan 2023).



Gambar II.1 *CT Scan* Otak (Abu Kamesh 2024)

Berdasarkan Radiology Key (2015), terdapat tiga bidang dalam pencitraan medis.

1. Bidang Aksial

Bidang aksial (atau *transverse*) adalah bidang horizontal yang membagi tubuh menjadi bagian atas dan bawah, tegak lurus terhadap sumbu panjang tubuh. Dalam pencitraan medis seperti *CT Scan*, bidang ini menampilkan irisan tubuh yang dilihat dari arah kaki menuju kepala atau sebaliknya.

2. Bidang Koronal

Bidang koronal (atau *frontal*) adalah bidang vertikal yang membagi tubuh menjadi bagian depan dan belakang. Penamaannya merujuk pada *coronal suture* tengkorak, yakni garis sambungan tulang yang melintang dari telinga kiri ke kanan—menyerupai letak mahkota atau bando.

3. Bidang Sagital

Bidang sagital adalah bidang vertikal yang membagi tubuh menjadi sisi kanan dan kiri. Penamaannya merujuk pada *sagittal suture* tengkorak yang posisinya menyerupai arah anak panah jika dilihat dari depan.

II.1.1.1 MRI

Magnetic Resonance Imaging (MRI) merupakan teknologi pencitraan 3D noninvasif beresolusi tinggi yang memanfaatkan interaksi medan magnet kuat dan gelombang radio terhadap proton dalam molekul air pada jaringan tubuh. Berdasarkan perbedaan waktu relaksasi energi proton tersebut, MRI sangat unggul untuk memvisualisasikan detail anatomi jaringan lunak—seperti struktur otak, saraf, dan otot—serta

efektif dalam mendiagnosis tumor tanpa paparan radiasi. Meskipun aman dari radiasi, penggunaannya dikontraindikasikan bagi pasien dengan implan logam (misalnya alat pacu jantung) dan memiliki risiko penyerta seperti kebisingan, stimulasi saraf, hingga potensi toksisitas agen kontras gadolinium pada penderita gangguan ginjal (National Institute of Biomedical imaging and Bioengineering 2025).


II.1.1.2 CT Scan

Computed Tomography (CT) adalah prosedur pencitraan diagnostik yang menggunakan teknologi sinar-X. Prosedur ini bekerja dengan mengarahkan berkas sinar-X yang sempit dan berputar cepat mengelilingi tubuh pasien. Sinyal yang dihasilkan kemudian diproses oleh komputer untuk membuat serangkaian gambar irisan tomografi secara detail, yang dapat direkonstruksi menjadi gambar tiga dimensi (3D).

CT Scan memiliki peran penting sebagai instrumen peringatan dini dalam mendiagnosis tumor otak. Berdasarkan penelitian oleh Budiman dkk. (2024), penggunaan CT Scan terbukti sangat efektif dan memberikan dampak positif bagi deteksi dini tumor otak pada manusia. Tingkat efektivitas ini dibuktikan secara kuantitatif melalui perolehan nilai rata-rata effect size sebesar 1.17 yang masuk dalam kategori tinggi. Selain itu, hasil pengujian N-Gain juga menunjukkan skor 0.58 dengan kategori efektivitas tinggi.

Meskipun MRI sering dianggap sebagai metode pencitraan yang lebih sensitif dalam mendeteksi keberadaan tumor yang berukuran kecil, CT Scan tetap menawarkan keunggulan lain, seperti tingkat ketersediaan alat yang lebih merata di berbagai fasilitas kesehatan serta waktu pemeriksaan yang jauh lebih singkat. Temuan yang mendukung efektivitas CT Scan pada tahap awal ini berdampak besar pada praktik klinis sehari-hari. Modalitas dapat membuat proses pengambilan keputusan diagnostik dan perencanaan pengobatan pasien menjadi lebih cepat dan efektif.

CT Scan dapat digunakan untuk mengidentifikasi penyakit atau cedera, seperti mencitrakan kepala untuk menemukan cedera, tumor, atau gumpalan yang menyebabkan *stroke* serta mencitrakan paru-paru atau patah tulang yang kompleks. Disamping kelebihan yang dipunyai, *CT Scan* memiliki kelemahan berupa prosedur ini menggunakan radiasi yang memiliki risiko biologis dan agen kontrasnya berpotensi menyebabkan reaksi alergi atau gangguan ginjal pada pasien tertentu (National Institute of Biomedical Imaging and Bioengineering 2022).



Gambar II.2 Perbandingan *CT Scan* dan MRI Otak (Mamourian 2020)

Selain risiko biologis, *CT Scan* juga kurang sensitif dalam mendiagnosis, seperti yang terlihat pada Gambar II.2. Pada kasus tumor *intra-axial*, masalah utamanya adalah kurang jelasnya gambar jaringan lunak. Menurut Mamourian (2020), banyak tumor jenis ini bersifat *isodense* atau kepadatannya mirip dengan jaringan otak normal. Akibatnya, tumor sulit dibedakan jika tidak memakai cairan kontras atau dibandingkan dengan hasil MRI. Selain itu, sering terjadi kebingungan diagnosis karena tumor bisa terlihat seperti penyakit lain, seperti infark subakut, abses otak, atau lesi demielinisasi. Masalah ini bisa diperparah oleh bias konfirmasi, di mana pembacaan hasil *CT Scan* terpengaruh oleh riwayat penyakit pasien. Oleh karena itu, kunci untuk mendeteksi tumor *intra-axial* pada *CT Scan* adalah dengan mengamati tanda-tanda kecil lainnya secara teliti (Mamourian 2020).

II.2 *Artificial Intelligence (AI)* dalam Pencitraan Medis

Implementasi AI pada citra medis memiliki dampak besar pada berbagai tugas dalam alur kerja radiologi. AI berdampak pada tugas-tugas klinis berbasis gambar, seperti deteksi kelainan, karakterisasi objek dalam gambar menggunakan segmentasi, diagnosis, dan penentuan stadium, serta pemantauan objek untuk diagnosis dan penilaian respons pengobatan.

Dalam konteks transparansi dan kemampuan interpretasi keputusan medis, model-model pembelajaran mesin tersebut dapat dikategorikan lebih lanjut menjadi dua jenis utama (Moreira dkk. 2024):

1. *White-Box Models*

Model ini dirancang dengan logika dasar dan proses yang jelas, sehingga mekanisme pengambilan keputusannya secara dapat ditafsirkan (*interpretable*) oleh manusia. Pengguna dapat memahami bagaimana model bekerja dengan memeriksa struktur internalnya secara langsung, seperti melihat bobot fitur

atau aturan keputusan. Contoh algoritma yang termasuk dalam kategori ini adalah *Decision Trees* dan regresi linear.

2. *Black-Box Models*

Model ini memiliki mekanisme internal yang sangat kompleks sehingga sulit atau tidak mungkin bagi pengguna manusia untuk memahami bagaimana prediksi atau hasil spesifik dihasilkan. Karena kompleksitasnya, hubungan antara input dan output sering dianggap sebagai misteri yang tidak dapat diperiksa secara manual. *Deep Neural Networks* dan model *ensemble* yang rumit merupakan representasi utama dari kategori ini.

Terdapat dua metode utama dalam pencitraan medis untuk tugas klasifikasi seperti membedakan tumor jinak atau ganas, yaitu *machine learning* tradisional dan *deep learning* (Hosny dkk. 2018).

II.2.1 *Deep Learning*

Deep learning menggunakan sistem *layers* yang secara bersamaan melakukan ekstraksi fitur, seleksi, dan klasifikasi selama proses pelatihan. Lapisan-lapisan ini belajar mengenali fitur dari yang abstrak, seperti garis hingga yang kompleks, seperti organ (Hosny dkk. 2018). Beberapa teknik utama yang biasa digunakan, yaitu:

1. CNN (*Convolutional Neural Networks*)

CNN adalah model *deep learning* yang dirancang untuk memproses data dengan topologi seperti *grid* dengan contoh berupa gambar. CNN dapat digunakan untuk mendeteksi objek dalam gambar seperti orang, mobil, dan bangunan. CNN juga dapat digunakan untuk melokalisasi objek dalam gambar, yang berarti dapat mengidentifikasi lokasi suatu objek dalam gambar.

CNN memiliki beberapa komponen kunci. Pertama, *convolutional layers* yang menerapkan filter pada gambar masukan untuk mendeteksi fitur seperti tepi dan tekstur, sekaligus menjaga hubungan spasial antarpiksel. Kedua, *pooling layers* yang melakukan pengurangan sampel untuk mengurangi kompleksitas komputasi dan jumlah parameter. Ketiga, *activation functions* yang memperkenalkan non-linearitas agar model dapat mempelajari hubungan data yang kompleks. Terakhir, *fully connected layers* yang bertanggung jawab membuat prediksi akhir berdasarkan fitur yang telah dipelajari oleh lapisan-lapisan sebelumnya (GeeksforGeeks 2020).


II.3 *Explainable AI (XAI)*

Explainable Artificial Intelligence (XAI) adalah seperangkat proses dan metode yang memungkinkan pengguna manusia untuk memahami hasil dan keluaran yang dibuat oleh algoritma *machine learning* (IBM 2023). Tujuan utama *Explainable AI*

adalah untuk mendapatkan model yang dapat diinterpretasikan oleh manusia. Interpretasi ini sangat penting untuk aplikasi di sektor-sektor sensitif seperti militer, perbankan, dan layanan kesehatan. Hal ini bertujuan agar para spesialis domain dapat diberikan penjelasan yang bermakna sehingga mereka dapat memahami dan memercayai solusi AI tersebut (Ali dkk. 2023).

II.3.1 Metode *Explainable AI* (XAI)

Berdasarkan mekanisme interpretasi, XAI memiliki hierarki yang dapat dilihat pada Gambar II.3.



Gambar II.3 Kategorisasi hierarkis metode XAI (Iftikhar dkk. 2025a)

Attribution-based methods memiliki konsep dengan memberi nilai pada setiap bagian masukan gambar. Bagian yang paling memengaruhi keputusan akhir akan mendapatkan nilai tinggi. Hal ini dapat membantu penggunaannya untuk melihat area pada gambar yang paling penting bagi AI. *Activation-based methods* melihat bagian gambar yang membuatnya bereaksi untuk memberikan penjelasan bagaimana AI mengenali fitur gambar secara bertahap. *Perturbation-based methods* menjelaskan keputusan dengan memodifikasi atau melakukan *masking* sebagian masukan dan mengamati dampaknya pada keluaran. *Transformer-based methods* memanfaatkan mekanisme *self-attention* dari *vision transformers* dan model terkait sehingga bisa menunjukkan bagian gambar yang sedang fokus diperhatikan oleh AI saat mengambil keputusan (Iftikhar dkk. 2025a).

II.3.1.1 *Attribution-based Methods*

Attribution-based methods menghasilkan visualisasi seperti *heatmap* dengan cara melacak representasi *internal model*, seperti gradien atau aktivasi, secara mundur dari *output* prediksi ke *input*. Metode ini memiliki asumsi bahwa tingkat kepentingan sebuah fitur *input* dapat diturunkan dari bagaimana perubahan pada fitur tersebut memengaruhi *output* akhir model. Terdapat beberapa algoritma *attribution-based methods* (Iftikhar dkk. 2025a), yaitu:

1. *Gradient-weighted Class Activation Mapping* (Grad-CAM)

Grad-CAM adalah sebuah metode XAI yang digunakan untuk memahami pentingnya berbagai lapisan dan fitur dalam sebuah CNN. Fungsi utamanya adalah membantu menemukan wilayah pada sebuah gambar yang memiliki dampak terbesar terhadap prediksi model.

2. FullGrad-CAM dan FullGrad-CAM++

Metode FullGrad-CAM dan FullGrad-CAM++ memperluas Grad-CAM dengan menggabungkan semua kontribusi bias dan gradien dari lapisan-lapisan sebelumnya. FullGrad-CAM melakukan *backpropagate gradient* dan mengakumulasi nilai absolutnya untuk menghasilkan penjelasan yang lebih informatif.

3. SmoothGrad

SmoothGrad mengurangi *visual noise* dengan menambahkan *Gaussian perturbation* kecil ke masukan beberapa kali dan mengambil rata-rata penjelasan berbasis gradien dari variasi-variasi ini. Hal ini dapat menghaluskan perubahan nilai yang sangat drastis yang muncul dalam metode berbasis gradien.

II.3.1.2 *Perturbation-based Methods*

Perturbation-based methods menjelaskan prediksi model dengan sengaja mengubah *input* dan mengamati bagaimana *output*-nya berubah. Saat sebuah bagian dari *input* ditutupi, diubah, atau dihilangkan dan menyebabkan prediksi model berubah drastis, bagian tersebut akan dianggap penting bagi keputusan model. Terdapat beberapa algoritma *perturbation-based methods* (Iftikhar dkk. 2025a), yaitu:

1. LIME (*Local Interpretable Model-Agnostic Explanations*)

Metode LIME membagi *input* menjadi segmen-segmen yang dapat ditafsirkan lalu mengganggu segmen-segmen ini dengan menyalakan atau mematikannya secara acak dan melatih model lokal yang lebih sederhana untuk meniru keputusan model *black-box* hanya di area tersebut. Bobot atau tingkat kepentingan dari model ini yang digunakan untuk menjelaskan fitur yang paling penting.

2. RISE (*Randomized Input Sampling for Explanation*)

Metode RISE bekerja dengan membuat banyak *mask* biner secara acak yang menutupi bagian-bagian gambar. Setiap gambar yang ditutupi *mask* dimasukkan ke model untuk dilihat skor prediksinya. Setelah itu, peta yang menunjukkan bagian penting dihasilkan dengan menggabungkan semua *mask* acak tersebut.

II.3.1.3 *Activation-based Methods*

Activation-based methods adalah teknik yang menghasilkan penjelasan dengan cara melihat langsung *feature maps* di dalam lapisan-lapisan jaringan saraf (CNN). Ter-

dapat beberapa algoritma *activation-based methods* (Iftikhar dkk. 2025a), yaitu:

1. DeConvNets (*Deconvolutional Networks*)

Metode DeConvNets memiliki tujuan untuk memahami dan memvisualisasikan apa yang telah dipelajari oleh setiap neuron atau lapisan dalam sebuah CNN. Metode DeConvNets mengambil sebuah aktivasi fitur dari lapisan dalam seperti neuron yang aktif dan merekonstruksinya kembali ke ruang *input*. Hasil dari metode ini adalah sebuah gambar yang menunjukkan pola visual yang membuat neuron tersebut aktif.

2. *Class Activation Mapping* (CAM)

Metode CAM dilakukan untuk mengidentifikasi wilayah pada gambar *input* yang paling penting yang digunakan model untuk membuat prediksi kelas tertentu. CAM melihat *importance weights* dari lapisan *global average pooling* yang terletak tepat sebelum lapisan keputusan akhir. Setelah itu, CAM menyorot area pada gambar asli yang memiliki peta fitur penting aktif. Hasilnya adalah sebuah *heatmap* yang menunjukkan lokasi bukti.

II.3.1.4 *Transformer-based Methods*

Transformer-based merupakan metode khusus pada arsitektur *Vision Transformer* (ViT) yang berfokus pada mekanisme *attention* bawaan dari model itu sendiri. ViT memproses gambar dengan membaginya menjadi beberapa potongan dan kemudian menghitung skor atensi di antara semua *patch* tersebut. Teknik ini mengekstrak dan memvisualisasikan skor atensi ini untuk menghasilkan peta yang menunjukkan bagian gambar yang paling diperhatikan oleh model saat mengambil keputusan (Iftikhar dkk. 2025a).

II.4 Evaluasi Model

Evaluasi model deep learning sangat krusial untuk menilai kemampuan nyata model dalam menggeneralisasi data baru, bukan sekadar melihat seberapa kecil tingkat kesalahan saat pelatihan. Secara kritis, metrik performa adalah alat ukur yang jauh lebih mudah diinterpretasikan untuk membandingkan secara obyektif dan memilih konfigurasi model yang paling optimal. Oleh karena itu, evaluasi wajib disesuaikan dengan tantangan spesifik masing-masing tugas untuk memastikan bahwa model terbukti akurat dan dapat diandalkan saat menghadapi skenario di dunia nyata (Terven dkk. 2025).

II.4.1 *Deep Learning*

Salah satu komponen penting dari *deep learning* untuk melatih dan mengevaluasi model adalah *performance metrics*. *Performance metrics* menilai kemampuan mo-

del untuk membuat prediksi akurat pada data yang belum pernah dilihat. Berdasarkan Terven dkk. (2025), terdapat beberapa *performance metrics* yang bisa digunakan dalam pendeteksian tumor, yaitu:

1. *Precision, Recall, dan F1-Score*

Precision mengukur akurasi prediksi positif, *recall* mengukur seberapa banyak kasus tumor aktual yang berhasil ditemukan, dan *F1-Score* memberikan skor keseimbangan antara keduanya.

2. *Precision-Recall Curve*


Kurva yang memvisualisasikan *trade-off* antara *precision* dan *recall* di berbagai ambang batas. *Precision-recall curve* direkomendasikan untuk data yang tidak seimbang dengan kelas minoritas yang penting.

II.4.2 Explainable Artificial Intelligence (XAI)

Berdasarkan Kadir, Mosavi, dan Sonntag (2023), untuk melakukan evaluasi terhadap XAI, diperlukan metrik XAI yang bisa ditentukan oleh dua taksonomi, yaitu taksonomi berbasis aplikasi dan taksonomi berbasis metodologi evaluasi.

1. Taksonomi Berbasis Aplikasi


Taksonomi berbasis aplikasi adalah klasifikasi yang mengelompokkan metrik XAI berdasarkan tujuan konseptualnya. Hal ini memisahkan konsep umum seperti *user satisfaction* dan *transparency* dari metode *local explanation* yang lebih teknis beserta turunannya seperti *attribution* dan *saliency* (Kadir, Mosavi, dan Sonntag 2023).



Gambar II.4 Taksonomi berdasarkan aplikasi XAI (Kadir, Mosavi, dan Sonntag 2023)

2. Taksonomi Berbasis Metodologi Evaluasi

Taksonomi berbasis metodologi evaluasi mengklasifikasikan teknik-teknik evaluasi penjelasan lokal ke dalam tiga pendekatan teknis utama, yaitu *retraining*, *ground truth comparison*, dan *input perturbation* (Kadir, Mosavi, dan Sonntag 2023).



Gambar II.5 Taksonomi berdasarkan metodologi evaluasi (Kadir, Mosavi, dan Sonntag 2023)

Dalam pendekatan *ground truth comparison*, terdapat penelitian terbaru oleh Muhammad dan Bendeche (2025) yang mengusulkan metrik evaluasi kuantitatif bernama XAlign. Metrik ini dirancang untuk mengatasi keterbatasan metrik yang tumpang tindih standar dengan menilai *spatial fidelity heatmap* melalui tiga komponen integratif yang diformulasikan sebagai berikut.

(a) *Weighted Relevance Overlap* (WRO)

Komponen ini mengukur proporsi relevansi penjelasan yang terlokalisasi secara tepat di dalam area anotasi ahli. Semakin tinggi nilai WRO, semakin fokus penjelasan tersebut pada area klinis yang relevan. Secara matematis, WRO didefinisikan seperti pada Persamaan II.1:

$$WRO = \frac{\sum_{i \in G} X_i}{\sum_i X_i} \quad (II.1)$$

G merepresentasikan himpunan piksel dalam masker *ground truth*. X_i adalah skor relevansi intensitas *heatmap* pada piksel ke- i .

(b) *Boundary Agreement Score* (BAS)

BAS menilai ketepatan penyelarasan struktural antara batas *heatmap* dengan kontur lesi atau tumor menggunakan *Hausdorff Distance* yang dinormalisasi, seperti yang ditunjukkan pada Persamaan II.2:

$$BAS = 1 - \frac{HD(G, X)}{\max_dim(I)} \quad (II.2)$$

$HD(G, X)$ adalah jarak Hausdorff antara kontur *ground truth* (G) dan peta penjelasan (X). $\max_dim(I)$ adalah dimensi maksimum citra untuk normalisasi. Nilai BAS yang mendekati 1 mengindikasikan korespondensi anatomis yang presisi.

(c) *Dispersion Penalty* (DP)

Komponen ini memberikan penalti terhadap penyebaran atribusi di luar area klinis untuk memastikan peta *saliency* tetap ringkas, dengan formulasi pada Persamaan II.3:

$$DP = \frac{\sum_{i \notin G} X_i}{\sum_i X_i} \quad (II.3)$$

$i \notin G$ menunjukkan piksel yang berada di luar area *ground truth*. Nilai DP yang lebih rendah menandakan penjelasan yang lebih fokus dengan sedikit *noise* latar belakang.

Secara keseluruhan, skor akhir XAlign dihitung dengan menggabungkan ke-

tiga komponen tersebut menggunakan bobot skalar (α, β, γ) seperti pada Persamaan II.4:

$$XAlign = \alpha \cdot WRO + \beta \cdot BAS - \gamma \cdot DP \quad (II.4)$$

Penggunaan XAlign memungkinkan evaluasi yang tidak hanya mengukur akurasi lokasi, tetapi juga kepatuhan bentuk penjelasan terhadap anatomi tumor yang sebenarnya (Muhammad dan Bendeche 2025).

Untuk menentukan metrik evaluasi XAI, prosesnya dimulai dengan mengidentifikasi konsep yang akan diuji menggunakan taksonomi berbasis aplikasi. Taksonomi ini membantu membedakan apakah tujuannya adalah untuk mengukur konsep umum seperti *user satisfaction* dan *transparency*, atau untuk mengevaluasi penjelasan teknis yang lebih spesifik seperti *local explanation*, yang mencakup metode seperti *salien-ty*. Setelah itu, taksonomi berbasis metodologi evaluasi digunakan untuk memilih pendekatan teknis yang sesuai untuk mengevaluasi penjelasan lokal tersebut (Kadir, Mosavi, dan Sonntag 2023).

II.5 Penelitian Terkait

II.5.1 Pendeteksian Tumor

II.5.1.1 *Detection and Classification of Brain Tumor Using a Hybrid Learning Model in CT Scan Images*

ghasemi2025hybrid<empty citation> mengajukan model hibrid yang menggabungkan fitur *handcrafted* (LBP, HOG, dan intensitas median) dengan fitur *deep learning* dari ResNet50 dan AlexNet yang dioperasikan dalam mode *frozen*, diseleksi menggunakan algoritma SelectKBest ($k = 10.000$), dan diklasifikasikan melalui *Multi-layer Perceptron* (MLP) lima lapisan untuk membedakan empat kelas tumor otak pada citra CT scan. Meskipun pendekatan fusi fitur ini terbukti efektif dengan akurasi 94,82%, spesifisitas 98,35%, dan $AUC > 0,98$ pada seluruh kelas, terdapat sejumlah kelemahan mendasar yang perlu dicermati. Dataset yang digunakan hanya bersumber dari satu repositori daring (Radiopaedia) dengan total 1.388 citra, sehingga generalisabilitas model ke skenario klinis multisenter masih dipertanyakan. Selain itu, penggunaan CNN *pre-trained* tanpa *fine-tuning* berpotensi membatasi adaptasi model terhadap karakteristik spesifik citra CT otak, mengingat bobot yang digunakan dilatih pada domain ImageNet yang berbeda secara signifikan. Ketiadaan analisis *explainability* juga menjadi hambatan adopsi klinis yang krusial.

II.5.1.2 *Deep Neural Network Correlation Learning Mechanism for CT Brain Tumor Detection*

Woźniak, Siłka, dan Wieczorek (2021) mengajukan *Correlation Learning Mechanism* (CLM) yang mengintegrasikan CNN dengan ANN klasik untuk mendeteksi tumor otak pada citra CT *scan* secara adaptif. Inovasi utamanya terletak pada mekanisme pemilihan palet filter secara dinamis, di mana ANN mengevaluasi hasil CNN dan menyimpan konfigurasi terbaik ke dalam arsip untuk menyempurnakan iterasi berikutnya. Proses pelatihan dipercepat melalui implementasi *multi-threading* paralel berbasis algoritma Adam, yang memungkinkan eksplorasi ruang konfigurasi secara luas dalam waktu singkat. Model dievaluasi pada dua *dataset* citra CT dan mencapai akurasi 96,55% serta 95,09%, dengan spesifisitas 97,43% sebagai nilai tertinggi dibandingkan metode pembandingan, mengindikasikan kemampuan superior dalam meminimalkan diagnosis positif palsu.

II.5.1.3 *Explainable CNN for brain tumor detection and classification through XAI based key features identification*

Iftikhar dkk. (2025b) mengajukan pendekatan *explainable* CNN untuk klasifikasi tumor otak guna mengatasi sifat *black-box* pada model *deep learning*. Penelitian ini mengintegrasikan Grad-CAM, SHAP, dan LIME ke dalam arsitektur CNN, di mana analisis Grad-CAM dimanfaatkan untuk memangkas *layer* berkontribusi minimal sehingga menghasilkan model yang lebih efisien. Model dievaluasi pada *dataset* MRI empat kelas (*meningioma, glioma, pituitary, no tumor*) dan mencapai akurasi 99,21% pada data latih serta 94,72% pada data uji, dengan visualisasi XAI yang membuktikan fokus model pada area patologis yang relevan.

II.5.1.4 *Deep-EFNet: An Optimized EfficientNetB0 Architecture with Dual Regularization for Scalable Multi-Class Brain Tumor Classification in MRI*

Alshaari dan Alqahtani (2025) mengajukan arsitektur *deep learning* berbasis *transfer learning* bernama Deep-EFNet untuk klasifikasi multi-kelas tumor otak dari citra MRI, guna mengatasi tantangan kompleksitas ekstraksi fitur serta keterbatasan generalisasi model pada *dataset* berukuran bervariasi. Penelitian ini memanfaatkan EfficientNetB0 sebagai *backbone* pra-latih dengan bobot ImageNet, yang diperkaya dengan lapisan *batch normalization, global average pooling*, dua lapisan *dense* (512 dan 256 unit dengan aktivasi ReLU dan regularisasi L2), serta *dropout* bermuatan 0,5 untuk mencegah *overfitting*. Pelatihan dilakukan dalam dua fase: fase pertama membekukan seluruh bobot *backbone* dan melatih hanya *classification head* dengan laju pembelajaran 10^{-4} , sedangkan fase kedua melakukan *fine-tuning* pada 30 lapisan teratas dengan laju pembelajaran 10^{-3} agar fitur tingkat tinggi dapat diadaptasi

terhadap tugas klasifikasi spesifik. Model dievaluasi pada dua *dataset* MRI empat kelas (*glioma, meningioma, pituitary, no tumor*), yakni 3K-DS (3.064 citra) dan 7K-DS (7.023 citra), menggunakan validasi *5-fold cross-validation*. Hasil menunjukkan akurasi 95,4% pada 3K-DS dan 98,2% pada 7K-DS untuk evaluasi *single-split*, serta ROC-AUC sebesar 0,99–1,00 di seluruh kelas, melampaui metode mutakhir seperti *hybrid CNN* (94%), CGAN (97%), dan Deep-GAN (96%).

II.5.2 XAI

II.5.2.1 *An XAI-Enhanced EfficientNetB0 Framework for Precision Brain Tumor Detection in MRI Imaging*

Mahesh dkk. (2024) mengintegrasikan teknik *Explainable AI* (XAI) berupa *Gradient-weighted Class Activation Mapping* (Grad-CAM) ke dalam model klasifikasi tumor otak berbasis MRI, dengan tujuan mengatasi sifat *black-box* model *deep learning* yang menghambat kepercayaan tenaga medis terhadap rekomendasi diagnostik berbasis AI. Grad-CAM bekerja dengan menghitung gradien kelas keluaran terhadap peta fitur lapisan konvolusi terakhir, menghasilkan *heatmap* yang divisualisasikan di atas citra MRI untuk menunjukkan area yang paling memengaruhi prediksi model. Penelitian ini mengklaim bahwa pola *heatmap* yang dihasilkan selaras dengan penanda diagnostik klinis yang sudah dikenal, seperti lokalisasi massa tumor pada kasus *glioma* dan aktivasi yang menyebar pada kasus *No Tumor*.

II.5.2.2 *Explainable CNN for Brain Tumor Detection and Classification through XAI Based Key Features Identification*

Iftikhar dkk. (2025b) mengajukan pendekatan CNN berbasis XAI untuk klasifikasi tumor otak multi-kelas dari citra MRI, di mana Grad-CAM dimanfaatkan tidak hanya sebagai alat visualisasi, tetapi juga sebagai mekanisme pemangkasan arsitektur model secara sistematis dengan mengeliminasi lapisan-lapisan yang berada di bawah ambang batas kontribusi minimum, sehingga menghasilkan model yang lebih ringkas tanpa penurunan performa yang signifikan. Validasi interpretabilitas dilengkapi dengan SHAP untuk analisis kepentingan fitur secara global dan LIME untuk eksplanasi berbasis *superpixel* pada level prediksi individual. Model dievaluasi pada dua dataset MRI empat kelas dengan total 7.023 citra (Msoud) dan 3.264 citra (NeuroMRI), mencapai akurasi 99,21% pada data *seen* dan 94,72% pada data *unseen*. Keterbatasan utama studi ini adalah cakupan evaluasi yang terbatas pada modalitas MRI tanpa validasi silang pada modalitas pencitraan lain seperti CT Scan, serta belum dilakukannya validasi klinis formal oleh tenaga medis. Celah ini menjadi salah satu landasan tugas akhir untuk mengeksplorasi penerapan integrasi XAI pada modalitas CT Scan yang lebih umum tersedia di fasilitas kesehatan Indonesia.

II.5.3 Kesenjangan

Meskipun penelitian di bidang deteksi dan klasifikasi tumor berbasis *deep learning* telah menunjukkan perkembangan yang pesat, sejumlah kesenjangan mendasar masih belum tertangani secara memadai dalam literatur yang ada.

Pertama, sebagian besar penelitian masih terfokus pada modalitas MRI dan belum memvalidasi pendekatan mereka pada *CT Scan*. Alshaari dan Alqahtani (2025) hanya mengevaluasi Deep-EFNet pada dua dataset MRI tanpa eksplorasi lintas modalitas, sementara Iftikhar dkk. (2025b) juga membatasi evaluasinya secara eksklusif pada MRI meskipun arsitekturnya dirancang untuk klasifikasi multi-kelas yang lebih general. *CT Scan* memiliki karakteristik intensitas, resolusi kontras, dan artefak yang secara fundamental berbeda dari MRI, sehingga kemampuan model maupun interpretabilitas XAI yang telah terbukti pada MRI tidak dapat diasumsikan berlaku langsung pada modalitas ini. Padahal, *CT Scan* merupakan modalitas yang jauh lebih tersedia dan terjangkau di fasilitas kesehatan negara berkembang, termasuk Indonesia, sehingga validasi pada modalitas ini menjadi kebutuhan yang mendesak secara klinis.

Kedua, terdapat kesenjangan yang tidak homogen dalam hal adopsi *explainability*: sebagian penelitian sama sekali tidak menyertakan komponen XAI, sementara sebagian lainnya telah mengadopsinya namun masih dalam lingkup validasi yang dangkal. Alshaari dan Alqahtani (2025) tidak mengintegrasikan teknik XAI apapun sehingga proses pengambilan keputusan model sepenuhnya bersifat *black-box* dan menyulitkan interpretasi klinis. Kondisi serupa dijumpai pada ghasemi2025hybrid<empty citation> yang mengusulkan model hibrid berbasis *CT Scan* dengan akurasi kompetitif, namun tidak menyertakan mekanisme *explainability* apapun; arsitektur fusi fitur yang kompleks justru memperparah sifat *black-box*-nya karena kontribusi masing-masing komponen fitur—LBP, HOG, ResNet50, maupun AlexNet—terhadap keputusan klasifikasi tidak dapat ditelusuri secara transparan, sehingga klaim potensi klinis yang diajukan penulis sulit dipertanggungjawabkan tanpa dukungan interpretabilitas yang memadai. Di sisi lain, Mahesh dkk. (2024) telah mengintegrasikan Grad-CAM ke dalam arsitektur EfficientNetB0, namun validasi eksplanasi yang dilakukan hanya berupa inspeksi visual terhadap kesesuaian heatmap dengan penanda diagnostik yang sudah diketahui sebelumnya, tanpa pengukuran kuantitatif terhadap *ground truth mask* tumor. Yang patut dicermati, Mahesh dkk. sendiri mengakui dalam tinjauan literturnya bahwa area yang disoroti Grad-CAM tidak selalu divalidasi secara klinis untuk memastikan kesesuaiannya dengan fitur yang relevan secara medis, namun metodologi yang diajukan tidak beranjak dari keterbatasan tersebut. Kondisi

ini menunjukkan bahwa keberadaan teknik XAI saja tidak cukup; validasi objektif terhadap kebermanaknaan spasial eksplanasinya merupakan lapisan kebutuhan tersendiri yang masih terabaikan dalam literatur.

Berdasarkan kesenjangan-kesenjangan tersebut, tugas akhir ini mengusulkan pendekatan yang beroperasi pada modalitas *CT Scan* sekaligus mengintegrasikan Grad-CAM sebagai mekanisme *explainability* yang divalidasi secara objektif terhadap *ground truth mask* tumor, guna menghasilkan sistem diagnosis yang tidak hanya akurat, tetapi juga transparan dan dapat dipertanggungjawabkan kesesuaian spasial eksplanasinya dalam konteks klinis yang relevan.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Penelitian oleh Zienius dkk. (2019) menganalisis jalur diagnosis tumor otak melalui pemindaian *Direct Access Computed Tomography* (DACT) di layanan primer. Studi berbasis populasi ini dilakukan selama lima tahun di wilayah Lothian, Skotlandia, dengan mengevaluasi 2.938 rujukan dari dokter umum yang mencurigai adanya patologi intrakranial. Selain menilai keandalan CT kepala sebagai modalitas diagnostik, studi ini secara kritis mengevaluasi efektivitas dua pedoman rujukan utama, yaitu pedoman Kernick dan NICE 2005, dalam mengidentifikasi pasien yang berisiko mengidap tumor otak.

III.1.1 Alur Diagnosis Tumor Otak

Saat ini, diagnosis tumor otak di layanan primer dilakukan melalui serangkaian tahapan berikut (Zienius dkk. 2019):

1. Pasien Merasakan Gejala dan Memeriksakan Diri ke Dokter Umum
Gejala tumor otak bersifat tidak khas dan mudah dikira penyakit lain, sehingga pasien rata rata harus mengunjungi dokter umum sebanyak tiga kali atau lebih sebelum akhirnya mendapat rujukan (Zienius dkk. 2019).
2. Dokter Umum Membuat Rujukan *Direct Access CT* (DACT)
Dokter umum dapat merujuk pasien langsung untuk pemindaian CT kepala tanpa melalui spesialis terlebih dahulu. Namun, pedoman rujukan yang tersedia yaitu pedoman Kernick dan NICE 2005 terbukti tidak akurat dalam memilih pasien, dengan nilai prediksi positif hanya sebesar 3% dan tingkat kesepakatan antar pedoman yang rendah (*weighted kappa* = 0,33) (Zienius dkk. 2019).
3. Pasien Menunggu Jadwal Pemindaian
Setelah rujukan dibuat, pasien tidak langsung menjalani pemindaian. Rata rata waktu tunggu dalam studi ini adalah 17,3 hari untuk seluruh pasien, dan 14,6 hari untuk pasien yang akhirnya terdiagnosis tumor signifikan (Zienius

dkk. 2019). Karena DACT bukan jalur darurat, keterlambatan ini dianggap wajar secara prosedural, namun dalam konteks tumor otak, setiap hari penundaan tetap memiliki implikasi klinis yang nyata.

4. Pemindaian Dilakukan dan Dianalisis oleh Konsultan Neuroradiologi

Seluruh pemindaian CT kepala dilakukan di satu pusat neurosains terpusat dan dilaporkan oleh konsultan neuroradiologi. CT kepala terbukti cukup andal sebagai alat skrining karena tidak ditemukan satu pun hasil negatif palsu (*false negative*) dalam studi ini. Namun, *diagnostic yield* untuk tumor signifikan hanya sebesar 1,43% (Zienius dkk. 2019), yang berarti sebagian besar pemindaian tidak menemukan tumor. Pelaksanaan neuroimaging sejak awal turut mempersingkat waktu yang dibutuhkan hingga hasil analisis tersedia bagi klinisi. Hal ini tercermin dalam temuan **carey2019impact**<empty citation>, yang melaporkan bahwa median waktu menuju diagnosis tumor otak ganas pada kelompok yang menjalani neuroimaging awal hanya sebesar 8 hari sejak kunjungan pertama terkait keluhan sakit kepala ($p < 0,001$).

5. Laporan Dikembalikan ke Dokter Umum untuk Menentukan Tindak Lanjut

Dari 559 pasien dengan temuan abnormal nontumor, sebanyak 34,2% tetap perlu dirujuk untuk pencitraan lanjutan atau penilaian spesialis (Zienius dkk. 2019). Ketiadaan standar pelaporan yang baku mempersulit interpretasi dokter umum, khususnya terhadap temuan insidental.

6. Pasien Dirujuk ke Spesialis dan Dikonfirmasi melalui Histopatologi

Apabila hasil pemindaian mencurigakan, pasien dirujuk ke spesialis untuk konfirmasi melalui histopatologi. Dari 42 tumor signifikan yang ditemukan, jenis terbanyak adalah metastasis (40%), diikuti tumor hipofisis (19%), meningioma (17%), *glioblastoma multiforme* (12%), glioma non GBM (10%), dan limfoma SSP (2%) (Zienius dkk. 2019).

Secara keseluruhan, alur DACT berfungsi dengan baik secara teknis dan mampu mendukung diagnosis tumor otak yang lebih cepat melalui neuroimaging awal, sebagaimana ditunjukkan oleh **carey2019impact**<empty citation> dengan median waktu diagnosis sebesar 8 hari sejak kunjungan pertama. Namun, Zienius dkk. (2019) menegaskan bahwa sistem ini masih lemah pada tahap seleksi pasien dan interpretasi hasil, sehingga efektivitas dan efisiensi alur secara keseluruhan belum optimal dan masih membutuhkan peningkatan lebih lanjut.

III.1.2 Penggunaan AI dalam CT Scan Otak

Meskipun teknologi AI telah dikembangkan untuk membantu interpretasi *non contrast CT head* (NCCTH), penggunaannya saat ini masih berada pada tahap evaluasi berbasis data nyata dan belum memasuki tahap implementasi klinis. Studi AI REA-

CT (**novak2025**) merupakan contoh konkret dari tahap ini: sebuah studi *multireader multicase* yang menguji alat AI bernama *qER EU 2.0* pada 150 pemindaian nyata dari pasien gawat darurat, melibatkan 30 pembaca dari empat rumah sakit NHS di Inggris.

Hasil evaluasi menunjukkan bahwa bantuan AI meningkatkan sensitivitas pembaca secara bermakna dalam mendeteksi abnormalitas kritis, namun disertai penurunan spesifisitas yang signifikan (**novak2025**). Lebih lanjut, performa algoritma terbukti tidak merata, yakni deteksi *mass effect*, yang merupakan salah satu tanda adanya lesi desak ruang seperti tumor, hanya menghasilkan AUC sebesar 0,604, jauh di bawah subkelompok patologi lainnya (**novak2025**). Para penulis secara eksplisit menyatakan bahwa hasil studi retrospektif ini tidak dapat langsung diterapkan dalam praktik klinis, dan menegaskan perlunya studi prospektif lanjutan sebelum teknologi ini dapat diimplementasikan secara bertanggung jawab (**novak2025**).

III.2 Analisis Kebutuhan

III.2.1 Identifikasi Masalah Pengguna

Terdapat dua kelompok pengguna utama yang menghadapi masalah terkait penerapan AI dalam medis, yaitu profesional medis (dokter dan radiolog) serta pasien. Bagi profesional medis, tantangan utamanya tidak hanya terletak pada adopsi teknologi baru, tetapi juga pada keterbatasan manusiawi dan beban kerja yang ekstrem dalam praktik klinis. Berdasarkan Zhang dkk. (2023), tingkat kesalahan diagnostik dalam radiologi berkisar antara 10-26% dengan 60-80% kesalahan diklasifikasikan sebagai kesalahan perseptual atau kegagalan dalam mendeteksi adanya lesi. Faktor kelelahan turut berperan signifikan dengan survei mencatat 47% radiolog mengalami *burnout* dan 58% mengalami gejala fisik seperti kelelahan mata yang dapat mengganggu akurasi interpretasi.

Di Indonesia, masalah ini menjadi jauh lebih kritis akibat ketimpangan rasio tenaga medis. Data analisis pasar layanan radiologi mencatat bahwa Indonesia hanya memiliki sekitar 2.161 radiolog terdaftar untuk melayani populasi sebesar 277 juta jiwa, atau setara dengan rasio 1,2 radiolog per 100.000 penduduk (Insights10 2023). Kondisi kekurangan SDM ini secara langsung meningkatkan beban kerja radiolog, yang berpotensi memperparah risiko *burnout* dan kesalahan diagnosis. Selain itu, profesional medis juga menghadapi masalah rendahnya kepercayaan terhadap keandalan sistem AI. Masalah ini berakar dari kurangnya edukasi, pelatihan, dan minimnya keterlibatan mereka dalam proses pengembangan sistem (Syafthan 2025). Hal ini menciptakan paradoks bahwa teknologi yang sangat dibutuhkan untuk mengurangi

human error justru diragukan validitasnya oleh penggunanya sendiri.

Dari sisi pasien, tantangan utama yang menghambat adopsi *Artificial Intelligence* (AI) dalam praktik klinis adalah kurangnya kepercayaan terhadap validitas diagnosis yang melibatkan algoritma. Berbeda dengan asumsi umum bahwa teknologi canggih akan meningkatkan rasa aman pasien, literatur terbaru justru menunjukkan fenomena sebaliknya, yaitu keterlibatan AI sering kali dipersepsikan sebagai faktor yang mendegradasi kualitas layanan medis. Riset eksperimental terbaru yang dilakukan oleh Chen dan Cui (2025) memberikan bukti bahwa kepercayaan pasien terhadap dokter dan intensi untuk melakukan pengobatan mencapai titik tertinggi justru ketika dokter secara eksplisit menyatakan tidak menggunakan AI dalam proses diagnosisnya dengan skor rata-rata kepercayaan 0,63. Sebaliknya, ketika pasien mengetahui bahwa dokter menggunakan AI secara ekstensif, tingkat kepercayaan mereka menurun ke angka 0,30 (Chen dan Cui 2025). Hal ini mengindikasikan bahwa di mata pasien, penggunaan AI belum dianggap sebagai peningkatan kapabilitas diagnostik, melainkan sebagai substitusi yang mengurangi nilai keahlian manusia.

Penurunan kepercayaan ini bukan tanpa alasan. Skeptisisme pasien berakar pada beberapa kekhawatiran fundamental. Pertama, risiko halusinasi AI, seperti model generatif dapat memproduksi informasi medis yang terdengar masuk akal dan meyakinkan tetapi secara faktual salah atau dibuat-buat. Ketakutan akan diagnosis yang keliru akibat kesalahan algoritma ini menjadi penghalang psikologis utama. Kedua, masalah transparansi dan akuntabilitas. Pasien sering kali memandang AI sebagai *black-box* yang proses pengambilan keputusannya tidak dapat dijelaskan secara intuitif, memicu keraguan apakah keputusan medis tersebut didasarkan pada kondisi unik pasien atau sekadar pola statistik semata (Chen dan Cui 2025). Selain itu, terdapat korelasi negatif antara persepsi profesionalisme dan penggunaan AI. Pasien cenderung mempertanyakan kompetensi dan penilaian klinis dokter yang terlalu bergantung pada alat bantu AI, terutama jika alat tersebut bersifat umum dan tidak dirancang khusus untuk medis. Penggunaan alat semacam ini dianggap mengaburkan batas tanggung jawab profesional dan menurunkan standar interaksi manusiawi yang menjadi inti dari layanan kesehatan (Chen dan Cui 2025). Temuan ini menegaskan bahwa diperlukan transparansi, validasi klinis yang ketat, dan jaminan pengawasan manusia untuk mengatasi ketidakpercayaan pasien.

Berdasarkan analisis dari studi literatur yang dijelaskan pada subbab, analisis kondisi saat ini, dan analisis permasalahan pengguna, diidentifikasi 4 permasalahan utama, yaitu:

1. Seleksi Pasien yang Lh dan Tidak Akurat

Pedoman rujukan yang digunakan dokter umum, yaitu pedoman Kernick dan NICE 2005, terbukti memiliki nilai prediksi positif yang sangat rendah, hanya sebesar 3%, dengan tingkat kesepakatan antar pedoman yang buruk (*weighted kappa* = 0,33). Artinya, kedua pedoman ini hampir tidak lebih baik dari tebakan acak dalam memilah pasien yang benar-benar berisiko tumor. Implikasinya, sebagian besar pemindaian yang dilakukan tidak menemukan tumor (*diagnostic yield* hanya 1,43%), sehingga sumber daya radiologi terbuang untuk kasus yang tidak relevan, sementara pasien berisiko tinggi bisa saja terlambat tersaring (Zienius dkk. 2019).

2. Keterlambatan Diagnosis

Rata-rata pasien harus mengunjungi dokter umum tiga kali atau lebih sebelum mendapat rujukan, ditambah waktu tunggu pemindaian rata-rata sebesar 17,3 hari (Zienius dkk. 2019). Meskipun prosedur ini dianggap wajar secara administratif, dalam konteks tumor otak setiap hari penundaan berdampak signifikan terhadap prognosis. Studi **carey2019impact** membuktikan bahwa neuroimaging awal mampu mempersingkat waktu diagnosis hingga median 8 hari sejak kunjungan pertama, namun sayangnya akses ke jalur cepat ini masih bergantung pada keputusan dokter umum yang disaring dengan pedoman yang tidak akurat.

3. Ketimpangan Sumber Daya Radiologi

Rasio 1,2 radiolog per 100.000 penduduk di Indonesia merupakan angka yang jauh dari memadai untuk menopang sistem diagnosis berbasis pencitraan (Insights10 2023). Beban kerja yang berlebihan ini tidak hanya menciptakan risiko *burnout*—dengan 47% radiolog mengalaminya secara global—tetapi juga mendegradasi akurasi interpretasi secara sistemik, mengingat 60–80% kesalahan diagnostik dalam radiologi bersifat perseptual, yakni radiolog gagal mendeteksi lesi yang sebenarnya ada (Zhang dkk. 2023). Kondisi ini menjadikan keterlibatan AI bukan sekadar pilihan, melainkan kebutuhan yang mendesak.

4. Kurangnya Kepercayaan dari Klinisi dan Pasien Ini adalah isu paradoksikal yang paling kritis. Di satu sisi, profesional medis meragukan AI karena kurangnya edukasi dan minimnya keterlibatan mereka dalam proses pengembangannya (Syafthah 2025). Di sisi lain, pasien justru memberikan kepercayaan tertinggi kepada dokter yang secara eksplisit *tidak* menggunakan AI (skor rata-rata 0,63), dibandingkan dokter yang menggunakannya secara ekstensif (skor 0,30) (Chen dan Cui 2025). Paradoks ini menunjukkan bahwa

masalah adopsi AI dalam medis bukan semata-mata soal kapabilitas teknis, melainkan soal legitimasi sosial dan kepercayaan institusional yang belum terbangun. Tanpa menyelesaikan krisis kepercayaan ini, sistem AI yang secara teknis canggih sekalipun akan menghadapi resistensi besar dari seluruh ekosistem layanan kesehatan.

Dengan mempertimbangkan keempat permasalahan tersebut, dapat disimpulkan bahwa meskipun alur diagnosis tumor otak melalui jalur *Direct Access CT* telah berfungsi secara teknis, sistem ini masih memiliki berbagai kelemahan yang signifikan dari sisi klinis maupun struktural. Seleksi pasien yang tidak akurat, keterlambatan diagnosis yang berdampak klinis nyata, ketimpangan sumber daya radiologi yang ekstrem, khususnya di Indonesia, serta defisit kepercayaan terhadap AI dari sisi klinis maupun pasien. Oleh karena itu, penelitian ini bertujuan untuk mengembangkan model AI yang dilengkapi dengan modul *Explainable AI* berupa visualisasi untuk deteksi tumor otak melalui citra CT scan kepala. Model ini diharapkan dapat membuka peluang dalam pembuatan sistem yang memperketat seleksi pasien sejak tahap awal, mempersingkat waktu menuju diagnosis, serta membantu radiolog dalam menganalisis citra secara lebih efisien untuk mengatasi keterbatasan sumber daya manusia. Dengan menyediakan visualisasi penjelas terhadap setiap hasil prediksi, model ini diharapkan dapat menjembatani kesenjangan antara akurasi teknis dan kepercayaan klinis, sekaligus memperluas peluang integrasi dalam pengembangan sistem pendukung keputusan medis yang lebih terbuka, transparan, dan bertanggung jawab. Pengembangan model ini diharapkan memiliki peluang sebagai berikut.

1. Pengembangan model AI dengan modul *Explainable AI* berupa visualisasi heatmap untuk mengidentifikasi area mencurigakan pada CT scan, menggantikan pedoman seleksi pasien yang tidak akurat
2. Standardisasi hasil pemindaian melalui model AI yang konsisten antar waktu pemeriksaan, mengurangi kesalahan perseptual radiolog akibat kelelahan/beban kerja berlebihan
3. Sistem pendukung keputusan awal yang mempersingkat waktu dari kunjungan pertama hingga diagnosis, mengurangi keterlambatan yang berdampak klinis pada pasien tumor otak
4. Implementasi *Explainable AI* sebagai fitur interpretabilitas yang menjelaskan dasar prediksi kepada klinisi dan pasien, menjembatani kesenjangan kepercayaan terhadap AI

III.2.2 Kebutuhan Fungsional

Untuk dapat memenuhi kebutuhan peluang tersebut, diperlukan kebutuhan fungsional model sebagai berikut.

1. Model harus dapat menerima *input* data berupa citra digital *CT Scan* otak
2. Model harus mampu mengklasifikasikan citra *input* ke dalam dua kelas keputusan, yaitu tumor atau sehat (tidak ada tumor).
3. Model harus menghasilkan visualisasi interpretasi keputusan model menggunakan metode *Explainable AI* visualisasi untuk menyoroti area fitur pada citra yang membuat model mengklasifikasikan gambar citra tersebut ke dalam kelas tumor.
4. Sistem harus menampilkan tingkat kepercayaan dari hasil prediksi untuk membantu tenaga medis dalam menilai validitas keputusan sistem dan membangun kepercayaan pengguna.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional model adalah sebagai berikut.

1. *Interpretability*

Model harus mampu menyediakan transparansi atas keputusan yang diambil. Berbeda dengan model sebelumnya yang bersifat *black-box*, model yang diusulkan harus memvisualisasikan area fokus, seperti penggunaan *heatmap* yang menjadi dasar model memprediksi. Hal ini bertujuan untuk menjawab keraguan pasien akan validitas diagnosis AI dan membantu profesional medis memverifikasi hasil tanpa harus mempercayai algoritma secara buta.

2. *Reliability*

Model harus memiliki tingkat konsistensi yang tinggi dalam memberikan hasil prediksi. Model diharapkan dapat mempertahankan atau melampaui akurasi model referensi.

3. *Complexity*

Model harus memiliki tingkat *space complexity* yang rendah dan terukur pada tahap inferensi. Hal ini penting agar model dapat diimplementasikan secara optimal pada infrastruktur komputasi yang umum tersedia di fasilitas kesehatan, tanpa mengorbankan kecepatan maupun akurasi proses klasifikasi dan visualisasi.

III.3 Analisis Pemilihan Solusi

Pada bagian ini, dilakukan analisis kebutuhan untuk menentukan solusi yang paling tepat dalam mengatasi permasalahan *black-box* pada model AI. Tahapan analisis ini mencakup identifikasi dan pemaparan berbagai alternatif solusi dan menggunakan metodologi AHP untuk mengevaluasi dan memilih solusi terbaik dari alternatif tersebut.

III.3.1 Alternatif Solusi

Alternatif solusi yang dapat diberikan dalam permasalahan tersebut terbagi menjadi dua, yaitu penggunaan metode XAI pada infrastruktur yang sama dan penggunaan model yang berbeda untuk mencegah terjadinya *black-box* pada AI.

Alternatif solusi pertama fokus pada penerapan metode XAI yang dapat menyelesaikan masalah *black-box*, khususnya dalam konteks *computer vision* (*CT scan*) dan model CNN yang sudah ada. Penjelasan mendalam mengenai metode-metode berikut dapat dilihat pada Bab II.3.1, Subbab Metode *Explainable AI* (XAI).

1. *Attribution-based methods*

Attribution-based methods memberi nilai pada setiap bagian masukan gambar. Bagian yang paling memengaruhi keputusan akhir akan mendapat nilai tinggi. Hal ini dapat membantu penggunaannya untuk melihat area mana pada gambar yang paling penting bagi AI. Alternatif solusi yang menggunakan *attribution-based methods* adalah sebagai berikut.

- (a) *Gradient-weighted Class Activation Mapping* (Grad-CAM)
 - (b) FullGrad-CAM dan FullGrad-CAM++
 - (c) *SmoothGrad*
- #### 2. *Transformer-based methods*
- Transformer-based methods* memanfaatkan mekanisme *attention* bawaan pada arsitektur *Vision Transformer* (ViT). Teknik ini membagi gambar menjadi beberapa *patch* dan memvisualisasikan skor atensinya menjadi peta yang menyoroti area paling krusial dalam pengambilan keputusan model (Iftikhar dkk. 2025a).

Selain mengevaluasi berbagai metode XAI untuk disematkan pada arsitektur *deep learning* yang ada, analisis ini juga memperhitungkan alternatif penggunaan model yang berbeda secara mendasar, seperti model *machine learning* konvensional. Perbandingan komprehensif antara pendekatan *deep learning* berbasis XAI dengan model konvensional (baik yang bersifat *white-box* maupun *black-box*) diperlukan untuk membuktikan efektivitas dan urgensi dari solusi yang diusulkan dalam tugas akhir ini.

Analisis penentuan solusi yang digunakan pada tugas akhir ini menggunakan *Analytic Hierarchy Process* (AHP). AHP adalah metode pengambilan keputusan yang digunakan oleh individu atau organisasi untuk melakukan pemeringkatan alternatif yang mereka pertimbangkan berdasarkan perbandingan berpasangan. *Analytic Hierarchy Process* (AHP) melibatkan lima langkah utama. Pertama, menyusun hierarki masalah keputusan ke dalam tiga tingkatan, yaitu tujuan, kriteria, dan alternatif. Kedua, melakukan perbandingan berpasangan untuk kriteria guna menilai kepentingan

relatifnya menggunakan skala sembilan poin, mulai dari rasio 1 yang berarti sama penting hingga rasio 9 yang berarti sangat penting, serta nilai kebalikannya. Ketiga, menghitung bobot kriteria untuk mewakili kepentingan relatifnya, yang diturunkan dari rasio preferensi pada langkah sebelumnya. Keempat, mengevaluasi alternatif dengan melakukan perbandingan berpasangan serupa untuk setiap pasangan alternatif berdasarkan setiap kriteria. Kelima, menggabungkan bobot kriteria dan skor alternatif melalui perkalian dan penjumlahan untuk menghasilkan skor total bagi setiap alternatif, yang kemudian digunakan untuk memeringkatnya (1000minds 2025).

AHP pada tugas akhir dilakukan berdasarkan literatur yang melakukan evaluasi terhadap model terkait. Terdapat tiga studi literatur yang digunakan untuk menganalisis alternatif solusi, yaitu:

1. *Explainable AI and vision transformers for detection and classification of brain tumor: a comprehensive survey* (Hosny dan Mohammed 2025)

Penelitian ini membahas tentang tinjauan teknis dan perbandingan teknik diagnostik *deep learning* (DL) untuk tumor otak, dengan fokus pada penelitian dari tahun 2020 hingga 2024, seperti CNN, *transfer learning*, *vision transformers* (ViT), teknik hibrida, dan *Explainable AI* (XAI). Tugas akhir ini mengeksplorasi kinerja, keunggulan, dan keterbatasan dari pendekatan-pendekatan tersebut pada *dataset* umum seperti Figshare dan BraTS.

2. *Explainable CNN for brain tumor detection and classification through XAI based key features identification* (Iftikhar dkk. 2025a)

Penelitian ini menggunakan metodologi yang menggabungkan *Explainable AI* (XAI) dengan arsitektur CNN untuk mengatasi masalah model yang kompleks dan sulit diinterpretasi. Tugas akhir ini menggunakan teknik XAI berupa *Gradient-weighted Class Activation Mapping* (Grad-CAM) agar memastikan model fokus pada fitur tumor yang relevan.

3. *Optimizing brain tumor classification through feature selection and hyperparameter tuning in machine learning models* (Tahosin dkk. 2023)

Penelitian ini memberikan data perbandingan algoritma *machine learning*. Hasilnya menunjukkan bahwa *Extra Trees* mencapai akurasi tertinggi (98%) dan *Naive Bayes* memiliki akurasi terendah (69%) namun sangat efisien secara komputasi.

Tahapan AHP yang dilakukan adalah sebagai berikut:

1. Struktur Hierarki Keputusan

- (a) Tujuan

Memilih pendekatan *deep learning* atau *machine learning* yang paling efektif dan sesuai untuk tugas klasifikasi atau deteksi penyakit dari data

medis.

(b) Kriteria

i. C1: Akurasi Deteksi

Kemampuan model untuk secara benar mengidentifikasi atau mengklasifikasikan kondisi medis.

ii. C2: *Interpretability*

Kemampuan model untuk memberikan penjelasan atas prediksinya, yang krusial dalam konteks medis untuk membangun kepercayaan dan memahami fokus model.

iii. C3: *Robustness* dan Generalisasi

Kemampuan model untuk berkinerja baik pada data baru (*unseen data*) atau *dataset* yang berbeda, serta ketahanan terhadap variasi data.

iv. C4: Kebutuhan Data dan Teknik *Preprocessing*

Sensitivitas model terhadap jumlah data yang tersedia dan efektivitas teknik seperti augmentasi data, *transfer learning*, atau *preprocessing* spesifik.

v. C5: Kompleksitas Model

Ukuran arsitektur, seperti jumlah *layer*, parameter yang dapat memengaruhi interpretasi, efisiensi, dan risiko *overfitting*.

(c) Alternatif Solusi

i. A1: CNN + Grad-CAM (Mewakili *attribution-based methods*)

ii. A2: *Vision Transformer* (ViT) + *Attention Map* (Mewakili *Transformer-based methods*)

iii. A3: *Naive Bayes* (Representasi *white-box*)

iv. A4: *Extra Trees* (Representasi *black-box*)

2. Perbandingan Berpasangan Antar Kriteria

Perbandingan berpasangan dilakukan berdasarkan kriteria yang ada untuk menentukan prioritas dari setiap kriteria. Perbandingan antarkriteria dilakukan menggunakan matriks perbandingan berpasangan kriteria. Matriks perbandingan berpasangan kriteria adalah tabel yang merekam hasil perbandingan preferensi antara setiap pasang kriteria, menggunakan skala sembilan poin untuk menunjukkan tingkat kepentingan satu kriteria terhadap yang lain. Hasil dari matriks perbandingan kriteria dapat dilihat pada Tabel III.1.

Tabel III.1 Matriks Perbandingan Berpasangan Kriteria

Kriteria	C1	C2	C3	C4	C5
C1 (Akurasi)	1	1	5	3	5
C2 (XAI)	1	1	5	3	5
C3 (Efisiensi)	1/5	1/5	1	1/3	1
C4 (Data)	1/3	1/3	3	1	3
C5 (Kompleksitas)	1/5	1/5	1	1/3	1

Setelah dilakukan perbandingan, dilakukan normalisasi ke vektor prioritas kriteria. Normalisasi dilakukan dengan cara matriks perbandingan dikuadratkan, kemudian setiap baris dijumlahkan, dan hasil penjumlahan setiap baris dibagi dengan total keseluruhan jumlah baris. Langkah-langkah tersebut diulangi pada matriks hasil hingga nilai vektor prioritas yang dihasilkan menjadi konvergen 1000minds (2025). Hasil dari vektor prioritas kriteria dapat dilihat pada Tabel III.2.

Tabel III.2 Vektor Prioritas Kriteria

Kriteria	Bobot	Prioritas (%)
C1: Akurasi	359	35,9%
C2: <i>Interpretability</i>	359	35,9%
C3: <i>Robustness/Generalisasi</i>	64	6,4%
C4: Kebutuhan Data	153	15,3%
C5: Kompleksitas Model	64	6,4%
Total	1.000	100,0%

3. Perbandingan Berpasangan Antar Alternatif

Perbandingan dilakukan dengan cara setiap alternatif dibandingkan dengan alternatif solusi lain berdasarkan masing-masing kriteria menggunakan matriks perbandingan berpasangan kriteria 1000minds (2025). Setelah itu, dilakukan normalisasi yang sama dengan perhitungan prioritas kriteria. Perbandingan antaralternatif berdasarkan kriteria dan prioritas alternatif solusi dapat dilihat pada Tabel III.3 hingga Tabel III.7.

Tabel III.3 Matriks Perbandingan Berpasangan C1 (Akurasi)

C1: Akurasi	A1	A2	A3	A4
A1	1	2	7	4
A2	1/2	1	5	3
A3	1/7	1/5	1	1/3
A4	1/4	1/3	3	1

Berdasarkan Tabel III.3, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 50,5%
- (b) A2: 30,6%
- (c) A3: 5,8%
- (d) A4: 13,1%

Pendekatan CNN dengan Grad-CAM (A1) memperoleh bobot tertinggi karena arsitektur CNN, terutama yang menggunakan *transfer learning*, secara konsisten mendominasi performa akurasi dalam analisis citra medis dan terbukti lebih stabil pada *dataset* standar. *Vision Transformer* (A2) masih menghadapi tantangan generalisasi jika data latih terbatas, sedangkan *Naive Bayes* (A3) memiliki performa paling rendah dengan akurasi sekitar 69% yang dinilai kurang memadai untuk diagnosis kritis.

Tabel III.4 Matriks Perbandingan Berpasangan C2 (Interpretability)

C2: XAI	A1	A2	A3	A4
A1	1	3	2	7
A2	1/3	1	1/3	3
A3	1/2	3	1	7
A4	1/7	1/3	1/7	1

Berdasarkan Tabel III.4, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 47,4%
- (b) A2: 13,9%
- (c) A3: 33,4%
- (d) A4: 5,3%

Metode CNN yang dilengkapi Grad-CAM (A1) unggul karena mampu menghasilkan visualisasi *heatmap* yang menyoroti area tumor berdasarkan gradien lapisan konvolusi terakhir sehingga memberikan transparansi keputusan yang sangat dibutuhkan. *Naive Bayes* (A3) menempati posisi kedua karena sifatnya sebagai model *white-box* yang mudah dijelaskan secara matematis, berbeda dengan *Extra Trees* (A4) yang merupakan model *ensemble* (*black-box*) yang sulit dilacak alur keputusannya. Sementara itu, peta atensi pada ViT (A2) sering kali menangkap hubungan global yang lebih abstrak dibandingkan fitur fisik tumor sehingga interpretasi visualnya lebih sulit dipahami dibandingkan *heatmap* CNN.

Tabel III.5 Matriks Perbandingan Berpasangan C3 (Efisiensi Komputasi)

C3: Efisiensi	A1	A2	A3	A4
A1	1	3	1/7	1/3
A2	1/3	1	1/9	1/5
A3	7	9	1	3
A4	3	5	1/3	1

Berdasarkan Tabel III.5, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 10,1%
- (b) A2: 4,9%
- (c) A3: 60,7%
- (d) A4: 24,3%

Naive Bayes (A3) mendominasi kriteria ini karena kesederhanaan algoritmanya yang membutuhkan sumber daya komputasi minimal dan waktu pelatihan yang cepat. *Extra Trees* (A4) juga dinilai efisien karena struktur *tree*-nya yang mengurangi redundansi data. Metode berbasis *deep learning* seperti CNN (A1) dan *Vision Transformer* (A2) memiliki beban komputasi yang jauh lebih berat, seperti ViT yang memproses gambar sebagai urutan *patch* dengan mekanisme atensi yang memakan memori besar dan waktu pelatihan yang jauh lebih lama dibandingkan metode konvensional.

Tabel III.6 Matriks Perbandingan Berpasangan C4 (Kebutuhan Data)

C4: Data	A1	A2	A3	A4
A1	1	3	1/5	1/3
A2	1/3	1	1/7	1/5
A3	5	7	1	2
A4	3	5	1/2	1

Berdasarkan Tabel III.6, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 12,2%
- (b) A2: 5,7%
- (c) A3: 52,3%
- (d) A4: 29,8%

Alternatif *Naive Bayes* (A3) dan *Extra Trees* (A4) lebih unggul karena kemampuan mereka untuk bekerja efektif dan tidak mudah *overfitting* pada *dataset*

dengan jumlah sampel yang sedikit. Sebaliknya, CNN (A1) membutuhkan jumlah data yang besar atau strategi augmentasi data untuk mencapai generalisasi yang baik, dan *Vision Transformer* (A2) mendapatkan bobot terendah karena arsitekturnya tidak memiliki bias induktif sehingga memerlukan *data-set* berskala besar agar performanya tidak menurun drastis.

Tabel III.7 Matriks Perbandingan Berpasangan C5 (Kompleksitas)

C5: Kompleksitas	A1	A2	A3	A4
A1	1	2	1/7	1/3
A2	1/2	1	1/8	1/4
A3	1/7	8	1	3
A4	3	4	1/3	1

Berdasarkan Tabel III.7, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 9,4%
- (b) A2: 6,0%
- (c) A3: 60,8%
- (d) A4: 23,8%

Dalam aspek kompleksitas arsitektur, *Naive Bayes* (A3) dinilai paling sederhana karena hanya mengandalkan perhitungan probabilitas statistik dasar, diikuti oleh *Extra Trees* (A4). Sementara itu, CNN (A1) memiliki struktur hierarkis yang dalam dengan jutaan parameter yang harus dilatih, dan *Vision Transformer* (A2) dinilai paling kompleks karena mekanisme *multi-head self-attention* yang memiliki kompleksitas kuadratik terhadap jumlah token (*patch* gambar), menjadikannya model yang paling berat secara struktural dibandingkan alternatif lainnya.

4. Perbandingan Berpasangan Setiap Pasangan Alternatif Berdasarkan Setiap Kriteria

Setelah perbandingan dilakukan pada setiap alternatif berdasarkan kriteria, dilakukan penggabungan perbandingan pada setiap pasangan alternatif berdasarkan setiap kriteria dengan hasil yang dapat dilihat pada Tabel III.8. Perhitungan Rinci Skor Akhir:

- (a) A1 (CNN + Grad-CAM): $(0,359 \times 505) + (0,359 \times 474) + (0,064 \times 101) + (0,153 \times 122) + (0,064 \times 94) = 382,607$
- (b) A2 (ViT + Attention Map): $(0,359 \times 306) + (0,359 \times 139) + (0,064 \times 49) + (0,153 \times 57) + (0,064 \times 60) = 175,452$

Tabel III.8 Hasil Perhitungan Perbandingan Berpasangan

Alternatif	C1	C2	C3	C4	C5	Hasil Akhir
Bobot Kriteria	35,9%	35,9%	6,4%	15,3%	6,4%	
A1	505	474	101	122	94	382,607
A2	306	139	49	57	60	175,452
A3	58	334	607	523	608	298,507
A4	131	53	243	298	238	142,434

$$(c) \text{ A3 (Naive Bayes): } (0,359 \times 58) + (0,359 \times 334) + (0,064 \times 607) + (0,153 \times 523) + (0,064 \times 608) = 298,507$$


$$(d) \text{ A4 (Extra Trees): } (0,359 \times 131) + (0,359 \times 53) + (0,064 \times 243) + (0,153 \times 298) + (0,064 \times 238) = 142,434$$

5. Pemilihan Solusi

Dengan mempertimbangkan bobot prioritas dan skor kinerja keseluruhan, model *deep learning* yang menggunakan Grad-CAM (A1) ditetapkan sebagai solusi pada tugas akhir. Metode ini memberikan keseimbangan terbaik antara akurasi tinggi dan interpretabilitas kuat, sejalan dengan tujuan metodologi yang menekankan pada keandalan model sekaligus transparansi keputusan AI.

BAB IV

PERANCANGAN MODEL PENDETEKSIAN TUMOR OTAK BERBASIS CNN YANG TERINTEGRASI XAI



Gambar IV.1 Perancangan Alur Implementasi

Secara umum, alur implementasi pada penelitian ini terbagi menjadi empat tahap utama. Pertama, *data understanding* yang mencakup pengumpulan data dari tiga sumber, yaitu citra otak tanpa tumor (*No Tumor Scrape*), citra otak dengan tumor (*Tumor Scrape*), dan citra otak dengan *mask* tumor (*Tumor with Mask*), yang kemudian dibagi menjadi subset *train*, *validation*, dan *test*. Kedua, *data preparation* yang meliputi konversi format, standardisasi saluran RGB, pemilihan *preprocessing* eksperimen (Gaussian+CLAHE atau Wavelet+Normalisasi Intensitas atau tanpa kedua *preprocessing* tersebut), seleksi *Region of Interest* (ROI), dan augmentasi data. Ketiga, *modelling* yang menguji tiga arsitektur model, yaitu CLM (CNN + ANN), *Explainable* CNN (CNN + Grad-CAM *Pruning*), dan EfficientNetB0, masing-masing dengan *hyperparameter tuning*. Keempat, evaluasi yang mencakup pemilihan model terbaik per arsitektur, dilanjutkan dengan implementasi XAI menggunakan Grad-CAM yang disertai evaluasi XAI menggunakan metrik XAlign.


IV.1 Data Understanding

Selain modifikasi arsitektur, penyesuaian juga dilakukan pada *dataset* yang digunakan. *Dataset* yang digunakan dalam tugas akhir ini merupakan gabungan dari dua sumber data yang berbeda untuk menciptakan kumpulan data yang dapat digunakan untuk klasifikasi tumor otak serta segmentasi tumor otak.

1. Dataset Otak CT Scan tanpa Mask Tumor

Untuk melatih dan memvalidasi model, Tugas Akhir ini mengumpulkan datast melalui website Radiopaedia. Radiopaedia merupakan repositori kasus pencitraan medis yang mencakup berbagai modalitas, seperti CT-scan dan MRI.

Meskipun terbuka dari komunitas medis, seluruh draf artikel dan kasus klinis yang diunggah dapat dilakukan *peer-review* dan harus melewati proses divalidasi oleh para ahli radiologi profesional yang bekerja sama dengan Radiopaedia. Proses verifikasi ini memastikan bahwa setiap data gambar yang tersedia memiliki diagnosis patologi yang akurat dan anotasi klinis yang dapat dipertanggungjawabkan.



Gambar IV.2 Website Radiopaedia

Dalam pengumpulan data, dilakukan pencarian secara manual dengan beberapa kata kunci yang dibagi menjadi dua, yaitu normal dan kelas penyakit (glioma dan meningioma). Pada pencarian tersebut, terdapat *filter* modalitas pencitraan berupa CT scan) dan dengan bidang *Axial non-contrast*. Setelah dilakukan pencarian, dilakukan pengunduhan secara manual dengan melihat letak tumor dari gambar lain, seperti MRI atau anotasi pada gambar yang lain. Dalam pengunduhan, dilakukan pemisahan folder untuk tempat setiap kelas yang akan dijadikan bahan untuk pelatihan dan tes model.

2. Dataset Otak CT Scan dengan Tumor dan Mask Tumor

Untuk Dataset Otak dengan Tumor dan Mask Tumor, tugas akhir ini menggunakan *dataset Unpaired MR-CT Brain Dataset for Unsupervised Image Translation* (Al-Kadi dkk. 2022). Dataset ini digunakan sebagai *ground truth* untuk kebutuhan validasi XAI. Spesifikasi dari dataset yang digunakan adalah:

- Sumber: Jordan University Hospital (via Mendeley Data).
- Kondisi Medis: Patologis (tumor otak).
- Format Data: Citra 2D (DICOM).
- Resolusi Citra: 256×256 piksel.
- Representasi Piksel: 8-bit (0-255) yang telah diterapkan filter *smooth* dan *sharp*.
- Ketebalan Slice: 7,0 mm.

(g) Jumlah Sampel: 89 citra CT bidang aksial.

IV.2 Data Preparation

Dalam melakukan preprarasi pada semua dataset, terdapat *preprocessing* yang dilakukan agar data menjadi seragam dan *preprocessing* tambahan yang dilakukan untuk eksperimen agar model bisa mendeteksi tumor lebih baik.

IV.2.1 Preprocessing Umum

Pada penelitian ini, tahap *preprocessing* umum diterapkan pada seluruh citra masukan untuk memastikan kompatibilitas format dasar dengan arsitektur model yang akan digunakan.

1. Standardisasi Format dan Saluran: Citra masukan yang didapatkan dari berbagai sumber memiliki format yang bervariasi (misalnya *grayscale* atau RGB). Seluruh citra diseragamkan menjadi format *Red-Green-Blue* (RGB) dengan 3 saluran (*channels*). Penyesuaian ini diwajibkan karena sebagian besar arsitektur CNN menerima dimensi masukan awal dengan 3 saluran warna.
2. Penyesuaian Dimensi dan *Padding*: Seluruh citra diubah dimensinya menjadi ukuran yang seragam (sebagai contoh 224×224 atau 256×256 piksel). Untuk mencegah distorsi rasio aspek anatomis jaringan otak akibat pemampatan (*squishing*), teknik *padding* digunakan. Piksel bernilai nol (hitam) ditambahkan pada sisi citra yang lebih pendek sehingga citra menjadi berbentuk persegi secara proporsional sebelum dilakukan penyesuaian ukuran. Hasil akhir disimpan sebagai file PNG dalam format *unsigned integer* 8-bit (uint8) dengan rentang nilai piksel $[0, 255]$.
3. Normalisasi Intensitas: Normalisasi intensitas **tidak** dilakukan pada tahap penyimpanan *file* ini. Citra disimpan dalam format uint8 RGB $[0, 255]$ murni guna menjaga informasi kecerahan absolut antar citra. Sebagai gantinya, statistik normalisasi global berupa nilai *mean* dan *standard deviation* (σ) per kanal dihitung secara *streaming* dari seluruh *train set* dan disimpan ke dalam berkas `norm_stats.json`. Statistik ini dihitung **hanya** dari *train set* untuk mencegah *data leakage* dari data validasi maupun pengujian. Normalisasi kemudian diterapkan oleh *dataloader* pada *notebook* berikutnya menggunakan metode standardisasi (*Z-score normalization*) dengan persamaan matematis berikut:

$$X_{norm} = \frac{X/255,0 - \mu}{\sigma} \quad (IV.1)$$

di mana μ adalah *mean* dan σ adalah *standard deviation* per kanal dari *train set*. Proses ini memastikan normalisasi yang konsisten antara fase pelatihan

(*training*) dan inferensi (*inference*), sekaligus menstabilkan pembaruan bobot (*weight updates*) saat proses pelatihan model CNN.

4. Seleksi *Region of Interest* (ROI): Citra MRI umumnya mengandung latar belakang gelap yang tidak berkontribusi pada proses klasifikasi. Mengacu pada metodologi Islam et al. (**islam2024deepfusion**), seleksi ROI dilakukan melalui dua tahap. Pertama, citra dikonversi ke *grayscale* menggunakan persamaan:

$$I_g = 0,299 \cdot I_R + 0,587 \cdot I_G + 0,114 \cdot I_B \quad (IV.2)$$

Kedua, *thresholding* Otsu diterapkan pada citra *grayscale* untuk memisahkan *foreground* dari *background* secara otomatis dengan meminimalkan varian intra-kelas. *Bounding box* terkecil yang mencakup seluruh kontur *foreground* yang valid kemudian dihitung, dan area tersebut di-*crop* dari citra RGB asli sebagai ROI. Pada kasus di mana tidak ditemukan kontur yang valid (ukuran crop $< 32 \times 32$ piksel), citra penuh digunakan sebagai *fallback*.

IV.2.2 Preprocessing Eksperimen

Preprocessing tambahan dilakukan sesuai dengan beberapa artikel yang tersedia, yaitu sebagai berikut.

1. clahe + Gaussian *denoise* (Putra dkk. (2025))

Pemfilteran Gaussian (Gaussian *filtering*) diterapkan pada tahap *denoising* dengan tujuan utama untuk menekan derau frekuensi tinggi (*high-frequency noise*) pada citra MRI. Penerapan filter ini secara langsung dapat meningkatkan rasio sinyal terhadap derau (*signal-to-noise ratio*) pada tekstur gambar. Melalui pengurangan derau ini, representasi visual dari margin (tepi) tumor menjadi lebih jelas dan tingkat kecerahan di seluruh irisan gambar menjadi lebih seragam, sehingga model *Convolutional Neural Network* (CNN) mampu mengekstraksi fitur-fitur tekstur dengan jauh lebih efektif.

Contrast Limited Adaptive Histogram Equalization (CLAHE) diterapkan pada tahap prapemrosesan (*preprocessing*) untuk meningkatkan kontras lokal pada citra. Teknik algoritma ini berfungsi untuk menonjolkan batas-batas tumor secara efektif tanpa ikut mengamplifikasi derau (*noise*) di sekitarnya. Dengan mengoptimalkan kontras secara lokal, penggunaan CLAHE yang digabungkan dengan normalisasi dan reduksi derau memungkinkan jaringan model *deep learning* untuk menangkap fitur-fitur tekstur tumor yang sangat halus (*fine-grained*) dengan lebih akurat.

2. clahe + Wavelet *denoise* (Flower dan Leo (2025)) Filter Wavelet merupakan sebuah teknik untuk reduksi derau yang bekerja dengan cara mendekomposisi

gambar ke dalam berbagai pita frekuensi menggunakan transformasi wavelet. Mekanisme ini memungkinkan dilakukannya analisis lokal pada komponen waktu maupun frekuensi secara bersamaan, sehingga sangat berguna untuk menangkap fitur transien dan mengurangi derau. Metode ini sangat disukai dalam pemrosesan citra karena kemampuannya yang unggul dalam mempertahankan tepi (*edges*) dan struktur penting pada anatomi sekaligus secara efektif menghilangkan derau yang tidak diinginkan.

CLAHE adalah versi tingkat lanjut dari teknik ekualisasi histogram yang berfungsi untuk meningkatkan kualitas visual dan interpretasi citra. Metode ini beroperasi secara lokal dengan cara membagi citra menjadi wilayah-wilayah yang lebih kecil, yang disebut sebagai *tiles*, lalu menerapkan ekualisasi histogram secara spesifik di dalam setiap *tile* tersebut. Mekanisme pembagian wilayah ini membantu mencegah terjadinya amplifikasi derau yang berlebihan (*over-amplification of noise*) dan mampu meningkatkan detail lokal tanpa memunculkan artefak visual. Teknik ini dinilai sangat bermanfaat ketika memproses pemindaian MRI yang memiliki wilayah heterogen, contohnya pada area yang memiliki struktur gelap dan terang secara bersamaan.

IV.2.3 Augmentasi

Berdasarkan (Goceri 2023), menggabungkan beberapa proses augmentasi secara berurutan terbukti memberikan performa klasifikasi yang lebih tinggi dibandingkan dengan augmentasi tunggal. Pada penelitian ini, diterapkan lima metode augmentasi geometris yang dijalankan hanya pada data *training*, dengan setiap gambar asli menghasilkan 10 salinan (2 salinan per metode), sehingga total dataset *training* menjadi 11 kali lipat data asli. Seluruh piksel yang keluar *frame* akibat transformasi diisi menggunakan refleksi tepi (BORDER_REFLECT_101) agar tidak terdapat artefak hitam yang dapat mengganggu fitur medis.

1. *Shearing* Tunggal

Pada metode ini, citra mengalami distorsi sudut pada sumbu x dan y secara independen dengan sudut yang dipilih secara acak dari rentang -15° hingga 15° . Pusat transformasi ditetapkan di tengah citra agar lesi tidak bergeser jauh dari posisi aslinya. Metode ini merupakan augmentasi tunggal yang paling tidak efisien apabila diaplikasikan secara tersendiri tanpa dikombinasikan dengan transformasi lain (Goceri 2023).

2. Rotasi Tunggal

Citra dirotasi searah atau berlawanan arah jarum jam dengan sudut acak dari rentang -25° hingga 25° , berpusat di tengah citra. Rotasi umumnya aman diterapkan pada citra medis karena lesi dapat muncul pada berbagai orientasi,

sehingga model jaringan dapat belajar mengenali fitur yang tidak bergantung pada orientasi tertentu.

3. Rotasi → Translasi

Metode ini menerapkan dua transformasi secara berurutan:

- Rotasi: Citra dirotasi terlebih dahulu dengan sudut acak dari rentang -25° hingga 25° untuk mensimulasikan variasi sudut akuisisi pencitraan.
- Translasi (Pergeseran): Hasil rotasi kemudian digeser pada sumbu x dan y dengan nilai acak dari rentang -15 hingga 15 piksel untuk mensimulasikan variasi posisi pasien saat pencitraan.

4. Translasi → *Shearing*

Berdasarkan (Goceri 2023), kombinasi translasi dan *shearing* merupakan pendekatan yang terbukti memberikan performa tertinggi dalam klasifikasi citra *CT scan* paru. Kombinasi ini bekerja dengan menerapkan dua transformasi geometris secara berurutan:

- Translasi (Pergeseran): Citra digeser pada sumbu x dan y menggunakan nilai yang diambil secara acak dari rentang -15 hingga 15 piksel. Langkah ini berguna untuk mencegah *bias* posisional, sehingga model tidak terpaku pada properti di satu lokasi spasial tunggal.
- *Shearing* (Distorsi Sudut): Setelah ditranslasi, citra kemudian diberikan efek distorsi pada sumbu x dan y dengan sudut yang dipilih secara acak antara -15° hingga 15° untuk mensimulasikan variasi proyeksional.

Berdasarkan pengujian kuantitatif dalam artikel tersebut, metode ini berhasil menghasilkan tingkat akurasi sebesar 85.74%, sensitivitas 86.16%, dan spesifisitas 97.65% pada klasifikasi citra *CT scan* paru.

5. Translasi → *Shearing* → Rotasi

Metode ini merupakan kombinasi tiga transformasi geometris yang diterapkan secara berurutan, menjadikannya metode augmentasi paling komprehensif dalam penelitian ini:

- Translasi: Citra digeser secara acak dalam rentang -15 hingga 15 piksel pada kedua sumbu untuk mensimulasikan variasi posisi.
- *Shearing*: Citra yang telah digeser kemudian didistorsi dengan sudut acak antara -15° hingga 15° untuk mensimulasikan variasi proyeksional.
- Rotasi: Terakhir, citra dirotasi dengan sudut acak dari rentang -25° hingga 25° untuk mensimulasikan variasi orientasi akuisisi pemindaian.


Kombinasi ketiga transformasi ini terbukti menjadi pendekatan paling tepat untuk augmentasi citra *MR* otak dalam meningkatkan klasifikasi kasus HGG

dan LGG, dengan akurasi sebesar 88.24%, sensitivitas 90.48%, dan spesifisitas 97.13% (Goceri 2023).

IV.3 Modelling

IV.3.1 Explainable CNN

Penelitian yang dilakukan oleh Woźniak, Siłka, dan Wieczorek (2021) mengusulkan sebuah *Correlation Learning Mechanism* (CLM) yang mengombinasikan *Convolutional Neural Network* (CNN) dengan *Artificial Neural Network* (ANN).



Gambar IV.3 Visualisasi mekanisme *Correlation Learning Mechanism* (CLM) (Woźniak, Siłka, dan Wieczorek 2021)

Pada penelitian ini, arsitektur model dirancang melalui beberapa tahapan utama yang mencakup ekstraksi fitur menggunakan lapisan konvolusi, normalisasi, klasifikasi, hingga tahap optimasi komponen jaringan menggunakan metode pemangkas berbasis *Explainable AI* (XAI).

1. Lapisan Masukan (*Input Layer*): Model ini menerima masukan berupa citra medis *Magnetic Resonance Imaging* (MRI) otak dalam format warna *Red-Green-Blue* (RGB) yang dimensinya telah diseragamkan terlebih dahulu menjadi ukuran $224 \times 224 \times 3$ piksel. Penyeragaman dimensi ini ditujukan untuk memastikan keselarasan seluruh data masukan sebelum memasuki tahapan ekstraksi fitur.
2. Lapisan Konvolusi dan *Max Pooling*: Tahap ekstraksi fitur menggunakan serangkaian lapisan konvolusi dengan jumlah filter yang meningkat secara bertahap, yaitu 8, 16, 32, 64, 128, dan 256 filter. Seluruh lapisan konvolusi ini menerapkan ukuran kernel 3×3 , *padding* 'same' untuk menjaga dimensi spasial, dan fungsi aktivasi *Rectified Linear Unit* (ReLU) untuk menangkap pola gambar yang kompleks. Setelah setiap lapisan konvolusi, terdapat lapisan *Max Pooling* yang berfungsi untuk memperkecil ukuran peta fitur (*down-sampling*) sebesar faktor 2 guna mengurangi beban komputasi model.
3. Lapisan Normalisasi dan *Average Pooling*: Setelah melewati keseluruhan rangkaian konvolusi dan *max pooling*, arsitektur menambahkan lapisan *Average Pooling* untuk mengurangi dimensi fitur menjadi satu nilai per kelas, yang kemudian digunakan untuk klasifikasi akhir.

tch Normalization yang berfungsi untuk menormalkan hasil aktivasi dari fitur yang diekstrak. Kemudian, peta fitur tersebut diturunkan kembali dimensinya dengan dilewatkan pada lapisan *Average Pooling*.

4. Lapisan *Fully Connected* (Klasifikasi): Peta fitur yang masih berupa multi-dimensi diratakan menjadi vektor satu dimensi (1D) oleh lapisan *Flatten*. Vektor ini kemudian diteruskan ke dalam dua lapisan *Dense* secara berurutan, di mana masing-masing lapisan memiliki 512 neuron dan menggunakan fungsi aktivasi *ReLU*. Pada tahap paling akhir, sebuah lapisan *Dense* dengan fungsi aktivasi *Softmax* digunakan untuk mengeluarkan distribusi probabilitas yang mengklasifikasikan citra ke dalam empat kelas: *Meningioma*, *Glioma*, *Pituitary*, dan *NoTumor*.
5. Pemangkas Arsitektur Berbasis XAI: Sebagai langkah optimasi utama, model yang telah dilatih kemudian dianalisis menggunakan metode *Explainable AI* (XAI) berbasis *Gradient-weighted Class Activation Mapping* (Grad-CAM) untuk mengevaluasi tingkat kepentingan setiap lapisannya. Lapisan-lapisan yang memiliki nilai rata-rata kepentingan di bawah ambang batas (*threshold*) dan dianggap kurang berkontribusi akan dihapus dari arsitektur secara sistematis. Setelah lapisan yang tidak penting dihilangkan, model dilatih kembali (*retraining*) untuk menghasilkan arsitektur akhir yang tidak terlalu kompleks, lebih efisien, dan sangat terfokus pada fitur tumor yang relevan.

IV.3.2 Explainable CNN

IV.3.3 EfficientNetB0

IV.3.4 hyperparameter tuning

Pemilihan hyperparameter tidak memiliki standar universal yang menjamin hasil optimal untuk setiap tugas klasifikasi. Berdasarkan penelitian Wojciuk dkk. (2024), meskipun learning rate dan ukuran gambar input secara umum memberikan dampak terbesar pada performa model, tingkat signifikansi dari hyperparameter sangat bervariasi bergantung pada karakteristik dataset yang digunakan. hyperparameter tuning yang dilakukan adalah sebagai berikut.

1. *Learning Rate* (0.0001, 0.001, 0.01): Pada penelitian Wojciuk dkk. (2024), *learning rate* yang diuji memiliki nilai antara 0.0001 hingga 0.03. Artikel tersebut mencatat bahwa *learning rate* dengan nilai yang lebih rendah umumnya berkorelasi dengan performa model yang lebih tinggi.
2. *Batch Size* (16, 32, 64): Berdasarkan penelitian Wojciuk dkk. (2024), *batch size* yang dicoba memiliki nilai 16, 32, dan 64. Walaupun artikel menemukan bahwa *batch size* memiliki dampak yang sangat minim pada akurasi, artikel

tersebut juga menjelaskan bahwa signifikansi parameter terhadap model bergantung kepada dataset yang digunakan sehingga dapat dilakukan eksperimen terhadap parameter-parameter lain.

3. *Dropout Rate* (0.1, 0.2, 0.3): Di sinilah terdapat perbedaan yang patut dicatat. Artikel Wojciuk dkk. menguji rentang 0.01 hingga 0.4 dan menemukan bahwa performa terbaik biasanya berada di rentang 0.1 hingga 0.3. Namun, nilai yang Anda pilih (terutama 0.5) sebenarnya merupakan standar yang sangat umum digunakan untuk arsitektur klasifikasi citra medis. Untuk tugas dengan kompleksitas fitur yang tinggi seperti deteksi tumor otak pada CT-Scan, *dropout* yang lebih besar sering kali diperlukan agar model tidak *overfitting* terhadap pola spesifik dari data latih.

IV.3.5 Explainable AI

Pada tugas akhir ini, terdapat modifikasi arsitektur terutama dalam *palettes generator*. *Palettes generator* yang terdapat pada sistem saat ini diganti menggunakan XAI yang akan memberikan penjelasan yang lebih baik. Terdapat penambahan arsitektur yang akan dilakukan, yaitu (Cea dkk. 2017):

1. Pengambilan *feature maps* (A_k) dan *output* skor (y_c).
2. Penghitungan Gradien
Bagian ini menghitung gradien dari *output* skor terhadap *feature maps*. Tujuan dihitungnya gradien adalah untuk menentukan seberapa penting setiap piksel di *feature map* untuk menghasilkan skor kelas tersebut.
3. *Global Average Pool Gradient Maps*
Gradien tersebut kemudian dirata-ratakan secara global untuk membuat bobot kepentingan, yaitu bobot yang menandakan seberapa penting fitur tersebut mengenali kelas yang dipilih.
4. *Weighted Combination*
Bobot kepentingan kemudian dikalikan dengan *feature maps* yang dihasilkan CNN untuk memperkuat atau melemahkan *feature maps* berdasarkan seberapa penting *feature maps* tersebut. Setelah itu, dilakukan penjumlahan semua *feature maps* yang sudah dibobot tersebut agar menjadi satu peta tunggal.
5. ReLU
Setelah memiliki satu peta tunggal, aktivasi ReLU diterapkan untuk mempertahankan bagian-bagian yang berpengaruh positif terhadap kelas target. Ini membuat peta Grad-CAM hanya fokus pada fitur yang mendukung kelas tersebut.
6. Grad-CAM *Heatmap*
Peta tunggal tersebut akan diubah ukurannya ke ukuran spasial yang sama

dengan *input* sehingga dapat dilapisi di atas *input*. Peta Grad-CAM akan melapisi gambar asli menggunakan *heatmap*. Hasil peta Grad-CAM akan menyoroti area di dalam gambar yang signifikan untuk prediksi CNN terhadap kelas yang dipilih dan memberikan wawasan tentang apa yang dilihat oleh jaringan sebagai hal penting untuk pengambilan keputusannya.

IV.4 Rancangan Evaluasi

IV.4.1 Evaluasi Model

Untuk menilai kinerja klasifikasi model, penelitian ini menggunakan evaluasi yang sama dengan evaluasi model yang dilakukan oleh penelitian x dan penelitian y, yaitu:

1. Akurasi (*Accuracy*): Mengukur rasio prediksi benar secara keseluruhan dengan membandingkan prediksi positif dan negatif yang benar (*True Positives* dan *True Negatives*) terhadap total seluruh data.
2. Presisi (*Precision*): Mengukur ketepatan prediksi positif yang dihasilkan oleh model.
3. *Recall*: Mengukur kemampuan model dalam menemukan semua sampel positif yang sebenarnya.
4. Spesifisitas (*Specificity*): Mengukur kemampuan model dalam mengidentifikasi hasil negatif dengan benar (tercantum dalam hasil evaluasi di Tabel 5 dan visualisasi metrik).
5. *F1-Score*: Mengukur keseimbangan model menggunakan rata-rata harmonik dari Presisi dan *Recall*.

IV.4.2 Evaluasi XAI

Evaluasi terhadap *Explainable Artificial Intelligence* (XAI) bertujuan untuk memastikan bahwa model tidak hanya akurat, tetapi juga transparan, dapat diinterpretasikan, dan dapat dipercaya untuk adopsi di dunia nyata. Evaluasi kualitas dari penjelasan XAI ini akan dilakukan sebagai berikut:

1. *Ground Truth Comparison*

Penelitian ini menerapkan metrik XAlign yang diusulkan oleh Muhammad dan Bendeche (2025) dengan penjelasan yang dapat dilihat pada Bab II. Skor XAlign akan dihitung untuk setiap hasil prediksi Grad-CAM menggunakan persamaan:

$$XAlign = \alpha \cdot WRO + \beta \cdot BAS - \gamma \cdot DP \quad (IV.3)$$

Nilai bobot akan diatur mengikuti konfigurasi standar berdasarkan penelitian tersebut, yaitu $\alpha = 0,5$, $\beta = 0,4$, dan $\gamma = 0,1$. Skor XAlign yang men-

dekati 1,0 akan mengindikasikan bahwa Grad-CAM berhasil menghasilkan penjelasan yang sangat selaras dengan diagnosis klinis.

Sebagai kriteria keberhasilan, penelitian ini mengacu pada performa Grad-CAM yang dilaporkan dalam studi literatur pada *dataset* neuro-onkologi (TCGA-LGG). Metode yang digunakan mencatat skor rata-rata XAlign sebesar 64,1% (Muhammad dan Bendeche 2025). Oleh karena itu, tugas akhir ini menargetkan capaian skor XAlign $\geq 0,641$ sebagai batas minimal validitas penjelasan yang dihasilkan model.

2. *Visual Validation* (Evaluasi Kualitatif)

Sebagai pelengkap data kuantitatif XAlign, perbandingan visual *side-by-side* tetap akan dilakukan antara citra asli, *ground truth mask*, dan *heatmap* Grad-CAM untuk analisis kasus per kasus, khususnya pada prediksi *false positive*.

BAB V

IMPLEMENTASI

V.1 Lingkungan Implementasi

Bagian ini menjelaskan spesifikasi perangkat keras dan perangkat lunak yang digunakan dalam tahap implementasi penelitian. Implementasi dilakukan pada platform *cloud-based notebook*, yaitu Kaggle Notebook dan Google Colaboratory (Google Colab), sehingga spesifikasi perangkat keras yang digunakan bersifat dinamis dan disediakan secara otomatis oleh masing-masing penyedia layanan.

V.1.1 Lingkungan Perangkat Keras

Spesifikasi sumber daya komputasi yang digunakan pada masing-masing platform selama penelitian ini berlangsung adalah sebagai berikut:

1. Kaggle Notebook
 - (a) Prosesor: 4 *vCPU*
 - (b) Memori (RAM): hingga 29 GB
 - (c) GPU: NVIDIA Tesla T4 x2 (2 x 16 GB VRAM)
2. Google Colaboratory
 - (a) Prosesor: 2 *vCPU*
 - (b) Memori (RAM): 12–13 GB
 - (c) GPU: NVIDIA Tesla T4 (16 GB VRAM), digunakan jika tersedia. Saat tidak tersedia, *runtime* dijalankan menggunakan CPU.

V.1.2 Lingkungan Perangkat Lunak

Perangkat lunak yang digunakan untuk mendukung proses pengembangan adalah:

1. Sistem Operasi: Linux (*runtime environment* berbasis Ubuntu yang disediakan oleh Kaggle Notebook dan Google Colab)
2. Bahasa Pemrograman: Python 3.10+
3. *Platform Notebook*: Kaggle Notebook dan Google Colaboratory (Google Colab)
4. *Library* Utama:
5. *Driver*: CUDA Toolkit dan cuDNN (terpasang otomatis pada *runtime* GPU)

Kaggle/Colab)

V.2 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini merupakan dataset citra *CT scan* (*Computed Tomography*) tumor otak yang dikumpulkan dari dua sumber berbeda, menghasilkan total 557 gambar yang terbagi ke dalam tiga kelas, yaitu *no tumor* (otak normal), glioma, dan meningioma. Karakteristik pengumpulan dan pembagian data ini dijabarkan sebagai berikut:

1. Sumber Pertama: Platform Radiopaedia (radiopaedia.org)

Sebuah platform referensi radiologi kolaboratif berbasis komunitas yang memuat ribuan kasus pencitraan medis klinis yang dikontribusikan oleh para radiologis di seluruh dunia. Pengumpulan data dari sumber ini dilakukan melalui teknik *web scraping*, yakni pengambilan gambar secara otomatis dari halaman-halaman kasus *CT scan* otak yang relevan. Citra yang dikumpulkan mencakup tiga kategori: gambar *CT scan* dengan diagnosis glioma, gambar *CT scan* dengan diagnosis meningioma, dan gambar *CT scan* otak normal (*no tumor*). Gambar-gambar dari Radiopaedia memiliki karakteristik klinis yang bervariasi karena berasal dari berbagai institusi dan perangkat pencitraan yang berbeda-beda, sehingga mencerminkan keragaman kondisi akuisisi citra yang realistis.

2. Sumber Kedua: Dataset Publik Mendeley Data

Sumber kedua berasal dari dataset publik yang tersedia di platform Mendeley Data (**NamaPenulisTahun**). Dataset ini menyediakan 80 gambar citra *CT scan* tumor otak beserta *mask* segmentasi tumornya, yaitu citra biner yang menandai secara piksel wilayah tumor pada setiap gambar. Keberadaan *mask* pada dataset ini memperkaya representasi visual kelas tumor dalam dataset keseluruhan, sekaligus memberikan informasi spasial lokasi tumor yang dapat dimanfaatkan untuk keperluan evaluasi XAI yang digunakan.

Gambar-gambar dari kedua sumber tersimpan dalam tiga format file berbeda, yaitu PNG (239 gambar, 42,9%), JPG (221 gambar, 39,7%), dan JPEG (97 gambar, 17,4%), dengan resolusi yang bervariasi mulai dari 205×255 hingga 1.365×1.365 piksel. Setelah dilakukan penggabungan dari kedua sumber, dataset dibagi ke dalam tiga subset, yaitu data latih (*train*) sebanyak 386 gambar (69,3%), data uji (*test*) sebanyak 99 gambar (17,8%), dan data validasi (*val*) sebanyak 72 gambar (12,9%). Pembagian dataset ke dalam tiga subset tersebut dilakukan secara stratifikasi berdasarkan kelas, sehingga proporsi setiap kelas (*no tumor*, glioma, dan meningioma) terjaga secara merata di seluruh subset *train*, *val*, dan *test*.

Mengingat gambar-gambar dari sumber kedua (Mendeley Data) memiliki karakteristik yang berbeda dibandingkan sumber pertama, penelitian ini merancang tiga skenario eksperimen *splitting* data Mendeley Data untuk mengevaluasi dampaknya terhadap generalisasi model. Ketiga skenario tersebut adalah sebagai berikut:

1. uji

Data sumber kedua pada subset *test* saja: Seluruh gambar dari sumber kedua ditempatkan pada subset *test*. Skenario ini bertujuan untuk mengukur kemampuan generalisasi model yang dilatih sepenuhnya pada data sumber pertama ketika diuji pada distribusi data yang berbeda.

Tabel V.1 Pembagian Data Skenario 1

Kategori	Tumor	Tanpa Tumor	Total	Persentase (%)
Train (Latih)	173	73	246	44.17
Validation (Validasi)	75	49	124	22.26
Test (Uji)	145	42	187	33.57
Total	393	164	557	100

2. validasi dan uji

Data sumber kedua pada subset *val* dan *test*: Gambar dari sumber kedua didistribusikan ke dalam subset *val* dan *test*, sementara subset *train* tetap hanya berisi data dari sumber pertama. Skenario ini memungkinkan proses validasi dan pengujian dilakukan pada distribusi yang lebih beragam, sekaligus menjaga proses pelatihan tetap bersih dari data sumber kedua.

Tabel V.2 Pembagian Data Skenario 2

Kategori	Tumor	Tanpa Tumor	Total	Persentase (%)
Train (Latih)	173	73	246	44.17
Validation (Validasi)	114	49	163	29.26
Test (Uji)	106	42	148	26.57
Total	393	164	557	100

3. validasi, uji, dan latih

Data sumber kedua pada seluruh subset (*train*, *val*, dan *test*): Gambar dari sumber kedua didistribusikan secara proporsional ke seluruh subset *train*, *val*, dan *test*. Skenario ini mencerminkan kondisi pelatihan yang memanfaatkan keseluruhan data yang tersedia dari kedua sumber secara terpadu.

Ketiga skenario ini dirancang untuk mengkaji sejauh mana asal-usul dan penempatan data sumber kedua memengaruhi kinerja model klasifikasi, khususnya dalam konteks perbedaan distribusi (*domain shift*) antara kedua sumber data. Kondisi dataset mentah yang heterogen ini menjadi dasar dilakukannya proses *preprocessing*.

Tabel V.3 Pembagian Data Skenario

Kategori	Tumor	Tanpa Tumor	Total	Persentase (%)
Train	224	73	297	53.32
Validation	90	49	139	24.96
Test	79	42	121	21.72
Total	393	164	557	100

V.3 Pemrosesan Data

V.3.1 Pemrosesan Umum

Proses *preprocessing* dilakukan untuk menyeragamkan seluruh gambar agar memenuhi standar *input* model jaringan saraf tiruan yang digunakan. Terdapat tiga tahap *preprocessing* yang diterapkan pada keseluruhan 557 gambar dataset:

1. Konversi Format ke PNG

Seluruh gambar dikonversi ke format PNG untuk memastikan konsistensi format file. Sebelum *preprocessing*, terdapat 318 gambar (57,1%) yang bukan berekstensi PNG. Setelah *preprocessing*, keseluruhan 557 gambar tersimpan dalam format PNG.

Hasil akhir proses *preprocessing* menunjukkan perbaikan yang menyeluruh pada seluruh aspek yang disasar. Ukuran rata-rata file juga berkurang secara signifikan dari 96,52 KB menjadi 30,86 KB per gambar, dengan total ukuran dataset menyusut dari 52,5 MB menjadi 16,79 MB — penghematan sekitar 68% ruang penyimpanan.

Distribusi rata-rata intensitas piksel antarsplit pun relatif konsisten, dengan nilai *test* sebesar 53,47, *train* sebesar 58,56, dan *val* sebesar 64,16 (skala 0–255), yang mengindikasikan tidak adanya bias kecerahan yang signifikan antar subset data. Ringkasan perbandingan kondisi dataset sebelum dan sesudah *preprocessing* disajikan pada Tabel V.4.

Tabel V.4 Perbandingan Kondisi Dataset Sebelum dan Sesudah *Preprocessing*

Aspek	Sebelum	Setelah
Mode warna	RGB, L, RGBA, P (4 varian)	RGB
Resolusi	15 varian berbeda	224 × 224
Format file	PNG, JPG, JPEG	PNG
Ukuran file rata-rata	96,52 KB	30,86 KB
Total ukuran dataset	52,5 MB	16,79 MB

V.3.2 Pemrosesan Eksperimen

V.3.2.1 Gaussian Denoise dan CLAHE

Berdasarkan hasil analisis statistik, terdapat perbedaan yang terukur antara dataset sebelum dan sesudah diterapkan *preprocessing* Gaussian dan CLAHE, sebagaimana ditunjukkan pada Tabel V.5.

Tabel V.5 Perbandingan Parameter Dataset Sebelum dan Sesudah *Preprocessing*

Parameter	Sebelum	Sesudah	Perubahan
Intensitas minimum	0,0	3,78–3,93	Noise impulsif tereliminasi
Rata-rata intensitas (<i>train</i>)	58,56	64,41	+5,85
Rata-rata intensitas (<i>val</i>)	64,16	69,79	+5,63
Rata-rata intensitas (<i>test</i>)	53,47	59,68	+6,21
Standar deviasi (<i>train</i>)	78,45	77,81	Sedikit turun
Ukuran file rata-rata	30,86 KB	52,32 KB	+69,6%

Pergeseran nilai intensitas minimum dari 0,0 menjadi 3,78-3,93 menunjukkan bahwa Gaussian berhasil menghilangkan piksel terisolasi bernilai nol yang merepresentasikan *noise* impulsif pada citra *CT scan*. Kenaikan rata-rata intensitas sebesar 5,6–6,2 poin secara konsisten di seluruh subset menunjukkan bahwa CLAHE berhasil meningkatkan kontras lokal citra. Selain itu, standar deviasi yang tidak meningkat melainkan sedikit menurun mengindikasikan bahwa peningkatan kontras berlangsung terkontrol tanpa *over-amplification noise*. Hal ini sejalan dengan pernyataan Irwandi Rizki Putra *et al.* (Putra2025) bahwa *Gaussian filtering* berfungsi untuk meredam *noise* frekuensi tinggi, sedangkan CLAHE bertujuan meningkatkan kontras lokal tanpa memperkuat *noise* pada citra medis.

V.3.2.2 Wavelet Denoise dan Intensity Normalization

V.4 Implementasi Arsitektur Model Utama (CLM)

V.4.1 Convolutional Neural Network (CNN)

V.4.2 Artificial Neural Network (ANN)

V.4.3 Integrasi Model

V.5 Explainable AI (Grad-CAM)

V.5.1 Ekstraksi Feature Maps dan Gradien

V.5.2 Global Average Pooling dan Weighted Combination

V.5.3 Pembangkitan Heatmap (Aktivasi ReLU)

BAB VI

EVALUASI

asdfasdf

VI.1 Metode Evaluasi

asdfasdf

VI.2 Hasil Evaluasi

asdfasdf

VI.3 Pembahasan Hasil Evaluasi

VI.4 Evaluasi Kesalahan Penulisan yang Sering Terjadi

VI.4.1 Penggunaan Kata "di mana" atau "dimana"

Banyak yang menuliskan kata "di mana" atau "dimana" sebagai pengganti kata "which" dalam bahasa Inggris. Padahal, penggunaan kata "di mana" atau "dimana" tidak tepat dalam konteks tersebut. Demikian juga untuk kata serupa, misalnya "yang mana". Kata "di mana" atau "dimana" ini harus diganti dengan kata lain, seperti "dengan", "tempat", "yang", dan sebagainya tergantung kalimatnya. Penjelasan lengkap dapat dilihat pada (BPBI).

VI.4.2 Penggunaan Kata "sedangkan" dan "sehingga"

Kata "sedangkan" dan "sehingga" adalah kata hubung atau konjungsi. Konjungsi adalah kata atau ungkapan yang menghubungkan satuan bahasa (kata, frasa, klausa, dan kalimat). Konjungsi dapat dibagi menjadi konjungsi intrakalimat dan antarkalimat. Kata "sedangkan" menghubungkan dua klausa yang bersifat kontrasif, sedangkan "sehingga" menghubungkan dua klausa yang bersifat kausal. Dalam ragam formal, kata hubung "sedangkan" dan "sehingga" hanya dapat digunakan sebagai konjungsi intrakalimat sehingga kedua konjungsi itu **tidak dapat diletakkan pada awal kalimat**. Selain itu, penggunaan kata "sedangkan" harus didahului oleh koma (,), sedangkan kata "sehingga" tidak perlu didahului oleh koma (,). Contoh penggunaan yang benar dan salah dapat dilihat pada Tabel VI.1.

Tabel VI.1 Contoh penggunaan kata "sedangkan" dan "sehingga"

Kata	Salah	Benar
sedangkan	Sedangkan sistem lama masih digunakan oleh banyak pengguna.	Sistem lama masih digunakan oleh banyak pengguna, sedangkan sistem baru belum siap.
sehingga	Sehingga sistem lama masih digunakan oleh banyak pengguna.	Sistem lama masih digunakan oleh banyak pengguna sehingga sistem baru belum siap.

VI.4.3 Penggunaan Istilah yang Tidak Baku

Ada beberapa istilah yang sering digunakan dalam pembicaraan sehari-hari, tetapi tidak baku dalam penulisan ilmiah. Beberapa istilah tersebut antara lain:

1. analisa → analisis
2. eksisting atau existing → yang ada atau saat ini
3. bisnis proses → proses bisnis
4. user → pengguna
5. system → sistem
6. database → basis data
7. aktifitas → aktivitas
8. efektifitas → efektivitas
9. sosial media → media sosial

VI.4.4 Pemisah Desimal dan Ribuan

Tanda pemisah desimal dalam bahasa Indonesia adalah tanda koma, contoh:

1. (Salah) Akurasi naik menjadi 50.6%
2. (Benar) Akurasi naik menjadi 50,6%

VI.4.5 Daftar atau *List*

Ada beberapa aturan penulisan daftar atau *list* yang perlu diperhatikan, antara lain:

- a) Jika memungkinkan, hindari penggunaan "bullet points" atau sejenisnya. Sebaiknya, gunakan angka (1, 2, 3, ...) atau huruf (a, b, c, ...). Dengan demikian, pembaca dapat dengan mudah melihat jumlah *item* atau *list*.
- b) Jika dalam daftar hanya ada satu item, tidak perlu menggunakan nomor urut.
- c) Penjelasan atau deskripsi suatu item sebaiknya menyatu dengan judul item tersebut, tidak berbeda halaman. Contoh yang salah: judul item ada di halaman 10, namun deskripsinya di halaman 11. Sebaiknya pindahkan judul tersebut ke halaman 11.
- d) Jika penjelasan atau deskripsi suatu item cukup panjang, misalnya lebih dari

1 halaman atau terdiri atas beberapa paragraf, sebaiknya setiap item tersebut dijadikan judul subbab, kecuali jika level subbab sudah mencapai level 4.

VI.4.6 Penggunaan Kata "masing-masing" dan "setiap"

Kata "masing-masing" digunakan di belakang kata yang diterangkan, misalnya "Setiap proses menggunakan algoritma masing-masing". Kata "tiap-tiap" atau "setiap" ditempatkan di depan kata yang diterangkan, misalnya "Setiap proses menggunakan algoritma tertentu".

BAB VII

PENUTUP

VII.1 Kesimpulan

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

VII.2 Saran

asdfas

DAFTAR PUSTAKA

- 1000minds. 2025. *What is the Analytic Hierarchy Process (AHP)?* Accessed November 13, 2025. <https://www.1000minds.com/decision-making/analytic-hierarchy-process-ahp>.
- Abu Kamesh, Mohammed. 2024. *Brain Tumour - Glioblastoma versus Metastasis*, July. <https://doi.org/10.53347/rid-191766>. <https://doi.org/10.53347/rid-191766>.
- Ali, Sajid, Tamer Abuhmed, Shaker El-Sappagh, Khan Muhammad, Jose M. Alonso-Moral, Roberto Confalonieri, Riccardo Guidotti, Javier Del Ser, Natalia Díaz-Rodríguez, dan Francisco Herrera. 2023. "Explainable Artificial Intelligence (XAI): What We Know and What Is Left to Attain Trustworthy Artificial Intelligence." *Information Fusion* 99:101805. <https://doi.org/10.1016/j.inffus.2023.101805>.
- Alshaari, Hussein, dan Saeed Alqahtani. 2025. "Deep-EFNet: An Optimized EfficientNetB0 Architecture with Dual Regularization for Scalable Multi-Class Brain Tumor Classification in MRI." Author's version accepted for publication, *IEEE Access*, <https://doi.org/10.1109/ACCESS.2025.3567919>. https://www.researchgate.net/publication/391557747_Deep-EFNet_An_Optimized_EfficientNetB0_Architecture_with_Dual_Regularization_for_Scalable_Multi-Class_Brain_Tumor_Classification_in_MRI.
- Asmita dan Praveen Mittal. 2025. "From black box AI to XAI in neuro-oncology: a survey on MRI-based tumor detection." *Discover Artificial Intelligence* 5 (1). <https://doi.org/10.1007/s44163-025-00247-3>. <https://link.springer.com/article/10.1007/s44163-025-00247-3>.
- Budiman, M. Arif, Yayat Suharyat, Sisi Yulianti, dan Abdul Rahman. 2024. "Effectiveness of Using CT Scan in Early Detection of Brain Tumor." *Indonesia Journal of Engineering and Education Technology (IJEET)* 2 (1): 164–172.

- Cea, Donatella, Lisa Barros Andrade e Sousa, Christina Bukas, Helena Pelin, Elisabeth Georgii, Helene Hoffmann, dan Sebastian Starke. 2017. *Introduction to Grad-CAM — XAI Tutorials*. Accessed November 20, 2025. https://xai-tutorials.readthedocs.io/en/latest/_model_specific_xai/Grad-CAM.html.
- Chapman, Pete, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, dan Rüdiger Wirth. 2000. *CRISP-DM 1.0: Step-by-step data mining guide*. Copyright 1999, 2000. Partners: NCR, DaimlerChrysler, SPSS, OHRA. The CRISP-DM consortium, August.
- Chen, Catherine, dan Zhihan Cui. 2025. “Impact of AI-Assisted Diagnosis on American Patients’ Trust in and Intention to Seek Help From Health Care Professionals: Randomized, Web-Based Survey Experiment.” *Journal of Medical Internet Research* 27 (June): e66083. <https://doi.org/10.2196/66083>. <https://www.jmir.org/2025/1/e66083>.
- Darmiati. 2023. “The impact of artificial intelligence assistance on the diagnostic performance of radiologists in detecting breast cancer on mammograms.” *Indonesian Journal of Cancer*, <https://www.indonesianjournalofcancer.or.id/e-journal/index.php/ijoc/article/view/1100/0>.
- Farber, Dana. 2025. *How We Diagnose Brain Tumors | Dana-Farber Cancer Institute*. <https://www.dana-farber.org/cancer-care/types/brain-tumors/diagnosis>.
- Flower, X. Little, dan T. Merlin Leo. 2025. “Performance Evaluation of Preprocessing Techniques for Noise Reduction and Enhancement in MRI-based Brain Tumor Detection.” 10 (2): b58–b63. https://www.researchgate.net/publication/389133174_Performance_Evaluation_of_Preprocessing_Techniques_for_Noise_Reduction_and_Enhancement_in_MRI-based_Brain_Tumor_Detection.
- GeeksforGeeks. 2020. *Convolutional Neural Network (CNN) in Machine Learning*, December. <https://www.geeksforgeeks.org/deep-learning/convolutional-neural-network-cnn-in-machine-learning/>.
- Goceri, E. 2023. “Medical image data augmentation: techniques, comparisons and interpretations.” *Artificial Intelligence Review*, <https://doi.org/10.1007/s10462-023-10453-z>.
- Hartung, Michael P., dan Mike Cadogan. 2023. *Abdominal CT: Planes*. Life in the Fast Lane • LITFL. Diakses melalui: <https://litfl.com/abdominal-ct-planes/>, February. <https://litfl.com/abdominal-ct-planes/>.

- Hosny, Ahmed, Chintan Parmar, John Quackenbush, Lawrence H. Schwartz, dan Hugo J. W. L. Aerts. 2018. "Artificial Intelligence in Radiology." *Nature Reviews Cancer* 18 (8): 500–510. <https://doi.org/10.1038/s41568-018-0016-5>.
- Hosny, Khalid M., dan Mahmoud A. Mohammed. 2025. "Explainable AI and vision transformers for detection and classification of brain tumor: a comprehensive survey." *Artificial Intelligence Review* 58 (June): 259. <https://doi.org/10.1007/s10462-025-11221-x>.
- Hospetrack. 2020. *Indonesia Hospital Intelligence*. Accessed October 28, 2025. <https://www.hospetrack.com/product/indonesia/>.
- IBM. 2023. *Explainable AI*, March. <https://www.ibm.com/think/topics/explainable-ai>.
- Iftikhar, Shagufta, Nadeem Anjum, Abdul Basit Siddiqui, Masood Ur Rehman, dan Naeem Ramzan. 2025a. "Explainable CNN for Brain Tumor Detection and Classification through XAI Based Key Features Identification." *Brain Informatics* 12 (1). <https://doi.org/10.1186/s40708-025-00257-y>.
- . 2025b. "Explainable CNN for brain tumor detection and classification through XAI based key features identification." *Brain Informatics* 12 (10): 1–19.
- Insights10. 2023. *Indonesia Radiology Service Market Analysis*. Insights10. Diakses melalui: <https://www.insights10.com/report/indonesia-radiology-service-market-analysis/>. <https://www.insights10.com/report/indonesia-radiology-service-market-analysis/>.
- International Agency for Research on Cancer. 2024a. *Brain, Central Nervous System. Fact Sheet*. Technical report. Accessed October 28, 2025. World Health Organization, Global Cancer Observatory (GCO). <https://gco.iarc.who.int/media/globocan/factsheets/cancers/31-brain-central-nervous-system-fact-sheet.pdf>.
- . 2024b. *Indonesia. Fact Sheet*. Technical report. Accessed October 28, 2025. World Health Organization, Global Cancer Observatory (GCO). <https://gco.iarc.who.int/media/globocan/factsheets/populations/360-indonesia-fact-sheet.pdf>.

- Jaffar, Ali, Muhammad Yousaf, Muhammad Hassan, Tayyab Rahim, Sheeza Hus-sain, Adeela Nawaz, dan Kunjshik Jaffar. 2025. “Comparative Analysis of MRI and CT Scan for the Diagnosis of Brain Tumor, Considering MRI as Gold Stan-dard.” *Journal of Health, Workforce and Clinical Research*, <https://jhwcr.com/index.php/jhwcr/article/view/106>.
- Al-Kadi, Omar, Israa Almallahi, Alaa Abu-Srhan, Mohammad Abushariah, dan Waleed Mahafza. 2022. *Unpaired MR-CT Brain Dataset for Unsupervised Image Trans-lation*. V. V1. Dataset. <https://doi.org/10.17632/z4wc364g79.1>. <https://doi.org/10.17632/z4wc364g79.1>.
- Kadir, Abdul, Amir Mosavi, dan Daniel Sonntag. 2023. *Evaluation Metrics for XAI: A Review, Taxonomy, and Practical Applications*. Accessed July 1, 2025. https://www.dfki.de/fileadmin/user_upload/import/14708_XAI_Evaluation_Metrics__Taxonomies__Concepts_and_Applications__INES_2023_-7.pdf.
- Mahesh, Muskan Gupta, Anupama T A, Vinoth Kumar V, Oana Geman, dan Dhillip Kumar V. 2024. “An XAI-enhanced efficientNetB0 framework for precision brain tumor detection in MRI imaging.” *Journal of Neuroscience Methods* 410:110227. <https://doi.org/10.1016/j.jneumeth.2024.110227>. <https://www.sciencedirect.com/science/article/pii/S0165027024001729>.
- Mamourian, Alexander. 2020. *Recognizing Intra-Axial Tumors on Brain Computed Tomography (CT)*. Medmastery. Diakses melalui: <https://www.medmastery.com/guides/brain-ct-clinical-guide/recognizing-intra-axial-tumors-brain-computed-tomography-ct-and>. <https://www.medmastery.com/guides/brain-ct-clinical-guide/recognizing-intra-axial-tumors-brain-computed-tomography-ct-and>.
- Mayo Clinic. 2019. *Brain Tumor - Diagnosis and Treatment - Mayo Clinic*. May-oclinic.org. Accessed October 28, 2025. <https://www.mayoclinic.org/diseases-conditions/brain-tumor/diagnosis-treatment/drc-20350088>.
- . 2023. *Brain Tumor - Symptoms and Causes*, April. <https://www.mayoclinic.org/diseases-conditions/brain-tumor/symptoms-causes/syc-20350084>.
- Moreira, Catarina, Yu-Liang Chou, Chihcheng Hsieh, Chun Ouyang, João Madeiras Pereira, dan Joaquim Jorge. 2024. “Benchmarking Instance-Centric Counter-factual Algorithms for XAI: From White Box to Black Box.” Diakses melalui: <https://arxiv.org/abs/2203.02399>, *arXiv preprint arXiv:2203.02399* (Novem-ber): 1–37. <https://arxiv.org/abs/2203.02399>.

- Muhammad, Dost, dan Malika Bendeche. 2025. "More than Just a Heatmap: Elevating XAI with Rigorous Evaluation Metrics." *Frontiers in Medical Technology* 7 (October). <https://doi.org/10.3389/fmedt.2025.1674343>.
- National Institute of Biomedical Imaging and Bioengineering. 2022. *Computed Tomography (CT)*. <https://www.nibib.nih.gov/science-education/science-topics/computed-tomography-ct>.
- National Institute of Biomedical imaging and Bioengineering. 2025. *Magnetic Resonance Imaging (MRI)*. <https://www.nibib.nih.gov/science-education/science-topics/magnetic-resonance-imaging-mri>.
- Nuraini, Ayu. 2024. *Kesulitan Akses Tenaga Radiologi Di Indonesia: Tantangan Untuk Pelayanan Kesehatan Yang Berkualitas*. KOMPASIANA. Kompasiana.com, December. <https://www.kompasiana.com/ayunuraini8527/675999b034777c753314b122/kesulitan-akses-tenaga-radiologi-di-indonesia-tantangan-untuk-pelayanan-kesehatan-yang-berkualitas>.
- Our World in Data. 2025. *Annual Number of Deaths by Cause*. Data source: Institute for Health Metrics and Evaluation (IHME), Global Burden of Disease. Accessed February 26, 2026. <https://ourworldindata.org/grapher/annual-number-of-deaths-by-cause>.
- Permana, Bayu Indra. 2025. *Kelangkaan Helium Global Bisa Ancam Layanan MRI Di Indonesia*. Tribunnews.com. Tribunnews, July. <https://www.tribunnews.com/kesehatan/2025/08/23/kelangkaan-helium-global-bisa-ancam-layanan-mri-di-indonesia>.
- Purnama, Basuki Eka. 2025. *Masih Ada Disparitas MRI Di Berbagai Provinsi Di Indonesia*. Mediaindonesia.com, July. <https://mediaindonesia.com/humaniora/804918/masih-ada-disparitas-mri-di-berbagai-provinsi-di-indonesia>.
- Putra, Irwandi Rizki, Zulrahmadi, Andri Swandi, Yulia, dan Tasya Destria Putri. 2025. "Enhanced Classification of Brain MRI Images for Tumor Detection Using Transfer Learning and Grad-CAM-Based Explainable Convolutional Neural Network (CNN)." *Journal of ICT Application and System (JICTAS)* 4 (2): 76–88. <https://doi.org/10.56313/jictas.v4i2.454>. <https://doi.org/10.56313/jictas.v4i2.454>.
- Radiology Key. 2015. *Brain*. Radiology Key. Diakses melalui: <https://radiologykey.com/brain/>, December. <https://radiologykey.com/brain/>.

- Republik Indonesia, Kementerian Kesehatan. 2025. *Update Tatalaksana Tumor Otak Dan Perawatan Luka Kraniotomi Angkatan 1*. LMS Kemkes. Accessed October 28, 2025. <https://lms.kemkes.go.id/courses/96f54d44-2103-4de0-8728-1fdae57accd4>.
- Syaftahan, Pabila. 2025. *Transformasi Radiologi Dengan Kecerdasan Buatan*. Indonesia Artificial Intelligence Hub. <https://aihub.id/berita/transformasi-radiologi-ai>.
- Tahosin, Mst Sazia, Md Alif Sheakh, Taminul Islam, Rishalatun Jannat Lima, dan Mahbuba Begum. 2023. "Optimizing Brain Tumor Classification through Feature Selection and Hyperparameter Tuning in Machine Learning Models." Accessed via: <https://doi.org/10.1016/j.imu.2023.101414>, *Informatics in Medicine Unlocked* 43 (January): 101414. <https://doi.org/10.1016/j.imu.2023.101414>. <https://doi.org/10.1016/j.imu.2023.101414>.
- Terven, Juan, Diana-Margarita Cordova-Esparza, Julio-Alejandro Romero-González, Alfonso Ramírez-Pedraza, dan E A Chávez-Urbiola. 2025. "A Comprehensive Survey of Loss Functions and Metrics in Deep Learning." *Artificial Intelligence Review* 58 (7). <https://doi.org/10.1007/s10462-025-11198-7>. <https://doi.org/10.1007/s10462-025-11198-7>.
- Woźniak, M., J. Siłka, dan M. Wiecezorek. 2021. "Deep neural network correlation learning mechanism for CT brain tumor detection." *Neural Computing and Applications*, <https://doi.org/10.1007/s00521-021-05841-x>. <https://doi.org/10.1007/s00521-021-05841-x>.
- Xu, Hanhui, dan Kyle Michael James Shuttleworth. 2023. "Medical artificial intelligence and the black box problem – a view based on the ethical principle of 'Do No Harm'." *Intelligent Medicine* 4 (1). <https://doi.org/10.1016/j.imed.2023.08.001>. <https://www.sciencedirect.com/science/article/pii/S2667102623000578>.
- Zhang, Li, Xin Wen, Jianwei Li, Jingyi Xu, Xin Yang, dan Meng Li. 2023. "Diagnostic Error and Bias in the Department of Radiology: A Pictorial Essay." *Insights into Imaging* 14 (1). <https://doi.org/10.1186/s13244-023-01521-7>.
- Zienius, K., Chak-Lam Ip, J. Park, M. Ozawa, W. Hamilton, D. Weller, D. Summers, dkk. 2019. "Direct access CT for suspicion of brain tumour: an analysis of referral pathways in a population-based patient group." Accessed February 25, 2026, *BMC Family Practice* 20 (118). <https://doi.org/10.1186/s12875-019-1003-y>.

LAMPIRAN A

KODE PROGRAM

Pada umumnya, kode program tidak perlu disertakan di dalam laporan tugas akhir karena kode program biasanya sangat panjang dan sudah disimpan dalam bentuk berkas-berkas elektronik terpisah di repositori daring. Namun, jika ada bagian kode program singkat yang penting untuk ditulis dalam laporan tugas akhir, bagian tersebut dapat disertakan di dalam laporan.

LAMPIRAN B

HASIL SURVEI LAPANGAN

B.1 Foto Survei Lokasi 1

Teks survei lokasi 1.

B.2 Foto Survei Lokasi 2

Teks survei lokasi 2.

B.3 Transkrip Wawancara dengan Narasumber

Teks transkrip wawancara.

