

***INTEGRASI EXPLAINABLE AI (XAI) PADA
CORRELATION LEARNING MECHANISM (CLM)
UNTUK DETEKSI TUMOR OTAK
MENGUNAKAN CITRA CT SCAN***

Laporan Tugas Akhir

Oleh

**Micky Valentino
18299093**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

25 Juni 2026

LEMBAR PENGESAHAN

INTEGRASI EXPLAINABLE AI (XAI) PADA CORRELATION LEARNING MECHANISM (CLM) UNTUK DETEKSI TUMOR OTAK MENGGUNAKAN CITRA CT SCAN

Laporan Tugas Akhir

Oleh

Micky Valentino
18299000

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 25 Juni 2026

Pembimbing

Dr. Ir. John Doe, M.T.

NIP. 123456789

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 25 Juni 2026

Micky Valentino

NIM: 18299093

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II hal. 15
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	...	...	...
5	Penyusunan bahan diskusi	...	...	...
6	Penyusunan kode program	...	...	...
7	Penyusunan formula atau perhitungan matematis	...	...	...
8	Penyusunan konsep desain atau algoritma	...	...	...
9	Penyusunan analisis data	...	...	...
10	Penyusunan kesimpulan atau rekomendasi	...	...	...

Bandung, 25 Juni 2026

Micky Valentino
NIM: 18299093

ABSTRAK

Implementasi Sistem Smart Scale Berbasis IoT dengan Arsitektur Desentralisasi untuk Optimalisasi Rantai Pasok Jeruk di Tingkat Lapak

oleh

John Doe

123456789

Proses manual dalam rantai pasok jeruk di tingkat lapak, yang mencakup sortir, timbang, dan catat, terbukti tidak efisien, memakan waktu, dan rentan terhadap kesalahan. Meskipun solusi berbasis Internet of Things (IoT) dapat mengatasi masalah ini, arsitektur terpusat konvensional berbasis cloud justru menimbulkan masalah baru berupa latensi tinggi yang menghambat alur kerja real-time. Penelitian ini bertujuan untuk merancang dan mengimplementasikan sebuah purwarupa sistem smart scale berbasis IoT dengan pendekatan desentralisasi (edge computing) untuk meminimalkan latensi dan meningkatkan efisiensi operasional. Metode yang digunakan adalah Model Purwarupa, yang diwujudkan dalam bentuk perangkat keras dengan arsitektur prosesor ganda (Raspberry Pi 5 dan ESP32) yang mampu mengintegrasikan fungsi timbang dan analisis kualitas citra secara simultan. Hasil evaluasi menunjukkan bahwa purwarupa dengan arsitektur edge computing yang diimplementasikan mampu memberikan respons 43,5% lebih cepat (latensi rata-rata 18,05 detik) dibandingkan dengan simulasi arsitektur terpusat. Selain itu, sistem ini berhasil meningkatkan efisiensi waktu kerja secara keseluruhan sebesar 58,32% jika dibandingkan dengan metode manual konvensional. Pengujian Penerimaan Pengguna (UAT) yang melibatkan 30 partisipan juga menunjukkan penerimaan yang sangat positif, dengan skor rata-rata untuk kemudahan penggunaan (5,0/5,0), kejelasan antarmuka (4,87/5,0) dan persepsi kinerja (4,95/5,0). Kesimpulannya, implementasi sistem smart scale dengan arsitektur desentralisasi terbukti merupakan solusi yang valid dan efektif untuk menjawab permasalahan latensi dan inefisiensi di lapak. Sistem ini tidak hanya unggul secara teknis dalam hal performa, tetapi juga fungsional dan dapat diterima dengan baik oleh pengguna akhir, serta berpotensi besar untuk modernisasi rantai pasok agribisnis.

Kata kunci: Smart Scale, Internet of Things, Edge Computing, Rantai Pasok Jeruk.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, saya dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul "Implementasi Algoritma XYZ untuk Optimasi Jaringan Komputer". Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Bandung, 20 Mei 2026

Penulis

John Doe

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
DAFTAR PERSAMAAN	xxi
DAFTAR ALGORITMA	xxiii
DAFTAR <i>LISTING</i>	xxv
DAFTAR SIMBOL	xxvii
DAFTAR SINGKATAN	xxxix
 I PENDAHULUAN	 1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	4
I.3 Tujuan	4
I.4 Batasan Masalah	5
I.5 Metodologi	5
I.6 Sistematika Penulisan	7
 II STUDI LITERATUR	 9
II.1 Tumor Otak	9
II.1.1 Teknologi Pencitraan Medis Tumor Otak	9
II.1.1.1 MRI	10
II.1.1.2 CT Scan	11
II.2 <i>Artificial Intelligence</i> (AI) dalam Pencitraan Medis	12
II.2.1 <i>Machine Learning</i> Tradisional	13
II.2.2 <i>Deep Learning</i>	13
II.3 <i>Explainable AI</i> (XAI)	15
II.3.1 Metode <i>Explainable AI</i> (XAI)	15
II.3.1.1 <i>Attribution-based Methods</i>	16
II.3.1.2 <i>Perturbation-based Methods</i>	16
II.3.1.3 <i>Activation-based Methods</i>	17
II.3.1.4 <i>Transformer-based Methods</i>	17
II.4 Evaluasi Model	17
II.4.1 <i>Deep Learning</i>	18
II.4.2 <i>Explainable Artificial Intelligence</i> (XAI)	19
II.5 Penelitian Terkait	21
II.5.1 <i>Explainable CNN for brain tumor detection and classifica-</i> <i>tion through XAI based key features identification</i>	21

II.5.2	<i>Enhanced Classification of Brain MRI Images for Tumor Detection Using Transfer Learning and Grad-CAM-Based Explainable CNN</i>	22
II.5.3	<i>Performance Evaluation of Preprocessing Techniques for Noise Reduction and Enhancement in MRI-based Brain Tumor Detection</i>	23
II.5.4	<i>CT to MRI Image Translation Using CycleGAN: A Deep Learning Approach for Cross-Modality Medical Imaging</i>	24
II.5.5	<i>Explainable AI for lung cancer detection via a custom CNN on CT images</i>	26
II.5.6	<i>Evaluasi Klinis dan Integrasi Alur Kerja AI dalam Radiologi Diagnostik</i>	27
III	ANALISIS MASALAH	29
III.1	Analisis Kondisi Saat Ini	29
III.1.1	Desain Sistem dan Mekanisme Kerja	29
III.1.2	Peran Model	30
III.1.3	Kelemahan dan Keterbatasan Sistem	31
III.2	Analisis Kebutuhan	31
III.2.1	Identifikasi Masalah Pengguna	32
III.2.2	Kebutuhan Fungsional	33
III.2.3	Kebutuhan Nonfungsional	34
III.3	Analisis Pemilihan Solusi	34
III.3.1	Alternatif Solusi	34
IV	PERANCANGAN	43
IV.1	<i>Data Understanding</i>	43
IV.2	<i>Data Preparation</i>	44
IV.2.1	<i>Preprocessing Umum</i>	44
IV.2.2	<i>Preprocessing Eksperimen</i>	45
IV.2.3	<i>Augmentasi</i>	46
IV.3	<i>Modelling</i>	48
IV.3.1	<i>Explainable CNN</i>	48
IV.3.2	<i>Hybrid model</i>	49
IV.3.3	<i>hyperparameter tuning</i>	50
IV.3.4	<i>Explainable AI</i>	51
IV.4	<i>Rancangan Evaluasi</i>	52
IV.4.1	<i>Evaluasi Model</i>	52
IV.4.2	<i>Evaluasi XAI</i>	52
V	IMPLEMENTASI	55
V.1	Lingkungan Implementasi	55
V.1.1	Lingkungan Perangkat Keras	55
V.1.2	Lingkungan Perangkat Lunak	55
V.2	Pengumpulan Data	55
V.3	Pemrosesan Data	57
V.3.1	Pemrosesan Umum	57

V.3.2	Pemrosesan Eksperimen	58
V.3.2.1	Gaussian Denoise dan CLAHE	58
V.3.2.2	Wavelet Denoise dan Intensity Normalization	59
V.4	Implementasi Arsitektur Model Utama (CLM)	59
V.4.1	<i>Convolutional Neural Network</i> (CNN)	59
V.4.2	<i>Artificial Neural Network</i> (ANN)	59
V.4.3	Integrasi Model	59
V.5	<i>Explainable AI</i> (Grad-CAM)	59
V.5.1	Ekstraksi <i>Feature Maps</i> dan Gradien	59
V.5.2	<i>Global Average Pooling</i> dan <i>Weighted Combination</i>	59
V.5.3	Pembangkitan <i>Heatmap</i> (Aktivasi ReLU)	59
VI	EVALUASI	61
VI.1	Metode Evaluasi	61
VI.2	Hasil Evaluasi	61
VI.3	Pembahasan Hasil Evaluasi	61
VI.4	Evaluasi Kesalahan Penulisan yang Sering Terjadi	61
VI.4.1	Penggunaan Kata ”di mana” atau ”dimana”	61
VI.4.2	Penggunaan Kata ”sedangkan” dan ”sehingga”	61
VI.4.3	Penggunaan Istilah yang Tidak Baku	62
VI.4.4	Pemisah Desimal dan Ribuan	62
VI.4.5	Daftar atau <i>List</i>	62
VI.4.6	Penggunaan Kata ”masing-masing” dan ”setiap”	63
VII	PENUTUP	65
VII.1	Kesimpulan	65
VII.2	Saran	65
Lampiran A	KODE PROGRAM	75
Lampiran B	HASIL SURVEI LAPANGAN	77
B.1	Foto Survei Lokasi 1	77
B.2	Foto Survei Lokasi 2	77
B.3	Transkrip Wawancara dengan Narasumber	77

DAFTAR GAMBAR

I.1	Penyebab kematian di dunia Tahun 2023 (Our World in Data 2025) .	2
I.2	<i>Cross-Industry Process for Data Mining</i> (CRISP-DM) (Chapman dkk. 2000)	6
II.1	<i>CT Scan</i> Otak (Abu Kamesh 2024)	10
II.2	<i>CT Scan</i> Otak (Abu Kamesh 2024)	12
II.3	Perbandingan <i>CT Scan</i> dan MRI Otak (Mamourian 2020)	13
II.4	Kategorisasi hierarkis metode XAI (Iftikhar dkk. 2025a)	15
II.5	Taksonomi berdasarkan aplikasi XAI (Kadir, Mosavi, dan Sonntag 2023)	19
II.6	Taksonomi berdasarkan metodologi evaluasi (Kadir, Mosavi, dan Sonntag 2023)	20
III.1	Visualisasi mekanisme <i>Correlation Learning Mechanism</i> (CLM) (Woźniak, Siłka, dan Wiczorek 2021)	29
IV.1	Arsitektur Model CNN + ANN	48

DAFTAR TABEL

III.1	Matriks Perbandingan Berpasangan Kriteria	37
III.2	Vektor Prioritas Kriteria	38
III.3	Matriks Perbandingan Berpasangan C1 (Akurasi)	38
III.4	Matriks Perbandingan Berpasangan C2 (Interpretability)	39
III.5	Matriks Perbandingan Berpasangan C3 (Efisiensi Komputasi)	39
III.6	Matriks Perbandingan Berpasangan C4 (Kebutuhan Data)	40
III.7	Matriks Perbandingan Berpasangan C5 (Kompleksitas)	41
III.8	Hasil Perhitungan Perbandingan Berpasangan	41
V.1	Perbandingan Kondisi Dataset Sebelum dan Sesudah <i>Preprocessing</i>	58
V.2	Perbandingan Parameter Dataset Sebelum dan Sesudah <i>Preprocessing</i>	58
VI.1	Contoh penggunaan kata ”sedangkan” dan ”sehingga”	62

DAFTAR PERSAMAAN

DAFTAR ALGORITMA

DAFTAR *LISTING*

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk CTC <i>loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ϵ	<i>Token blank</i> /kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam CTC	75
π_t	<i>Token</i> pada <i>timestep</i> t dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	L1 <i>loss</i> (<i>Mean Absolute Error</i>)	75
$\mathcal{L}_{L2}$	L2 <i>loss</i> (<i>Mean Squared Error</i>)	75
$\mathcal{L}_{CTC}$	CTC (<i>Connectionist Temporal Classification</i>) <i>loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75

$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator dalam GAN</i>	75
D	<i>Discriminator dalam GAN</i>	75
$G(z)$	<i>Output dari generator dengan input z</i>	75
$D(x)$	<i>Output dari discriminator dengan input x</i>	75
$G_{A \rightarrow B}$	<i>Generator dari domain A ke B</i>	75
$G_{B \rightarrow A}$	<i>Generator dari domain B ke A</i>	75
$V(D, G)$	<i>Fungsi nilai (value function) dalam GAN</i>	75
x	<i>Sampel data asli, input citra</i>	75
y	<i>Label atau ground truth, kondisi dalam conditional GAN</i>	75
z	<i>Noise vector atau representasi laten</i>	
$\mathbb{E}$	<i>Ekspektasi atau nilai harapan</i>	75
p_{data}	<i>Distribusi data asli</i>	75
p_z	<i>Distribusi prior (noise)</i>	75
$p(y x)$	<i>Probabilitas bersyarat output y given input x</i>	75
$p_t(\pi_t x)$	<i>Probabilitas token pada timestep t</i>	
$\mathcal{B}$	<i>Fungsi penciutan (collapse function) dalam CTC</i>	75
$\mathcal{B}^{-1}$	<i>Fungsi invers penciutan dalam CTC</i>	75
T	<i>Jumlah timestep atau panjang sequence</i>	
$ x - G(y) _1$	<i>L1 distance antara ground truth dan generated image</i>	75
$ x - G(y) _2$	<i>L2 distance antara ground truth dan generated image</i>	75
$N \times N$	<i>Ukuran patch dalam PatchGAN</i>	
d	<i>Cohen's d (effect size)</i>	75
n	<i>Jumlah sampel</i>	75
p	<i>p-value (nilai probabilitas statistik)</i>	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	1
CNN	<i>Convolutional Neural Network</i>	2
GPU	<i>Graphics Processing Unit</i>	14

BAB I

PENDAHULUAN

I.1 Latar Belakang


Berdasarkan data Our World in Data (2025) yang dapat dilihat pada Gambar I.1, kanker atau tumor ganas menempati urutan kedua sebagai penyebab kematian tertinggi di dunia setelah penyakit kardiovaskular, dengan perkiraan angka kematian mencapai 10,6 juta jiwa. Di dalam kelompok penyakit mematikan tersebut, tumor otak menjadi salah satu tantangan terbesar dalam dunia kesehatan global. Menurut International Agency for Research on Cancer (2024a), terdapat 321.731 kasus baru tumor otak di seluruh dunia, dengan angka kematian mencapai 248.500 kasus. Hal ini menempatkan tumor otak pada peringkat ke-19 dalam jumlah kejadian dan peringkat ke-12 dalam jumlah kematian. Berdasarkan data tersebut, perbandingan antara peringkat jumlah kejadian dan peringkat jumlah kematian pada tumor selain otak tidak berbeda jauh dibandingkan tumor otak. Perbedaan peringkat antara jumlah kejadian dengan jumlah kematian tumor otak ini menunjukkan urgensi diagnosis tumor otak lebih tinggi dibandingkan tumor yang lain.

Di Indonesia, kasus baru tumor otak tercatat sebanyak 5.738 kasus (1,4% dari total kasus kanker), dengan angka kematian mencapai 5.259 kasus (2,2%). Hal ini menempatkan tumor otak pada peringkat ke-15 dalam jumlah kejadian dan peringkat ke-11 dalam jumlah kematian. Selain itu, prevalensi lima tahun dari tumor otak mencapai angka 20.134 atau setara dengan 7,7 per 100.000 penduduk (International Agency for Research on Cancer 2024b). Hal ini mengindikasikan hanya sedikit orang yang masih hidup setelah lima tahun didiagnosis menderita tumor otak. Oleh karena itu, pendeteksian dini tumor otak merupakan hal yang krusial untuk keberhasilan pengobatan dan prognosis pasien (Republik Indonesia, Kementerian Kesehatan 2025).

Menurut Mayo Clinic (2019), untuk melakukan diagnosis tumor otak, diperlukan pemeriksaan neurologis, seperti pemeriksaan penglihatan, pendengaran, keseimbangan, koordinasi, kekuatan, dan refleks. Jika terdapat masalah di satu atau lebih area,

Causes of death, World, 2023

The estimated annual number of deaths from each cause. Estimates come with wide uncertainties, especially for countries with poor vital registration¹.



Data source: IHME, Global Burden of Disease (2025)

OurWorldinData.org/causes-of-death | CC BY

1. Civil Registration and Vital Statistics system A Civil Registration and Vital Statistics system (CRVS) is an administrative system in a country that manages information on births, marriages, deaths and divorces. It generates and stores 'vital records' and legal documents such as birth certificates and death certificates.

You can read more about how deaths are registered around the world in our article: [How are causes of death registered around the world?](#)

Gambar I.1 Penyebab kematian di dunia Tahun 2023 (Our World in Data 2025)

ini adalah petunjuk untuk melakukan pencitraan medis untuk melihat kondisi lebih lanjut. Terdapat cara yang dapat dilakukan untuk melakukan pencitraan medis pada tumor otak, yaitu pemindaian *CT Scan*, MRI otak, dan pemindaian *Positron Emission Tomography* (PET) otak. Oleh karena itu, pencitraan medis merupakan hal yang penting dalam pendeteksian tumor otak. Dari pencitraan medis tersebut, MRI menunjukkan akurasi diagnostik yang lebih tinggi dibandingkan *CT Scan*, yaitu MRI mendeteksi tumor otak pada 60% kasus dibandingkan dengan 50% oleh *CT Scan*. MRI menunjukkan akurasi diagnostik yang lebih tinggi, terutama untuk lokalisasi lesi dan penilaian parenkim, memperkuat statusnya sebagai standar emas dalam pencitraan tumor otak (Jaffar dkk. 2025).

Berdasarkan Hospetrack (2020), pada tahun 2019, Indonesia memiliki sekitar 750 pemindai *CT Scan* dan pemindai MRI yang jauh lebih rendah di antara 2.764 rumah sakit. Selain itu, disparitas MRI yang ada di Indonesia juga sangat besar. Berdasarkan data pada 2023, Kalimantan Barat hanya memiliki dua sistem MRI dengan jumlah penduduk mencapai lima juta jiwa. Sumatera Barat dengan 5,5 juta penduduk hanya memiliki empat alat kesehatan tersebut (Purnama 2025). Penggunaan MRI juga memiliki ketergantungan terhadap helium. Saat ini, terdapat kelangkaan helium secara global yang berdampak nyata pada penggunaan MRI Indonesia. Saat ini, Indonesia sedang mengembangkan inovasi teknologi MRI dengan desain tanpa helium. Namun, teknologi tersebut masih dalam tahap pengembangan dan belum terbukti dapat menyelesaikan permasalahan kelangkaan MRI di Indonesia (Permana 2025). Oleh karena itu, pendeteksian tumor otak melalui MRI sulit untuk dilakukan

di Indonesia dan salah satu alat pendeteksian tumor otak alternatif yang sudah lebih banyak digunakan adalah *CT Scan*. Sebuah studi dari Budiman dkk. (2024) mengonfirmasi bahwa penggunaan *CT Scan* terbukti sangat efektif dan memberikan dampak positif yang signifikan untuk keperluan deteksi dini tumor otak pada manusia.

Aspek yang penting dalam pendeteksian tumor otak adalah diagnosis yang dilakukan oleh radiolog. Menurut Nuraini (2024), Indonesia memiliki kesulitan akses tenaga radiolog dikarenakan distribusi tenaga medis yang tidak merata. Selain itu, diagnosis yang sering kali menghadapi tantangan dalam hal jumlah tenaga yang memadai untuk memenuhi kebutuhan pemeriksaan pasien yang semakin meningkat. Dengan meningkatnya jumlah kasus medis dan populasi yang terus bertumbuh, jumlah tenaga radiolog yang ada saat ini masih belum cukup untuk memenuhi seluruh permintaan pemeriksaan dengan akurat dan tepat waktu.

Saat ini, salah satu solusi yang ditawarkan untuk mengatasi permasalahan deteksi tumor otak adalah menggunakan teknologi *Artificial Intelligence* (AI). Pada penelitian yang dilakukan oleh Darmiati (2023), terdapat hasil bahwa bantuan AI secara signifikan meningkatkan sensitivitas dan spesifisitas semua radiolog dalam pendeteksian tumor pada payudara, dengan peningkatan median masing-masing sebesar 19,4% dan 12,1%. Penerapan AI secara langsung dalam praktik klinis juga telah dibuktikan keberhasilannya pada penanganan kasus tumor otak.

Salah satu penelitian terkini yang berfokus pada optimalisasi deteksi tumor otak menggunakan *CT Scan* adalah pengembangan *Correlation Learning Mechanism* oleh Woźniak, Siłka, dan Wieczorek (2021). Metode ini mengusulkan mekanisme pembelajaran korelasi baru untuk arsitektur jaringan saraf dalam yang menggabungkan *Convolutional Neural Network* (CNN) dengan arsitektur klasik. Hasil penelitian menunjukkan bahwa model CLM mampu mencapai akurasi sekitar 96%, serta presisi dan *recall* sekitar 95%. Dalam penelitian ini, CLM terbukti efektif dalam meningkatkan akurasi diagnostik pada citra CT tetapi penelitian ini memiliki keterbatasan utama berupa ketiadaan penjelasan hasil yang diberikan oleh model.

Pada AI yang digunakan untuk suplemen diagnostik tanpa transparansi terdapat permasalahan-permasalahan yang dapat terjadi. Berdasarkan Xu dan Shuttleworth (2023), terdapat permasalahan AI yang bersifat *black box* yang berarti dokter, pasien, atau pembuat AI tidak dapat memahami bagaimana AI menghasilkan kesimpulan atau rekomendasi medis. Hal ini dapat menyebabkan potensi kesalahan diagnosis, kehilangan pemahaman penuh terhadap informasi mengenai diagnosis, dan kesulitan dalam melacak identifikasi dan deteksi kesalahan medis. Salah satu solusi kece-

rdasan buatan yang saat ini sedang dikembangkan adalah penggunaan konsep *Explainable AI* (XAI). Berdasarkan Asmita dan Mittal (2025), XAI sangat penting untuk mengatasi ketidakpercayaan pada AI dengan cara meningkatkan transparansi dan interpretasi model *deep learning*. XAI memungkinkan para ahli, seperti radiolog untuk memahami bagaimana AI sampai pada suatu kesimpulan dengan menyoroti fitur-fitur data yang paling berpengaruh. Hal ini secara langsung membangun kepercayaan pada sistem otomatis, membantu kepatuhan terhadap regulasi, dan memperbaiki komunikasi hasil diagnosis kepada pasien.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah disampaikan, diagnosis tumor otak di Indonesia menghadapi tantangan berupa keterbatasan fasilitas MRI, sehingga mendorong penggunaan citra *CT Scan* sebagai alternatif utama. Di sisi lain, penggunaan *Artificial Intelligence* (AI) berbasis *deep learning* sebagai alat bantu diagnosis pada *CT Scan* masih memiliki kelemahan mendasar, yaitu sifat *black box* yang membuat landasan keputusannya tidak transparan. Ketidadaan penjelasan visual atas prediksi model ini menjadi persoalan, karena jika dibiarkan, model AI dengan akurasi tinggi sekalipun akan sulit divalidasi dan diandalkan objektivitasnya secara klinis. Oleh karena itu, penelitian ini mengusulkan pengembangan model *deep learning* untuk klasifikasi tumor otak pada citra *CT Scan* yang diintegrasikan dengan metode *Explainable AI* (XAI) guna memberikan transparansi diagnostik. Berdasarkan pokok persoalan tersebut, rumusan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Sejauh mana tingkat performa klasifikasi model *deep learning* yang dibangun dalam mendeteksi keberadaan tumor otak pada citra *CT Scan*?
2. Apakah integrasi metode *Explainable AI* pada model tersebut mampu menghasilkan representasi visual yang secara relevan dan tepat menyoroti area anomali tumor penyokong keputusan klasifikasi?

I.3 Tujuan

Tujuan utama dari tugas akhir ini adalah mengembangkan dan mengevaluasi arsitektur *deep learning* yang dapat mendeteksi keberadaan tumor otak pada citra *CT Scan* secara akurat sekaligus transparan. Kriteria keberhasilan dari tugas akhir ini diukur melalui dua aspek utama: (1) tercapainya performa klasifikasi model yang terukur secara kuantitatif melalui metrik evaluasi seperti akurasi, presisi, dan *recall*, serta (2) dihasilkannya visualisasi XAI yang mampu melokalisasi area fitur tumor secara tepat sesuai dengan posisi tumor, sehingga tidak lagi bertindak sebagai *black box*. Adapun tujuan dari pelaksanaan tugas akhir ini adalah:

1. Mengembangkan model *deep learning* untuk mengklasifikasikan keberadaan

tumor otak pada citra *CT Scan*.

2. Mengembangkan visualisasi pada citra untuk menjelaskan fokus perhatian model saat melakukan klasifikasi.

I.4 Batasan Masalah

Batasan masalah yang dilakukan pada tugas akhir ini adalah:

1. Dalam pelatihan, pengujian, dan validasi data, tugas akhir ini menggunakan data sekunder yang bersifat publik dan tidak melakukan pengambilan data primer dari rumah sakit. *Dataset* yang digunakan merupakan gabungan dari *dataset Unpaired MR-CT Brain Dataset for Unsupervised Image Translation* (Al-Kadi dkk. 2022) yang bersumber dari Jordan University Hospital untuk citra otak dengan tumor, serta *dataset* dari Radiopaedia yang diambil secara manual.
2. Tugas akhir ini menggunakan data gambar otak dengan bidang axial.
3. Tugas akhir tidak akan mencakup pengembangan sistem pendeteksian tumor otak maupun aplikasi berskala produksi yang terintegrasi dengan sistem informasi rumah sakit.
4. Fokus utama klasifikasi adalah untuk mendeteksi keberadaan tumor otak. Klasifikasi lebih lanjut mengenai jenis, stadium, atau keganasan tumor hanya akan dilakukan jika label tersebut tersedia dalam *dataset* yang digunakan.
5. Tugas akhir ini hanya mengevaluasi kemampuan model dalam mendeteksi keberadaan tumor otak, dan tidak menilai atau mengukur dimensi tumor yang terdeteksi.


I.5 Metodologi

Metodologi tahapan pengerjaan tugas akhir ini akan mengadopsi kerangka kerja *Cross-Industry Process for Data Mining* (CRISP-DM) seperti pada Gambar I.2.

Keseluruhan tahapan yang akan dilalui selama pelaksanaan tugas akhir, yang spesifik untuk menyelesaikan persoalan yang diangkat, adalah sebagai berikut.

1. *Business Understanding*

Business Understanding dilakukan untuk mengidentifikasi permasalahan tumor otak yang terjadi di Indonesia dan potensi solusi yang dapat dihadirkan oleh kecerdasan buatan. Proses investigasi dan pengumpulan fakta pada tahap ini dilakukan melalui studi literatur sistematis. Pencarian literatur berfokus pada basis data akademik seperti Google Scholar, Scopus, dan Springer-Link, menggunakan kombinasi kata kunci seperti "tumor otak", "CT Scan", "deep learning", dan "XAI". *Filtering* literatur dilakukan untuk mendapatk-



Gambar I.2 *Cross-Industry Process for Data Mining (CRISP-DM)* (Chapman dkk. 2000)

an sumber primer yang relevan dan terbaru sehingga menjamin validitas dan relevansi solusi yang diusulkan. Hal ini dilakukan dengan mencari studi literatur mengenai permasalahan tumor otak yang ada. Setelah itu, dilakukan pencarian solusi-solusi yang sudah berjalan dan yang sedang dikembangkan. Berdasarkan permasalahan dan solusi, dilakukan pendefinisian terhadap tujuan, persyaratan, dan rumusan masalah yang ingin dicapai.

2. *Data Understanding*

Data Understanding dilakukan untuk mengenali dan memeriksa *dataset* untuk mengidentifikasi karakteristik, kualitas, dan wawasan awal. Tahap ini dilakukan dengan mencari *dataset* publik citra *CT Scan* otak, lalu memeriksa data tersebut untuk mengetahui regulasi dalam pengumpulan data tersebut serta memeriksa kualitas data, seperti jumlah data dan distribusi kelas untuk mengidentifikasi potensi masalah dan hal yang harus dilakukan pada data tersebut.

3. *Data Preparation*

Data Preparation bertujuan untuk menghasilkan data yang bersih dan sesuai dengan model yang ingin digunakan. *Data preparation* dilakukan dengan cara membagi data menjadi tiga bagian, yaitu data latih, validasi, dan uji. Setelah itu, dilakukan pembersihan data yang memiliki kualitas rendah atau data

outlier, *preprocessing* pada citra, dan penyeragaman format data citra sesuai dengan model yang akan digunakan.

4. *Modeling*

Modeling dilakukan untuk memilih dan menetapkan teknik pemodelan yang ingin dilakukan dan melatihnya menggunakan hasil dari *data preparation*. *Modeling* dilakukan dengan memilih arsitektur model dan teknik XAI yang akan digunakan, membangun model menggunakan data latih, mengatur *hyperparameter* model untuk meningkatkan performa, dan menilai kinerja model-model yang telah dibuat untuk disimpan pada evaluasi.

5. *Evaluation*

Evaluasi dilakukan untuk memastikan model yang telah dipilih dapat mencapai tujuan penelitian dan menjawab rumusan masalah yang sudah dibuat. Evaluasi dilakukan dengan mengukur performa model CNN secara kuantitatif, seperti metrik akurasi, presisi, dan *recall* serta mengukur performa model XAI secara kuantitatif berdasarkan *ground truth* untuk melihat seberapa signifikan XAI dapat menyoroti area tumor.

6. *Deployment*

Pada pengerjaan Tugas Akhir ini tidak dilakukan tahapan *deployment*.

I.6 Sistematika Penulisan

Tuliskan gambaran umum isi dari setiap bab yang ada dalam laporan tugas akhir. Sistematika penulisan ini memberikan panduan bagi pembaca tentang struktur dan alur pembahasan dalam laporan tugas akhir. Berikut adalah contoh sistematika penulisan yang dapat diikuti:

1. Bab I Pendahuluan: Berisi latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika penulisan laporan tugas akhir .
2. Bab II Studi Literatur: Berisi kajian pustaka yang relevan dengan topik tugas akhir, termasuk teori-teori, konsep-konsep, dan hasil-hasil penelitian sebelumnya yang mendukung pelaksanaan tugas akhir.
3. Bab III Analisis: Berisi penjelasan tentang analisis masalah dan kebutuhan pengguna serta berbagai alternatif solusinya.
4. Bab IV Perancangan: Berisi penjelasan tentang perancangan solusi yang diusulkan, misalnya arsitektur sistem, desain basis data, antarmuka pengguna, dan sebagainya.
5. Bab V Implementasi: Berisi penjelasan tentang proses implementasi solusi yang diusulkan, termasuk langkah-langkah yang diambil, teknologi yang digunakan, dan hasil yang diperoleh.
6. Bab VI Evaluasi: Berisi analisis dan evaluasi terhadap solusi yang diimple-

mentasikan, termasuk metode pengujian, hal-hal yang disiapkan sebelum pengujian, hasil pengujian, dan penilaian kinerja.

7. Bab VII Kesimpulan dan Saran: Berisi kesimpulan dari hasil pelaksanaan tugas akhir dan saran untuk pengembangan lebih lanjut.
8. Daftar Pustaka: Berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. Lampiran: Berisi dokumen-dokumen pendukung seperti kode program, data lengkap hasil pengujian, rekaman wawancara, dan lain-lain.

BAB II

STUDI LITERATUR

II.1 Tumor Otak

Berdasarkan Mayo Clinic (2023), tumor otak didefinisikan sebagai pertumbuhan abnormal sel yang terjadi di dalam atau di dekat otak. Lokasi tumor dapat bervariasi, mencakup jaringan otak, saraf, kelenjar pituitari, kelenjar pineal, serta membran yang menutupi permukaan otak. Tumor yang bermula di otak disebut tumor otak primer, sedangkan tumor yang menyebar ke otak dari bagian tubuh lain disebut tumor otak sekunder atau metastatik.

II.1.1 Teknologi Pencitraan Medis Tumor Otak

Langkah awal untuk mendiagnosis tumor otak adalah pemeriksaan fisik, tes penglihatan, riwayat medis, dan tes neurologis untuk mengevaluasi fungsi otak serta saraf. Jika tes awal menunjukkan kemungkinan adanya tumor otak, pencitraan diagnostik akan dilakukan dan dianalisis oleh ahli neuroradiologi (Farber 2025). Dalam pencitraan tumor otak, terdapat tiga bidang utama yang bisa dilakukan oleh alat pencitraan seperti pada Gambar II.1 (Hartung dan Cadogan 2023).


Berdasarkan Radiology Key (2015), terdapat tiga bidang dalam pencitraan medis.

1. Bidang Aksial

Bidang aksial yang juga sering disebut sebagai bidang *transverse* merupakan bidang horizontal yang memotong tubuh secara melintang sehingga membaginya menjadi bagian atas dan bagian bawah. Bidang ini dinamakan aksial karena orientasi bidang ini posisinya tegak lurus terhadap sumbu panjang atau poros utama tubuh manusia. Dalam konteks medis seperti *CT Scan*, bidang ini memungkinkan dokter melihat irisan tubuh seolah-olah dilihat dari arah kaki ke arah kepala atau sebaliknya.

2. Bidang Koronal

Bidang koronal atau dikenal juga sebagai bidang frontal adalah bidang vertikal yang membelah tubuh menjadi dua bagian, yaitu bagian depan dan bagian belakang. Bidang ini dinamakan koronal karena bidang ini berjalan sejajar



Gambar II.1 *CT Scan* Otak (Abu Kamesh 2024)

dengan *coronal suture* pada tengkorak manusia. Sutura ini adalah garis pertemuan tulang tengkorak yang posisinya menyerupai letak mahkota di atas kepala, atau seperti bando yang melintang dari telinga kiri ke telinga kanan.

3. Bidang Sagital

Bidang sagital merupakan bidang vertikal yang memisahkan tubuh menjadi sisi kanan dan sisi kiri. Bidang ini dinamakan sagital karena posisinya sejajar atau melewati sutura tersebut, yang secara visual menyerupai bentuk atau arah anak panah yang melesat lurus jika dilihat dari arah depan wajah.

II.1.1.1 MRI

Magnetic Resonance Imaging (MRI) merupakan teknologi pencitraan 3D noninvasif beresolusi tinggi yang memanfaatkan interaksi medan magnet kuat dan gelombang radio terhadap proton dalam molekul air pada jaringan tubuh. Berdasarkan perbedaan waktu relaksasi energi proton tersebut, MRI sangat unggul untuk memvisualisasikan detail anatomi jaringan lunak—seperti struktur otak, saraf, dan otot—serta efektif dalam mendiagnosis tumor tanpa paparan radiasi. Meskipun aman dari radiasi, penggunaannya dikontraindikasikan bagi pasien dengan implan logam (misalnya alat pacu jantung) dan memiliki risiko penyerta seperti kebisingan, stimulasi saraf, hingga potensi toksisitas agen kontras gadolinium pada penderita gangguan ginjal (National Institute of Biomedical imaging and Bioengineering 2025).

II.1.1.2 CT Scan

Computed Tomography (CT) adalah prosedur pencitraan diagnostik yang menggunakan teknologi sinar-X. Prosedur ini bekerja dengan mengarahkan berkas sinar-X yang sempit dan berputar cepat mengelilingi tubuh pasien. Sinyal yang dihasilkan kemudian diproses oleh komputer untuk membuat serangkaian gambar irisan tomografi secara detail, yang dapat direkonstruksi menjadi gambar tiga dimensi (3D).

CT Scan memiliki peran penting sebagai instrumen peringatan dini dalam mendiagnosis tumor otak. Berdasarkan penelitian oleh Budiman dkk. (2024), penggunaan CT Scan terbukti sangat efektif dan memberikan dampak positif bagi deteksi dini tumor otak pada manusia. Tingkat efektivitas ini dibuktikan secara kuantitatif melalui perolehan nilai rata-rata effect size sebesar 1.17 yang masuk dalam kategori tinggi. Selain itu, hasil pengujian N-Gain juga menunjukkan skor 0.58 dengan kategori efektivitas tinggi.

Meskipun MRI sering dianggap sebagai metode pencitraan yang lebih sensitif dalam mendeteksi keberadaan tumor yang berukuran kecil, CT Scan tetap menawarkan keunggulan lain, seperti tingkat ketersediaan alat yang lebih merata di berbagai fasilitas kesehatan serta waktu pemeriksaan yang jauh lebih singkat. Temuan yang mendukung efektivitas CT Scan pada tahap awal ini berdampak besar pada praktik klinis sehari-hari. Modalitas dapat membuat proses pengambilan keputusan diagnostik dan perencanaan pengobatan pasien menjadi lebih cepat dan efektif.

CT Scan dapat digunakan untuk mengidentifikasi penyakit atau cedera, seperti mencitrakan kepala untuk menemukan cedera, tumor, atau gumpalan yang menyebabkan *stroke* serta mencitrakan paru-paru atau patah tulang yang kompleks. Disamping kelebihan yang dipunyai, *CT Scan* memiliki kelemahan berupa prosedur ini menggunakan radiasi yang memiliki risiko biologis dan agen kontrasnya berpotensi menyebabkan reaksi alergi atau gangguan ginjal pada pasien tertentu (National Institute of Biomedical Imaging and Bioengineering 2022).

Selain risiko biologis, *CT Scan* juga kurang sensitif dalam mendiagnosis, seperti yang terlihat pada Gambar II.3. Pada kasus tumor *intra-axial*, masalah utamanya adalah kurang jelasnya gambar jaringan lunak. Menurut Mamourian (2020), banyak tumor jenis ini bersifat *isodense* atau kepadatannya mirip dengan jaringan otak normal. Akibatnya, tumor sulit dibedakan jika tidak memakai cairan kontras atau dibandingkan dengan hasil MRI. Selain itu, sering terjadi kebingungan diagnosis karena tumor bisa terlihat seperti penyakit lain, seperti infark subakut, abses otak,



Gambar II.2 *CT Scan* Otak (Abu Kamesh 2024)

atau lesi demielinisasi. Masalah ini bisa diperparah oleh bias konfirmasi, di mana pembacaan hasil *CT Scan* terpengaruh oleh riwayat penyakit pasien. Oleh karena itu, kunci untuk mendeteksi tumor *intra-axial* pada *CT Scan* adalah dengan mengamati tanda-tanda kecil lainnya secara teliti (Mamourian 2020).


II.2 *Artificial Intelligence* (AI) dalam Pencitraan Medis

Implementasi AI memberikan dampak besar pada berbagai tugas dalam alur kerja radiologi. AI berdampak pada tugas-tugas klinis berbasis gambar, yang mencakup deteksi kelainan, karakterisasi objek dalam gambar menggunakan segmentasi, diagnosis, dan penentuan stadium, serta pemantauan objek untuk diagnosis dan penilaian respons pengobatan. Terdapat dua metode utama dalam pencitraan medis untuk tugas klasifikasi seperti membedakan tumor jinak atau ganas, yaitu *machine learning* tradisional dan *deep learning* (Hosny dkk. 2018).

Dalam konteks transparansi dan kemampuan interpretasi keputusan medis, model-model pembelajaran mesin tersebut dapat dikategorikan lebih lanjut menjadi dua jenis utama (Moreira dkk. 2024):

1. *White-Box Models*

Model ini dirancang dengan logika dasar dan proses yang jelas, sehingga mekanisme pengambilan keputusannya secara dapat ditafsirkan (*interpretable*)



Gambar II.3 Perbandingan *CT Scan* dan *MRI* Otak (Mamourian 2020)

oleh manusia. Pengguna dapat memahami bagaimana model bekerja dengan memeriksa strukturnya secara langsung, seperti melihat bobot fitur atau aturan keputusan. Contoh algoritma yang termasuk dalam kategori ini adalah *Decision Trees* dan regresi linear.

2. *Black-Box Models*

Model ini memiliki mekanisme internal yang sangat kompleks sehingga sulit atau tidak mungkin bagi pengguna manusia untuk memahami bagaimana prediksi atau hasil spesifik dihasilkan. Karena kompleksitasnya, hubungan antara input dan output sering dianggap sebagai misteri yang tidak dapat diperiksa secara manual. *Deep Neural Networks* dan model *ensemble* yang rumit merupakan representasi utama dari kategori ini.

II.2.1 *Machine Learning Tradisional*

Metode ini bergantung pada *engineered features* yang diekstraksi berdasarkan pengetahuan ahli dari area yang diminati. Contoh fitur ini adalah volume, bentuk, dan tekstur tumor. Fitur-fitur ini kemudian dipilih dan dimasukkan ke alat klasifikasi (Hosny dkk. 2018).

II.2.2 *Deep Learning*

Deep learning menggunakan sistem *layers* yang secara bersamaan melakukan ekstraksi fitur, seleksi, dan klasifikasi selama proses pelatihan. Lapisan-lapisan ini belajar mengenali fitur dari yang abstrak, seperti garis hingga yang kompleks, seperti organ (Hosny dkk. 2018). Beberapa teknik utama yang biasa digunakan, yaitu:

1. CNN (*Convolutional Neural Networks*)

CNN adalah model *deep learning* yang dirancang untuk memproses data dengan topologi seperti *grid* dengan contoh berupa gambar. CNN dapat digunakan untuk mendeteksi objek dalam gambar seperti orang, mobil, dan ba-

ngunan. CNN juga dapat digunakan untuk melokalisasi objek dalam gambar, yang berarti dapat mengidentifikasi lokasi suatu objek dalam gambar.

CNN memiliki beberapa komponen kunci. Pertama, *convolutional layers* yang menerapkan filter pada gambar masukan untuk mendeteksi fitur seperti tepi dan tekstur, sekaligus menjaga hubungan spasial antarpiksel. Kedua, *pooling layers* yang melakukan pengurangan sampel untuk mengurangi kompleksitas komputasi dan jumlah parameter. Ketiga, *activation functions* yang memperkenalkan non-linearitas agar model dapat mempelajari hubungan data yang kompleks. Terakhir, *fully connected layers* yang bertanggung jawab membuat prediksi akhir berdasarkan fitur yang telah dipelajari oleh lapisan-lapisan sebelumnya (GeeksforGeeks 2020).

2. RNN (*Recurrent Neural Networks*)

Recurrent Neural Network (RNN) adalah *deep neural network* yang dilatih pada data sekuensial untuk menciptakan model *machine learning* yang dapat membuat prediksi atau kesimpulan sekuensial berdasarkan *input* sekuensial (Stryker 2021). RNN dianggap sangat penting ketika menangani data citra medis yang bersifat sekuensial, seperti video atau gambar *time-series*, karena kemampuannya menangkap ketergantungan waktu (Li dkk. 2023).

RNN memiliki dua komponen kunci, yaitu *recurrent neuron* dan *RNN unfolding*. *Recurrent neuron* merupakan unit pemrosesan yang menyimpan keadaan tersembunyi yang berfungsi sebagai memori untuk menyimpan informasi dari *input-input* sebelumnya dalam suatu urutan sehingga memungkinkannya menangkap dependensi antarwaktu. *RNN unfolding* adalah proses struktur rekuren yang direpresentasikan sebagai rangkaian lapisan yang berurutan sesuai langkah waktu. Proses penguraian ini mengilustrasikan aliran informasi dan memungkinkan penerapan algoritma *backpropagation through time*, yaitu metode penyebaran galat mundur melintasi langkah-langkah waktu untuk menyesuaikan bobot jaringan dan mempelajari dependensi dalam data sekuensial (Stryker 2021).

3. *Generative Adversarial Network* (GAN)

Generative Adversarial Network (GAN) adalah model *machine learning* yang dirancang untuk menghasilkan data realistis dengan mempelajari pola dari *dataset* pelatihan yang ada (Varughese 2025). GAN memainkan peran penting dalam tugas-tugas yang memerlukan pembuatan atau translasi gambar (Li dkk. 2023). GAN didasarkan pada dua komponen *neural network*, yaitu generator dan diskriminator. Generator adalah jaringan yang bertugas menghasilkan data sintetis dari *input* acak. Tujuan generator adalah untuk mempelajari po-


la data asli dan menciptakan sampel palsu. Diskriminator berfungsi sebagai pengklasifikasi biner yang dilatih untuk membedakan antara data nyata dari distribusi data asli dan data palsu yang dihasilkan oleh generator (Geeks-forGeeks 2019).

II.3 *Explainable AI (XAI)*

Explainable Artificial Intelligence (XAI) adalah seperangkat proses dan metode yang memungkinkan pengguna manusia untuk memahami hasil dan keluaran yang dibuat oleh algoritma *machine learning* (IBM 2023). Tujuan utama *Explainable AI* adalah untuk mendapatkan model yang dapat diinterpretasikan oleh manusia. Interpretasi ini sangat penting untuk aplikasi di sektor-sektor sensitif seperti militer, perbankan, dan layanan kesehatan. Hal ini bertujuan agar para spesialis domain dapat diberikan penjelasan yang bermakna sehingga mereka dapat memahami dan memercayai solusi AI tersebut (Ali dkk. 2023).

II.3.1 Metode *Explainable AI (XAI)*

Berdasarkan mekanisme interpretasi, XAI memiliki hierarki yang dapat dilihat pada Gambar II.4.



Gambar II.4 Kategorisasi hierarkis metode XAI (Iftikhar dkk. 2025a)

Attribution-based methods memiliki konsep dengan memberi nilai pada setiap bagian masukan gambar. Bagian yang paling memengaruhi keputusan akhir akan mendapat nilai tinggi. Hal ini dapat membantu penggunaannya untuk melihat area pada gambar yang paling penting bagi AI. *Activation-based methods* melihat bagian gambar yang membuatnya bereaksi untuk memberikan penjelasan bagaimana AI mengenali fitur gambar secara bertahap. *Perturbation-based methods* menjelaskan keputusan dengan memodifikasi atau melakukan *masking* sebagian masukan dan mengamati dampaknya pada keluaran. *Transformer-based methods* memanfaatkan mekanisme *self-attention* dari *vision transformers* dan model terkait sehingga bisa menunjukkan bagian gambar yang sedang fokus diperhatikan oleh AI saat mengambil keputusan (Iftikhar dkk. 2025a).

II.3.1.1 *Attribution-based Methods*

Attribution-based methods menghasilkan visualisasi seperti *heatmap* dengan cara melacak representasi *internal model*, seperti gradien atau aktivasi, secara mundur dari *output* prediksi ke *input*. Metode ini memiliki asumsi bahwa tingkat kepentingan sebuah fitur *input* dapat diturunkan dari bagaimana perubahan pada fitur tersebut memengaruhi *output* akhir model. Terdapat beberapa algoritma *attribution-based methods* (Iftikhar dkk. 2025a), yaitu:

1. *Gradient-weighted Class Activation Mapping* (Grad-CAM)

Grad-CAM adalah sebuah metode XAI yang digunakan untuk memahami pentingnya berbagai lapisan dan fitur dalam sebuah CNN. Fungsi utamanya adalah membantu menemukan wilayah pada sebuah gambar yang memiliki dampak terbesar terhadap prediksi model.

2. FullGrad-CAM dan FullGrad-CAM++

Metode FullGrad-CAM dan FullGrad-CAM++ memperluas Grad-CAM dengan menggabungkan semua kontribusi bias dan gradien dari lapisan-lapisan sebelumnya. FullGrad-CAM melakukan *backpropagate gradient* dan mengakumulasi nilai absolutnya untuk menghasilkan penjelasan yang lebih informatif.

3. SmoothGrad

SmoothGrad mengurangi *visual noise* dengan menambahkan *Gaussian perturbation* kecil ke masukan beberapa kali dan mengambil rata-rata penjelasan berbasis gradien dari variasi-variasi ini. Hal ini dapat menghaluskan perubahan nilai yang sangat drastis yang muncul dalam metode berbasis gradien.

II.3.1.2 *Perturbation-based Methods*

Perturbation-based methods menjelaskan prediksi model dengan sengaja mengubah *input* dan mengamati bagaimana *output*-nya berubah. Saat sebuah bagian dari *input* ditutupi, diubah, atau dihilangkan dan menyebabkan prediksi model berubah drastis, bagian tersebut akan dianggap penting bagi keputusan model. Terdapat beberapa algoritma *perturbation-based methods* (Iftikhar dkk. 2025a), yaitu:

1. LIME (*Local Interpretable Model-Agnostic Explanations*)

Metode LIME membagi *input* menjadi segmen-segmen yang dapat ditafsirkan lalu mengganggu segmen-segmen ini dengan menyalakan atau mematikannya secara acak dan melatih model lokal yang lebih sederhana untuk meniru keputusan model *black-box* hanya di area tersebut. Bobot atau tingkat kepentingan dari model ini yang digunakan untuk menjelaskan fitur yang paling penting.

2. RISE (*Randomized Input Sampling for Explanation*)

Metode RISE bekerja dengan membuat banyak *mask* biner secara acak yang menutupi bagian-bagian gambar. Setiap gambar yang ditutupi *mask* dimasukkan ke model untuk dilihat skor prediksinya. Setelah itu, peta yang menunjukkan bagian penting dihasilkan dengan menggabungkan semua *mask* acak tersebut.

II.3.1.3 *Activation-based Methods*

Activation-based methods adalah teknik yang menghasilkan penjelasan dengan cara melihat langsung *feature maps* di dalam lapisan-lapisan jaringan saraf (CNN). Terdapat beberapa algoritma *activation-based methods* (Iftikhar dkk. 2025a), yaitu:

1. DeConvNets (*Deconvolutional Networks*)

Metode DeConvNets memiliki tujuan untuk memahami dan memvisualisasikan apa yang telah dipelajari oleh setiap neuron atau lapisan dalam sebuah CNN. Metode DeConvNets mengambil sebuah aktivasi fitur dari lapisan dalam seperti neuron yang aktif dan merekonstruksinya kembali ke ruang *input*. Hasil dari metode ini adalah sebuah gambar yang menunjukkan pola visual yang membuat neuron tersebut aktif.

2. *Class Activation Mapping* (CAM)

Metode CAM dilakukan untuk mengidentifikasi wilayah pada gambar *input* yang paling penting yang digunakan model untuk membuat prediksi kelas tertentu. CAM melihat *importance weights* dari lapisan *global average pooling* yang terletak tepat sebelum lapisan keputusan akhir. Setelah itu, CAM menyorot area pada gambar asli yang memiliki peta fitur penting aktif. Hasilnya adalah sebuah *heatmap* yang menunjukkan lokasi bukti.

II.3.1.4 *Transformer-based Methods*

Transformer-based merupakan metode khusus pada arsitektur *Vision Transformer* (ViT) yang berfokus pada mekanisme *attention* bawaan dari model itu sendiri. ViT memproses gambar dengan membaginya menjadi beberapa potongan dan kemudian menghitung skor atensi di antara semua *patch* tersebut. Teknik ini mengekstrak dan memvisualisasikan skor atensi ini untuk menghasilkan peta yang menunjukkan bagian gambar yang paling diperhatikan oleh model saat mengambil keputusan (Iftikhar dkk. 2025a).

II.4 Evaluasi Model

Evaluasi model ML sangat penting tidak hanya untuk mengukur kinerja kuantitatif tetapi juga untuk menilai kelayakan praktisnya dalam skenario berisiko tinggi. Evaluasi sangat krusial untuk menyeimbangkan *trade-off* antara akurasi deteksi de-

ngan *false positive rate* untuk mengurangi alarm palsu dan *false negative rate* untuk menghindari ancaman yang terlewat. Selain itu, evaluasi juga mencakup penilaian kualitas dari penjelasan XAI untuk memastikan model tidak hanya akurat tetapi juga transparan, dapat ditafsirkan, dan dapat dipercaya untuk adopsi di dunia nyata (Mohale dan Obagbuwa 2025).

II.4.1 *Deep Learning*

Salah satu komponen penting dari *deep learning* untuk melatih dan mengevaluasi model adalah *loss function* dan *performance metrics*. *Loss function* mengukur seberapa efektif sebuah model dapat mengaproksimasi keluaran yang diinginkan. Berdasarkan Terven dkk. (2025), terdapat beberapa *loss functions* yang bisa digunakan dalam pendeteksian tumor, yaitu:

1. *Weighted Cross-Entropy (WCE)*

Memberikan bobot yang lebih tinggi pada kelas minoritas untuk memastikan kelas tersebut mendapat perhatian yang cukup selama pelatihan.

2. *Dice Loss*

Loss function yang umum digunakan dalam pencitraan medis, terutama untuk skenario objek kecil, seperti tumor. *Loss function* ini secara langsung mengoptimalkan tumpang tindih spasial antara prediksi dan target.

3. *Tversky Loss*

Tversky Loss dirancang untuk data dengan *class imbalance* yang parah. *Loss function* ini memungkinkan penalti yang berbeda untuk *false positives* dan *false negatives*, yang sangat penting dalam deteksi medis, seperti melewatkan tumor atau *false negative* memiliki akibat yang lebih fatal.

Performance metrics menilai kemampuan model untuk membuat prediksi akurat pada data yang belum pernah dilihat. Berdasarkan Terven dkk. (2025), terdapat beberapa *performance metrics* yang bisa digunakan dalam pendeteksian tumor, yaitu:

1. *Precision, Recall, dan F1-Score*

Precision mengukur akurasi prediksi positif, *recall* mengukur seberapa banyak kasus tumor aktual yang berhasil ditemukan, dan *F1-Score* memberikan skor keseimbangan antara keduanya.

2. *Precision-Recall Curve*


Kurva yang memvisualisasikan *trade-off* antara *precision* dan *recall* di berbagai ambang batas. *Precision-recall curve* direkomendasikan untuk data yang tidak seimbang dengan kelas minoritas yang penting.

II.4.2 Explainable Artificial Intelligence (XAI)

Berdasarkan Kadir, Mosavi, dan Sonntag (2023), untuk melakukan evaluasi terhadap XAI, diperlukan metrik XAI yang bisa ditentukan oleh dua taksonomi, yaitu taksonomi berbasis aplikasi dan taksonomi berbasis metodologi evaluasi.

1. Taksonomi Berbasis Aplikasi

Taksonomi berbasis aplikasi adalah klasifikasi yang mengelompokkan metrik XAI berdasarkan tujuan konseptualnya. Hal ini memisahkan konsep umum seperti *user satisfaction* dan *transparency* dari metode *local explanation* yang lebih teknis beserta turunannya seperti *attribution* dan *saliency* (Kadir, Mosavi, dan Sonntag 2023).




Gambar II.5 Taksonomi berdasarkan aplikasi XAI (Kadir, Mosavi, dan Sonntag 2023)

2. Taksonomi Berbasis Metodologi Evaluasi

Taksonomi berbasis metodologi evaluasi mengklasifikasikan teknik-teknik evaluasi penjelasan lokal ke dalam tiga pendekatan teknis utama, yaitu *retraining*, *ground truth comparison*, dan *input perturbation* (Kadir, Mosavi, dan Sonntag 2023).

Dalam pendekatan *ground truth comparison*, terdapat penelitian terbaru oleh Muhammad dan Bendeche (2025) yang mengusulkan metrik evaluasi kuantitatif bernama XAlign. Metrik ini dirancang untuk mengatasi keterbatasan metrik yang tumpang tindih standar dengan menilai *spatial fidelity heatmap*



Gambar II.6 Taksonomi berdasarkan metodologi evaluasi (Kadir, Mosavi, dan Sonntag 2023)

melalui tiga komponen integratif yang diformulasikan sebagai berikut.

(a) *Weighted Relevance Overlap* (WRO)

Komponen ini mengukur proporsi relevansi penjelasan yang terlokalisasi secara tepat di dalam area anotasi ahli. Semakin tinggi nilai WRO, semakin fokus penjelasan tersebut pada area klinis yang relevan. Secara matematis, WRO didefinisikan seperti pada Persamaan II.1:

$$WRO = \frac{\sum_{i \in G} X_i}{\sum_i X_i} \quad (II.1)$$

G merepresentasikan himpunan piksel dalam masker *ground truth*. X_i adalah skor relevansi intensitas *heatmap* pada piksel ke- i .

(b) *Boundary Agreement Score* (BAS)

BAS menilai ketepatan penyelarasan struktural antara batas *heatmap* dengan kontur lesi atau tumor menggunakan *Hausdorff Distance* yang dinormalisasi, seperti yang ditunjukkan pada Persamaan II.2:

$$BAS = 1 - \frac{HD(G, X)}{\max_dim(I)} \quad (II.2)$$

$HD(G, X)$ adalah jarak Hausdorff antara kontur *ground truth* (G) dan peta penjelasan (X). $\max_dim(I)$ adalah dimensi maksimum citra untuk normalisasi. Nilai BAS yang mendekati 1 mengindikasikan korespondensi anatomis yang presisi.

(c) *Dispersion Penalty* (DP)

Komponen ini memberikan penalti terhadap penyebaran atribusi di luar area klinis untuk memastikan peta *saliency* tetap ringkas, dengan formulasi pada Persamaan II.3:

$$DP = \frac{\sum_{i \notin G} X_i}{\sum_i X_i} \quad (\text{II.3})$$

$i \notin G$ menunjukkan piksel yang berada di luar area *ground truth*. Nilai DP yang lebih rendah menandakan penjelasan yang lebih fokus dengan sedikit *noise* latar belakang.

Secara keseluruhan, skor akhir XAlign dihitung dengan menggabungkan ketiga komponen tersebut menggunakan bobot skalar (α, β, γ) seperti pada Persamaan II.4:

$$XAlign = \alpha \cdot WRO + \beta \cdot BAS - \gamma \cdot DP \quad (\text{II.4})$$

Penggunaan XAlign memungkinkan evaluasi yang tidak hanya mengukur akurasi lokasi, tetapi juga kepatuhan bentuk penjelasan terhadap anatomi tumor yang sebenarnya (Muhammad dan Bendeche 2025).

Untuk menentukan metrik evaluasi XAI, prosesnya dimulai dengan mengidentifikasi konsep yang akan diuji menggunakan taksonomi berbasis aplikasi. Taksonomi ini membantu membedakan apakah tujuannya adalah untuk mengukur konsep umum seperti *user satisfaction* dan *transparency*, atau untuk mengevaluasi penjelasan teknis yang lebih spesifik seperti *local explanation*, yang mencakup metode seperti *saliency*. Setelah itu, taksonomi berbasis metodologi evaluasi digunakan untuk memilih pendekatan teknis yang sesuai untuk mengevaluasi penjelasan lokal tersebut (Kadir, Mosavi, dan Sonntag 2023).

II.5 Penelitian Terkait

II.5.1 *Explainable CNN for brain tumor detection and classification through XAI based key features identification*

Penelitian terbaru yang dilakukan oleh Iftikhar dkk. (2025b) mengajukan pendekatan *explainable CNN* untuk klasifikasi tumor otak guna mengatasi sifat *black-box* pada model *deep learning* yang sering kali menghambat transparansi klinis. Penelitian ini menyoroti bahwa kompleksitas struktur model yang berlebihan sering kali menyebabkan model bergantung pada fitur yang tidak relevan, seperti jaringan lunak normal, yang menurunkan kepercayaan terhadap hasil diagnosis. Untuk mengatasi

hal tersebut, Iftikhar dkk. (2025b) mengembangkan metodologi yang mengintegrasikan teknik *Explainable AI* (XAI), khususnya *Gradient-weighted Class Activation Mapping* (Grad-CAM), *Shapley Additive Explanations* (SHAP), dan *Local Interpretable Model-agnostic Explanations* (LIME) ke dalam arsitektur CNN. Inovasi utama dalam penelitian ini adalah pemanfaatan analisis Grad-CAM untuk menyederhanakan arsitektur model dengan memangkas *layer* yang memiliki kontribusi minimal terhadap keputusan prediksi sehingga menghasilkan model yang lebih efisien tanpa mengorbankan akurasi.

Evaluasi performa dilakukan menggunakan *dataset* MRI publik dengan empat kelas klasifikasi, yaitu *meningioma*, *glioma*, *pituitary*, dan *no tumor*. Hasil penelitian menunjukkan bahwa model berbasis XAI yang diusulkan mampu mencapai akurasi sebesar 99,21% pada *dataset* latih dan 94,72% pada data uji yang belum pernah dilihat. Evaluasi juga menunjukkan keseimbangan yang baik antara presisi dan *recall*. Secara kualitatif, visualisasi XAI membuktikan bahwa model mampu memfokuskan perhatian pada area patologis yang spesifik berbeda dengan model awal tanpa XAI yang perhatiannya sering tersebar ke area tanpa tumor.

Studi dari Iftikhar dkk. (2025b) memiliki keterbatasan karena hanya berfokus pada modalitas pencitraan MRI yang saat ini menjadi permasalahan di Indonesia. Para peneliti secara eksplisit menyarankan penelitian masa depan untuk menguji efektivitas metode serupa pada modalitas lain, seperti *CT Scan* untuk memperluas jangkauan diagnostik. Celah penelitian menjadi salah satu landasan bagi tugas akhir ini untuk menerapkan integrasi XAI pada citra *CT Scan*, yang memiliki tantangan karakteristik citra berbeda dibandingkan MRI untuk menyediakan solusi diagnostik yang terpercaya di fasilitas kesehatan dengan keterbatasan alat MRI.

II.5.2 *Enhanced Classification of Brain MRI Images for Tumor Detection Using Transfer Learning and Grad-CAM-Based Explainable CNN*

Penelitian yang dilakukan oleh Putra dkk. (2025) mengusulkan kerangka kerja *deep learning* yang menggabungkan *transfer learning* dari model EfficientNet-B0 dengan metode *Explainable AI* (XAI) berbasis Grad-CAM untuk klasifikasi dan deteksi tumor otak. Penelitian ini secara khusus menyoroti pentingnya tahapan *preprocessing* yang dioptimalkan untuk meningkatkan kualitas representasi visual citra masukan sebelum proses ekstraksi fitur dilakukan. Rangkaian *preprocessing* yang diimplementasikan meliputi pengubahan ukuran citra (*resizing*) menjadi 224x224 piksel untuk menyesuaikan dengan arsitektur dasar EfficientNet-B0, serta normalisasi nilai intensitas piksel ke rentang [0,1] guna menstabilkan pembaruan gradien

selama proses pelatihan. Sebagai langkah optimasi utama, teknik *Contrast Limited Adaptive Histogram Equalization* (CLAHE) diterapkan untuk meningkatkan kontras lokal dan mempertegas batas-batas tumor, yang dikombinasikan dengan *Gaussian filtering* untuk meredam derau (*denoising*) frekuensi tinggi pada tekstur MRI. Pendekatan ini selanjutnya diperkuat oleh augmentasi data secara probabilistik, seperti rotasi, *flipping*, *zooming*, dan variasi kecerahan, yang secara signifikan memperluas keberagaman *dataset* latih untuk mencegah terjadinya *overfitting*.

Evaluasi performa dilakukan menggunakan *dataset* MRI publik yang terdiri dari 3.000 citra dengan empat kelas kategori: *glioma*, *meningioma*, *pituitary*, dan *no tumor*. Hasil eksperimen membuktikan bahwa integrasi alur *preprocessing* tersebut dengan EfficientNet-B0 mampu mencapai tingkat akurasi sebesar 94,2% dan nilai AUC 0,965, yang secara signifikan mengungguli model CNN *baseline*. Dari segi transparansi pengambilan keputusan, penggunaan visualisasi Grad-CAM mengonfirmasi bahwa model mampu memfokuskan atensinya (ditunjukkan dengan *heatmap* berintensitas tinggi) pada area lesi tumor secara tepat tanpa mengandalkan artefak latar belakang yang tidak relevan secara klinis.

Meskipun model dari Putra dkk. (2025) mencapai tingkat akurasi dan interpretabilitas yang tinggi, pengujian masih terbatas pada ruang lingkup citra MRI 2D independen dan masih dihadapkan pada tantangan variasi perangkat antar-institusi medis. Ketergantungan eksklusif pada modalitas MRI ini memvalidasi urgensi dan celah penelitian yang diangkat dalam tugas akhir ini, yaitu perancangan sistem pendukung keputusan deteksi tumor otak berbasis XAI yang diterapkan pada citra *CT Scan*. Eksplorasi pada data *CT Scan* akan mengevaluasi seberapa efektif metode *preprocessing* (seperti CLAHE dan reduksi derau) serta ekstraksi fitur visual beradaptasi dengan profil intensitas jaringan yang berbeda pada *CT Scan*, guna memperluas dan menyediakan alternatif diagnosis otomatis yang dapat dipercaya untuk mengatasi keterbatasan aksesibilitas alat MRI di berbagai fasilitas kesehatan.

II.5.3 Performance Evaluation of Preprocessing Techniques for Noise Reduction and Enhancement in MRI-based Brain Tumor Detection

Penelitian yang dilakukan oleh Flower dan Leo (2025) mengevaluasi efektivitas berbagai metode pra-pemrosesan yang secara khusus dirancang untuk meningkatkan kualitas citra medis, khususnya MRI, dalam mendeteksi tumor otak. Studi ini menyoroti bahwa citra mentah (*raw images*) sering kali mengalami degradasi kualitas akibat derau (*noise*), tingkat kontras yang rendah, serta keberadaan artefak. Gangguan-gangguan tersebut dapat menyulitkan proses interpretasi dan menurunkan

an keandalan algoritma deteksi maupun segmentasi. Untuk mengatasi tantangan tersebut, penelitian ini membandingkan teknik reduksi derau, yang meliputi filter *Gaussian*, *median*, *Non-Local Means* (NLM), dan *wavelet*, dengan teknik peningkatan kualitas citra (*image enhancement*), yaitu *Histogram Equalization* (HE), *Contrast Limited Adaptive Histogram Equalization* (CLAHE), dan normalisasi intensitas.

Evaluasi performa dari teknik-teknik pra-pemrosesan ini diukur menggunakan *dataset* publik yang mencakup empat kelas diagnosis: *glioma*, *meningioma*, *pituitary tumor*, dan *no-tumor*. Penilaian dilakukan secara kuantitatif bersandar pada metrik *Mean Squared Error* (MSE), *Peak Signal-to-Noise Ratio* (PSNR), *Structural Similarity Index* (SSIM), dan *Noise Power Spectrum* (NPS). Hasil analisis membuktikan bahwa filter *wavelet* adalah metode paling unggul untuk mereduksi derau, karena teknik dekomposisi frekuensinya mampu menghilangkan derau sambil tetap mempertahankan struktur dan tepi (*edges*) area tumor secara optimal. Di sisi peningkatan kualitas, normalisasi intensitas terbukti superior karena mampu menstandarkan rentang intensitas piksel di seluruh *dataset*, sehingga mengurangi variabilitas yang diakibatkan oleh pengaturan pemindai (*scanner*) yang berbeda-beda. Kombinasi dari filter *wavelet* dan normalisasi intensitas disimpulkan sebagai *pipeline* pra-pemrosesan yang paling optimal untuk menghasilkan citra yang konsisten dan berkualitas tinggi.

Meskipun kajian dari Flower dan Leo (2025) diimplementasikan pada modalitas MRI, prinsip rancangan *pipeline* pra-pemrosesan ini dapat diekstrapolasi untuk modalitas pencitraan lain seperti *CT Scan*. Menerapkan teknik reduksi derau yang mampu menjaga detail anatomis dipadukan dengan standardisasi intensitas sangat esensial untuk menyiapkan citra *CT Scan* sebelum masuk ke tahap analisis lebih lanjut. Pendekatan pra-pemrosesan yang komprehensif ini menjadi fondasi krusial ketika mengintegrasikan metode *Explainable AI* (XAI) ke dalam sistem pendukung keputusan. Dengan citra masukan yang bersih dan terstandarisasi, metode visualisasi seperti *Grad-CAM* dapat lebih akurat dalam menyoroti fitur patologis yang sebenarnya dari tumor otak, tanpa terdistraksi oleh artefak maupun inkonsistensi kontras visual.

II.5.4 *CT to MRI Image Translation Using CycleGAN: A Deep Learning Approach for Cross-Modality Medical Imaging*

Dalam upaya menjembatani keterbatasan modalitas pencitraan medis, Jha2024CTtoMRI<empty citation> melakukan penelitian yang berfokus pada translasi citra *CT Scan* menjadi citra yang menyerupai *Magnetic Resonance Imaging* (MRI). Penelitian ini dilatarbelakangi

oleh paradoks bahwa MRI menawarkan kontras jaringan lunak yang sangat baik namun proses pemindaianya lambat dan mahal, sedangkan *CT Scan* jauh lebih cepat namun melibatkan paparan radiasi pengion. Oleh karena itu, penelitian ini bertujuan mengembangkan model *deep learning* menggunakan arsitektur CycleGAN untuk men-translasi *CT Scan* menjadi citra menyerupai MRI. Pendekatan ini diharapkan dapat menghilangkan kebutuhan biaya tambahan dan paparan radiasi ganda bagi pasien.

Metodologi yang diterapkan melibatkan penggunaan *dataset* citra potongan lintang otak untuk CT dan MRI yang tidak berpasangan (*unpaired*). Pemrosesan awal data mencakup penyesuaian dimensi citra menjadi 256×256 piksel, penskalaan nilai piksel ke rentang $[-1, 1]$, serta penerapan augmentasi data untuk menekan risiko *overfitting*. Inovasi utama dalam arsitektur studi ini adalah pemanfaatan *cycle consistency loss* pada CycleGAN, yang memastikan citra dapat ditranslasi antar domain dan dikembalikan ke bentuk aslinya tanpa kehilangan fidelitas anatomis. Proses ini didukung oleh komponen generator yang terdiri dari *Encoder-Transformer-Decoder* dan diskriminator berbasis arsitektur *PatchGAN*.

Hasil penelitian menunjukkan bahwa model CycleGAN yang diusulkan sangat efektif, mencapai nilai evaluasi *Mean Absolute Error* (MAE) sebesar 0,5309, *Mean Squared Error* (MSE) 0,37901, dan *Peak Signal-to-Noise Ratio* (PSNR) 52,344. Angka-angka ini secara signifikan melampaui performa model CNN dasar (*baseline*) yang kesulitan menangani *dataset* tidak berpasangan. Secara kualitatif, citra MRI sintetis yang dihasilkan terbukti mampu merepresentasikan anatomi otak secara keseluruhan dengan baik, mencakup visualisasi yang jelas pada materi abu-abu, materi putih, cairan serebrospinal, hingga pembuluh darah utama. Meskipun demikian, para peneliti memberikan catatan penting bahwa citra sintetis ini masih kehilangan beberapa detail presisi sehingga belum dapat digunakan secara mentah untuk diagnosis klinis tanpa pertimbangan matang.

Studi ini memberikan landasan teknis yang sangat relevan untuk mengeksplorasi translasi citra lintas modalitas sebagai tahapan pra-pemrosesan diagnostik. Keberhasilan **Jha2024CTtoMRI** dalam menyintesis citra MRI dari *CT Scan* otak secara khusus mendukung gagasan bahwa mengubah set data *CT Scan* menjadi MRI sintetis berpotensi mengatasi keterbatasan kontras jaringan lunak pada citra aslinya. Pendekatan ini selaras dengan upaya deteksi tumor otak, di mana pengintegrasian teknik *Explainable AI* seperti Grad-CAM ke dalam citra sintetis dengan visibilitas struktur jaringan yang lebih baik diestimasi mampu menghasilkan

an visualisasi (*heatmap*) penentuan keputusan model yang jauh lebih representatif. Peningkatan kualitas representasi batas anatomis pada tahap pra-pemrosesan ini diharapkan dapat mempermudah model identifikasi dalam menyorot pola abnormal akibat tumor secara lebih transparan dan efisien.

II.5.5 *Explainable AI for lung cancer detection via a custom CNN on CT images*

Dalam upaya mengatasi tantangan diagnosis medis berbasis kecerdasan buatan yang sering kali bersifat *black-box*, Hammad dkk. (2025) melakukan penelitian yang berfokus pada deteksi kanker paru menggunakan citra *CT Scan*. Penelitian ini dilatarbelakangi oleh permasalahan bahwa analisis manual citra CT memakan waktu dan rentan kesalahan, sementara model *deep learning* sering kali gagal memberikan alasan di balik keputusan prediksi mereka sehingga mengurangi kepercayaan tenaga medis. Oleh karena itu, penelitian ini bertujuan mengembangkan sebuah model *custom Convolutional Neural Network* (CNN) yang tidak hanya memiliki akurasi tinggi, tetapi juga dilengkapi dengan fitur transparansi melalui integrasi teknik *Explainable AI* (XAI).

Metodologi yang diterapkan melibatkan penggunaan *dataset* citra *CT Scan* yang melalui proses pra-pemrosesan dan augmentasi data untuk meningkatkan generalisasi model. Inovasi utama dalam studi ini adalah penerapan metode *Gradient-weighted Class Activation Mapping* (Grad-CAM) untuk menghasilkan *heatmap* visual. Visualisasi ini berfungsi untuk menyoroti area spesifik pada citra CT yang dianggap penting oleh model dalam menentukan klasifikasi sehingga dokter dapat memverifikasi apakah model berfokus pada fitur patologis yang relevan atau sekadar *noise*.

Hasil penelitian menunjukkan bahwa model yang diusulkan mampu mencapai akurasi keseluruhan sebesar 93,06% dengan presisi dan *recall* yang seimbang di berbagai kelas klasifikasi. Secara kualitatif, hasil visualisasi Grad-CAM mendemonstrasikan bahwa model secara akurat memusatkan perhatian pada batas tumor dan struktur jaringan abnormal, yang selaras dengan diagnosis klinis. Temuan ini mengonfirmasi bahwa integrasi XAI sangat krusial dalam mengubah model *deep learning* menjadi alat bantu diagnosis yang transparan dan dapat diandalkan.

Studi ini memberikan landasan yang dapat memperkuat penelitian ini, khususnya dalam memvalidasi kelayakan penggunaan citra *CT Scan* sebagai *input* utama untuk sistem deteksi berbasis AI. Keberhasilan Hammad dkk. (2025) dalam menggunakan XAI dapat mempersempit kesenjangan kepercayaan antara sistem AI dan ahli radiologi mendukung hipotesis penelitian ini bahwa pendekatan serupa dapat diterapkan secara efektif pada deteksi tumor otak. Selain itu, penggunaan arsitektur model yang

efisien dalam penelitian tersebut sejalan dengan tujuan penggunaan *Correlation Learning Mechanism* (CLM) dalam penelitian ini, yaitu untuk menyediakan solusi diagnostik yang akurat, efisien, dan transparan di tengah keterbatasan fasilitas MRI di Indonesia.

II.5.6 Evaluasi Klinis dan Integrasi Alur Kerja AI dalam Radiologi Diagnostik

Dalam pengembangan model *Explainable AI* (XAI) untuk deteksi tumor pada citra CT-Scan, penting untuk tidak hanya mengevaluasi metrik teknis dari algoritma, tetapi juga bagaimana model tersebut dapat dioperasionalkan di dunia nyata. Mengingat implementasi AI di bidang medis telah terbukti secara efektif, penelitian (Vimallesvaran dkk. 2024) menawarkan kerangka kerja penting mengenai pembuktian efektivitas AI dalam alur kerja klinis. Melalui studi ACCEPT-AI, penelitian tersebut merancang uji coba acak klaster (*stepped-wedge cluster randomised trial*) untuk mengevaluasi perangkat lunak qER dari Qure.ai dalam memprioritaskan interpretasi CT-Scan kepala tanpa kontras di Instalasi Gawat Darurat.

Kaitan utama studi ini dengan pengembangan XAI untuk deteksi lesi atau tumor terletak pada presentasi luaran visual dari AI tersebut kepada tenaga medis. Alur pengujian dalam studi ini dibagi menjadi tiga fase berurutan: pra-implementasi, implementasi, dan pasca-implementasi. Pada fase pasca-implementasi, alur kerja AI diintegrasikan secara langsung dengan sistem rumah sakit tanpa mengubah urutan kasus secara fundamental, melainkan dengan memberikan penanda prioritas (*prioritised flag*) di dalam *Radiology Information System* (RIS).

Alur penggunaan qER bagi dokter berjalan sebagai berikut:

1. Ketika seorang radiolog membuka sebuah kasus dengan penanda prioritas di RIS, sistem akan menyediakan tangkapan sekunder (*secondary capture*) dari qER yang ditampilkan berdampingan dengan citra asli di dalam *Picture Archiving and Communication System* (PACS).
2. Tangkapan sekunder ini pada dasarnya berfungsi layaknya fitur interpretasi XAI, di mana sistem menampilkan kontur visual yang secara spesifik menunjukkan titik perhatian (*attention point*) algoritma terhadap suatu abnormalitas (misalnya efek massa / *mass effect* yang relevan dengan indikasi tumor).
3. Pada tahap pelaporan, radiolog tetap memegang kendali penuh atas diagnosis akhir. Mereka menggunakan pertimbangan klinis mereka sendiri untuk menyetujui temuan visual AI tersebut, memodifikasinya, atau mengabaikannya sebelum menulis dan menandatangani laporan.

Pendekatan operasional ini memberikan perspektif bahwa luaran model AI berkiner-


ja tinggi harus dirancang sebagai alat pendukung keputusan klinis, bukan sebagai pengganti penilaian ahli. Untuk pengembangan model XAI deteksi tumor, artikel ini menggarisbawahi bahwa efektivitas model tidak hanya diukur dari seberapa baik ia menyoroti area lesi secara terpusat, tetapi juga dari kemudahan interaksinya (seperti integrasi tangkapan sekunder berkontur ke dalam PACS) agar radiolog dapat memvalidasi penjelasan AI tersebut dengan cepat dan menurunkan waktu tunggu pelaporan.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Penelitian oleh Woźniak, Siłka, dan Wieczorek (2021) mengusulkan sebuah pendekatan hibrida yang dinamakan *Correlation Learning Mechanism* (CLM). Model ini mengintegrasikan *Convolutional Neural Network* (CNN) dengan *Artificial Neural Network* (ANN) klasik dalam satu arsitektur terpadu untuk mendeteksi tumor otak dari citra *CT Scan*.



Gambar III.1 Visualisasi mekanisme *Correlation Learning Mechanism* (CLM) (Woźniak, Siłka, dan Wieczorek 2021)

III.1.1 Desain Sistem dan Mekanisme Kerja

Sistem yang dikembangkan bekerja secara siklis dan iteratif dengan memanfaatkan pemrosesan paralel (*multi-threading*). Berdasarkan Gambar III.1, alur kerja sistem saat ini adalah sebagai berikut:

1. Segmentasi *Input*

Citra *CT Scan* otak dimasukkan ke dalam sistem dan disegmentasi menjadi 64 fragmen persegi. Jumlah fragmen ini dipilih secara spesifik untuk menyesuaikan dengan arsitektur CPU yang digunakan dalam penelitian tersebut guna menjaga keseimbangan antara kecepatan pembelajaran dan diversitas filter (Woźniak, Siłka, dan Wieczorek 2021).

2. Mekanisme Palet Filter

Fitur unik dari desain ini adalah penggunaan ”palet filter” pada CNN. Palet ini merupakan konfigurasi dinamis yang menentukan lapisan, jenis filter, dan operasi (seperti *pooling* dan ReLU). Pada iterasi awal, filter dipilih secara acak dari *pool* filter yang tersedia, namun pada iterasi selanjutnya, pemilihan filter diatur oleh mekanisme CLM berdasarkan umpan balik akurasi (Woźniak, Siłka, dan Wieczorek 2021).

3. Integrasi CNN-ANN

CNN memproses fragmen gambar menggunakan palet yang terpilih. *Output* dari CNN tidak hanya berupa *feature maps*, tetapi juga dikonversi menjadi vektor deskripsi statistik numerik yang mencakup nilai minimum, maksimum, rata-rata aritmetika, jumlah, median, dan standar deviasi.

4. Evaluasi dan Umpan Balik

ANN bertindak sebagai evaluator. Data statistik dan fitur dari CNN menjadi *input* bagi ANN untuk menghasilkan keputusan biner (tumor/sehat). Jika efisiensi ANN rendah, sistem melakukan pengacakan ulang (*reshuffling*) pada palet filter CNN untuk iterasi berikutnya. Palet yang menghasilkan *loss* terendah dan akurasi tertinggi disimpan dalam arsip basis data untuk digunakan kembali.

III.1.2 Peran Model

Dalam arsitektur hibrida ini, masing-masing model memiliki peran spesifik yang saling bergantung:

1. *Convolutional Neural Network* (CNN)

CNN berperan sebagai ekstraktor fitur yang adaptif. CNN tidak memiliki bobot filter yang statis seperti pada CNN konvensional, melainkan belajar untuk memilih kombinasi filter yang paling relevan untuk menonjolkan fitur tumor berdasarkan instruksi dari mekanisme korelasi. CNN juga bertugas menyederhanakan informasi visual kompleks menjadi deskripsi statistik yang lebih ringkas untuk diproses oleh ANN.

2. *Artificial Neural Network* (ANN)

ANN berperan sebagai *classifier* dan pengendali optimasi. ANN tidak hanya mengklasifikasikan keberadaan tumor, tetapi juga berfungsi sebagai mekanis-

me umpan balik bagi CNN. Performa ANN menjadi penentu apakah konfigurasi filter CNN saat ini harus dipertahankan atau diganti. Struktur ANN yang digunakan adalah *fully connected layers* dengan arsitektur yang dipilih untuk melakukan kompresi data akhir.

III.1.3 Kelemahan dan Keterbatasan Sistem

Model CLM yang diusulkan mampu mencapai akurasi tinggi hingga 96% tetapi terdapat beberapa kelemahan dan keterbatasan yang menjadi celah pengembangan sebagai berikut (Woźniak, Siłka, dan Wieczorek 2021).

1. Keterbatasan Kontrol Bobot Filter

Dalam bagian *future works*, peneliti mengakui bahwa sistem saat ini belum menerapkan pembobotan khusus (*special weights*) pada filter di lapisan CNN. Hal ini membatasi kemampuan sistem untuk mengontrol proses penyaringan secara lebih halus agar *feature maps* dapat menonjolkan objek kunci dengan lebih detail.

2. Ketergantungan pada Iterasi Tetap

Proses optimasi dan pelatihan dilakukan dalam jumlah iterasi yang tetap, seperti 120.000 iterasi atau seratus iterasi per *batch* dalam algoritma *multi threading*) sehingga prosesnya tidak dinamis seperti fungsi *fitness*. Hal ini berpotensi menyebabkan inefisiensi waktu komputasi atau konvergensi yang belum optimal (Woźniak, Siłka, dan Wieczorek 2021).

3. Kurangnya Aspek *Explainability* (XAI)

Pada sistem ini, hanya terdapat kotak merah yang tidak menandai otak secara keseluruhan yang memiliki tumor otak. Selain hal tersebut, sistem ini belum menerapkan metode *Explainable AI* (XAI) yang mendalam untuk menjelaskan mengapa keputusan tersebut diambil. Interaksi antara statistik numerik dari CNN dan keputusan ANN masih bersifat *black-box*, tanpa visualisasi kontribusi fitur yang mendetail, seperti *heatmap* atau nilai SHAP untuk mendukung diagnosis klinis yang transparan.

III.2 Analisis Kebutuhan

Berdasarkan referensi studi literatur mengenai tinjauan komprehensif tentang tantangan dan arahan masa depan *Artificial Intelligence* di layanan kesehatan oleh Ennab dan Mcheick (2024) dan tinjauan mengenai permasalahan *black-box* berdasarkan prinsip etika “*do no harm*” oleh Xu dan Shuttleworth (2023), terdapat permasalahan yang ada di sistem *deep learning* oleh Woźniak, Siłka, dan Wieczorek (2021), yaitu ketiadaan keterangan atau penjelasan mengenai *black-box* dari *deep learning* untuk mengetahui bagian mana yang terdeteksi tumor otak.

III.2.1 Identifikasi Masalah Pengguna

Terdapat dua kelompok pengguna utama yang menghadapi masalah terkait penerapan AI dalam medis, yaitu profesional medis (dokter dan radiolog) serta pasien. Bagi profesional medis, tantangan utamanya tidak hanya terletak pada adopsi teknologi baru, tetapi juga pada keterbatasan manusiawi dan beban kerja yang ekstrem dalam praktik klinis. Berdasarkan Zhang dkk. (2023), tingkat kesalahan diagnostik dalam radiologi berkisar antara 10-26% dengan 60-80% kesalahan diklasifikasikan sebagai kesalahan perseptual atau kegagalan dalam mendeteksi adanya lesi. Faktor kelelahan turut berperan signifikan dengan survei mencatat 47% radiolog mengalami *burnout* dan 58% mengalami gejala fisik seperti kelelahan mata yang dapat mengganggu akurasi interpretasi.

Di Indonesia, masalah ini menjadi jauh lebih kritis akibat ketimpangan rasio tenaga medis. Data analisis pasar layanan radiologi mencatat bahwa Indonesia hanya memiliki sekitar 2.161 radiolog terdaftar untuk melayani populasi sebesar 277 juta jiwa, atau setara dengan rasio 1,2 radiolog per 100.000 penduduk (Insights10 2023). Kondisi kekurangan SDM ini secara langsung meningkatkan beban kerja radiolog, yang berpotensi memperparah risiko *burnout* dan kesalahan diagnosis. Selain itu, profesional medis juga menghadapi masalah rendahnya kepercayaan terhadap keandalan sistem AI. Masalah ini berakar dari kurangnya edukasi, pelatihan, dan minimnya keterlibatan mereka dalam proses pengembangan sistem (Syafthan 2025). Hal ini menciptakan paradoks bahwa teknologi yang sangat dibutuhkan untuk mengurangi *human error* justru diragukan validitasnya oleh penggunanya sendiri.

Dari sisi pasien, tantangan utama yang menghambat adopsi *Artificial Intelligence* (AI) dalam praktik klinis adalah kurangnya kepercayaan terhadap validitas diagnosis yang melibatkan algoritma. Berbeda dengan asumsi umum bahwa teknologi canggih akan meningkatkan rasa aman pasien, literatur terbaru justru menunjukkan fenomena sebaliknya, yaitu keterlibatan AI sering kali dipersepsikan sebagai faktor yang mendegradasi kualitas layanan medis. Riset eksperimental terbaru yang dilakukan oleh Chen dan Cui (2025) memberikan bukti bahwa kepercayaan pasien terhadap dokter dan intensi untuk melakukan pengobatan mencapai titik tertinggi justru ketika dokter secara eksplisit menyatakan tidak menggunakan AI dalam proses diagnosisnya dengan skor rata-rata kepercayaan 0,63. Sebaliknya, ketika pasien mengetahui bahwa dokter menggunakan AI secara ekstensif, tingkat kepercayaan mereka menurun ke angka 0,30 (Chen dan Cui 2025). Hal ini mengindikasikan bahwa di mata pasien, penggunaan AI belum dianggap sebagai peningkatan kapabilitas diagnostik, melainkan sebagai substitusi yang mengurangi nilai keahlian manusia.

Penurunan kepercayaan ini bukan tanpa alasan. Skeptisisme pasien berakar pada beberapa kekhawatiran fundamental. Pertama, risiko halusinasi AI, seperti model generatif dapat memproduksi informasi medis yang terdengar masuk akal dan meyakinkan tetapi secara faktual salah atau dibuat-buat. Ketakutan akan diagnosis yang keliru akibat kesalahan algoritma ini menjadi penghalang psikologis utama. Kedua, masalah transparansi dan akuntabilitas. Pasien sering kali memandang AI sebagai *black-box* yang proses pengambilan keputusannya tidak dapat dijelaskan secara intuitif, memicu keraguan apakah keputusan medis tersebut didasarkan pada kondisi unik pasien atau sekadar pola statistik semata (Chen dan Cui 2025). Selain itu, terdapat korelasi negatif antara persepsi profesionalisme dan penggunaan AI. Pasien cenderung mempertanyakan kompetensi dan penilaian klinis dokter yang terlalu bergantung pada alat bantu AI, terutama jika alat tersebut bersifat umum dan tidak dirancang khusus untuk medis. Penggunaan alat semacam ini dianggap mengaburkan batas tanggung jawab profesional dan menurunkan standar interaksi manusiawi yang menjadi inti dari layanan kesehatan (Chen dan Cui 2025). Temuan ini menegaskan bahwa diperlukan transparansi, validasi klinis yang ketat, dan jaminan pengawasan manusia untuk mengatasi ketidakpercayaan pasien.

Untuk mengatasi masalah tersebut, perlu didefinisikan kebutuhan fungsional dan nonfungsional sistem. Rincian kebutuhan ini akan dijabarkan pada subbab berikutnya.

III.2.2 Kebutuhan Fungsional

Berdasarkan analisis kebutuhan, kebutuhan fungsional sistem yang diinginkan adalah sebagai berikut.

1. Sistem harus dapat menerima *input* data berupa citra digital *CT Scan* otak dengan format umum medis berupa DICOM.
2. Sistem harus mampu melakukan segmentasi citra menjadi fragmen-fragmen untuk persiapan ekstraksi fitur.
3. Sistem harus mampu mengklasifikasikan citra *input* ke dalam dua kelas keputusan, yaitu tumor atau sehat.
4. Sistem harus memiliki modul yang menampilkan matriks performa model yang telah tervalidasi untuk menilai performa kuantitatif dari sistem.
5. Sistem harus menghasilkan visualisasi interpretasi keputusan model menggunakan metode *Explainable AI* (XAI) untuk menyoroti area fitur pada citra yang dianggap indikatif terhadap tumor.
6. Sistem harus menampilkan tingkat kepercayaan dari hasil prediksi untuk membantu tenaga medis dalam menilai validitas keputusan sistem dan membangun

kepercayaan pengguna.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional sistem adalah sebagai berikut.

1. *Interpretability*

Sistem harus mampu menyediakan transparansi atas keputusan yang diambil. Berbeda dengan sistem sebelumnya yang bersifat *black-box*, sistem yang diusulkan harus memvisualisasikan area fokus, seperti penggunaan *heatmap* yang menjadi dasar prediksi tumor. Hal ini bertujuan untuk menjawab keraguan pasien akan validitas diagnosis AI dan membantu profesional medis memverifikasi hasil tanpa harus mempercayai algoritma secara buta.

2. *Reliability*

Sistem harus memiliki tingkat konsistensi yang tinggi dalam memberikan hasil prediksi. Mengingat risiko kesalahan diagnostik radiologi berkisar antara 10-26%, sistem diharapkan dapat mempertahankan atau melampaui akurasi model referensi (96%).

3. *Efficiency*

Waktu komputasi untuk memproses satu citra *input* hingga menghasilkan diagnosis dan visualisasi harus memiliki waktu yang singkat agar tidak menghambat alur kerja klinis.

III.3 Analisis Pemilihan Solusi

Pada bagian ini, dilakukan analisis kebutuhan untuk menentukan solusi yang paling tepat dalam mengatasi permasalahan *black-box* pada model AI. Tahapan analisis ini mencakup identifikasi dan pemaparan berbagai alternatif solusi dan menggunakan metodologi AHP untuk mengevaluasi dan memilih solusi terbaik dari alternatif tersebut.

III.3.1 Alternatif Solusi

Alternatif solusi yang dapat diberikan dalam permasalahan tersebut terbagi menjadi dua, yaitu penggunaan metode XAI pada infrastruktur yang sama dan penggunaan model yang berbeda untuk mencegah terjadinya *black-box* pada AI.

Alternatif solusi pertama fokus pada penerapan metode XAI yang dapat menyelesaikan masalah *black-box*, khususnya dalam konteks *computer vision* (*CT scan*) dan model CNN yang sudah ada. Penjelasan mendalam mengenai metode-metode berikut dapat dilihat pada Bab II.3.1, Subbab Metode *Explainable AI* (XAI).

1. *Attribution-based methods*

Attribution-based methods memberi nilai pada setiap bagian masukan gambar.

Bagian yang paling memengaruhi keputusan akhir akan mendapat nilai tinggi. Hal ini dapat membantu penggunaannya untuk melihat area mana pada gambar yang paling penting bagi AI. Alternatif solusi yang menggunakan *attribution-based methods* adalah sebagai berikut.

- (a) *Gradient-weighted Class Activation Mapping* (Grad-CAM)
- (b) FullGrad-CAM dan FullGrad-CAM++
- (c) *SmoothGrad*

2. *Transformer-based methods* *Transformer-based methods* memanfaatkan mekanisme *attention* bawaan pada arsitektur *Vision Transformer* (ViT). Teknik ini membagi gambar menjadi beberapa *patch* dan memvisualisasikan skor atensinya menjadi peta yang menyoroti area paling krusial dalam pengambilan keputusan model (Iftikhar dkk. 2025a).

Selain mengevaluasi berbagai metode XAI untuk disematkan pada arsitektur *deep learning* yang ada, analisis ini juga memperhitungkan alternatif penggunaan model yang berbeda secara mendasar, seperti model *machine learning* konvensional. Perbandingan komprehensif antara pendekatan *deep learning* berbasis XAI dengan model konvensional (baik yang bersifat *white-box* maupun *black-box*) diperlukan untuk membuktikan efektivitas dan urgensi dari solusi yang diusulkan dalam tugas akhir ini.

Analisis penentuan solusi yang digunakan pada tugas akhir ini menggunakan *Analytic Hierarchy Process* (AHP). AHP adalah metode pengambilan keputusan yang digunakan oleh individu atau organisasi untuk melakukan pemeringkatan alternatif yang mereka pertimbangkan berdasarkan perbandingan berpasangan. *Analytic Hierarchy Process* (AHP) melibatkan lima langkah utama. Pertama, menyusun hierarki masalah keputusan ke dalam tiga tingkatan, yaitu tujuan, kriteria, dan alternatif. Kedua, melakukan perbandingan berpasangan untuk kriteria guna menilai kepentingan relatifnya menggunakan skala sembilan poin, mulai dari rasio 1 yang berarti sama penting hingga rasio 9 yang berarti sangat penting, serta nilai kebalikannya. Ketiga, menghitung bobot kriteria untuk mewakili kepentingan relatifnya, yang diturunkan dari rasio preferensi pada langkah sebelumnya. Keempat, mengevaluasi alternatif dengan melakukan perbandingan berpasangan serupa untuk setiap pasangan alternatif berdasarkan setiap kriteria. Kelima, menggabungkan bobot kriteria dan skor alternatif melalui perkalian dan penjumlahan untuk menghasilkan skor total bagi setiap alternatif, yang kemudian digunakan untuk memeringkatnya (1000minds 2025).

AHP pada tugas akhir dilakukan berdasarkan literatur yang melakukan evaluasi terhadap model terkait. Terdapat tiga studi literatur yang digunakan untuk menganali-

sis alternatif solusi, yaitu:

1. *Explainable AI and vision transformers for detection and classification of brain tumor: a comprehensive survey* (Hosny dan Mohammed 2025)

Penelitian ini membahas tentang tinjauan teknis dan perbandingan teknik diagnostik *deep learning* (DL) untuk tumor otak, dengan fokus pada penelitian dari tahun 2020 hingga 2024, seperti CNN, *transfer learning*, *vision transformers* (ViT), teknik hibrida, dan *Explainable AI* (XAI). Tugas akhir ini mengeksplorasi kinerja, keunggulan, dan keterbatasan dari pendekatan-pendekatan tersebut pada *dataset* umum seperti Figshare dan BraTS.

2. *Explainable CNN for brain tumor detection and classification through XAI based key features identification* (Iftikhar dkk. 2025a)

Penelitian ini menggunakan metodologi yang menggabungkan *Explainable AI* (XAI) dengan arsitektur CNN untuk mengatasi masalah model yang kompleks dan sulit diinterpretasi. Tugas akhir ini menggunakan teknik XAI berupa *Gradient-weighted Class Activation Mapping* (Grad-CAM) agar memastikan model fokus pada fitur tumor yang relevan.

3. *Optimizing brain tumor classification through feature selection and hyperparameter tuning in machine learning models* (Tahosin dkk. 2023)

Penelitian ini memberikan data perbandingan algoritma *machine learning*. Hasilnya menunjukkan bahwa *Extra Trees* mencapai akurasi tertinggi (98%) dan *Naive Bayes* memiliki akurasi terendah (69%) namun sangat efisien secara komputasi.

Tahapan AHP yang dilakukan adalah sebagai berikut:

1. Struktur Hierarki Keputusan

- (a) Tujuan

Memilih pendekatan *deep learning* atau *machine learning* yang paling efektif dan sesuai untuk tugas klasifikasi atau deteksi penyakit dari data medis.

- (b) Kriteria

- i. C1: Akurasi Deteksi

Kemampuan model untuk secara benar mengidentifikasi atau mengklasifikasikan kondisi medis.

- ii. C2: *Interpretability*

Kemampuan model untuk memberikan penjelasan atas prediksinya, yang krusial dalam konteks medis untuk membangun kepercayaan dan memahami fokus model.

- iii. C3: *Robustness* dan Generalisasi

Kemampuan model untuk berkinerja baik pada data baru (*unseen data*) atau *dataset* yang berbeda, serta ketahanan terhadap variasi data.

iv. C4: Kebutuhan Data dan Teknik *Preprocessing*

Sensitivitas model terhadap jumlah data yang tersedia dan efektivitas teknik seperti augmentasi data, *transfer learning*, atau *preprocessing* spesifik.

v. C5: Kompleksitas Model

Ukuran arsitektur, seperti jumlah *layer*, parameter yang dapat memengaruhi interpretasi, efisiensi, dan risiko *overfitting*.

(c) Alternatif Solusi

i. A1: CNN + Grad-CAM (Mewakili *attribution-based methods*)

ii. A2: *Vision Transformer* (ViT) + *Attention Map* (Mewakili *Transformer-based methods*)

iii. A3: *Naive Bayes* (Representasi *white-box*)

iv. A4: *Extra Trees* (Representasi *black-box*)

2. Perbandingan Berpasangan Antar Kriteria

Perbandingan berpasangan dilakukan berdasarkan kriteria yang ada untuk menentukan prioritas dari setiap kriteria. Perbandingan antarkriteria dilakukan menggunakan matriks perbandingan berpasangan kriteria. Matriks perbandingan berpasangan kriteria adalah tabel yang merekam hasil perbandingan preferensi antara setiap pasang kriteria, menggunakan skala sembilan poin untuk menunjukkan tingkat kepentingan satu kriteria terhadap yang lain. Hasil dari matriks perbandingan kriteria dapat dilihat pada Tabel III.1.

Tabel III.1 Matriks Perbandingan Berpasangan Kriteria

Kriteria	C1	C2	C3	C4	C5
C1 (Akurasi)	1	1	5	3	5
C2 (XAI)	1	1	5	3	5
C3 (Efisiensi)	1/5	1/5	1	1/3	1
C4 (Data)	1/3	1/3	3	1	3
C5 (Kompleksitas)	1/5	1/5	1	1/3	1

Setelah dilakukan perbandingan, dilakukan normalisasi ke vektor prioritas kriteria. Normalisasi dilakukan dengan cara matriks perbandingan dikuadratkan, kemudian setiap baris dijumlahkan, dan hasil penjumlahan setiap baris dibagi dengan total keseluruhan jumlah baris. Langkah-langkah tersebut diulangi pada matriks hasil hingga nilai vektor prioritas yang dihasilkan menjadi kon-

vergen 1000minds (2025). Hasil dari vektor prioritas kriteria dapat dilihat pada Tabel III.2.

Tabel III.2 Vektor Prioritas Kriteria

Kriteria	Bobot	Prioritas (%)
C1: Akurasi	359	35,9%
C2: <i>Interpretability</i>	359	35,9%
C3: <i>Robustness</i> /Generalisasi	64	6,4%
C4: Kebutuhan Data	153	15,3%
C5: Kompleksitas Model	64	6,4%
Total	1.000	100,0%

3. Perbandingan Berpasangan Antar Alternatif

Perbandingan dilakukan dengan cara setiap alternatif dibandingkan dengan alternatif solusi lain berdasarkan masing-masing kriteria menggunakan matriks perbandingan berpasangan kriteria 1000minds (2025). Setelah itu, dilakukan normalisasi yang sama dengan perhitungan prioritas kriteria. Perbandingan antaralternatif berdasarkan kriteria dan prioritas alternatif solusi dapat dilihat pada Tabel III.3 hingga Tabel III.7.

Tabel III.3 Matriks Perbandingan Berpasangan C1 (Akurasi)

C1: Akurasi	A1	A2	A3	A4
A1	1	2	7	4
A2	1/2	1	5	3
A3	1/7	1/5	1	1/3
A4	1/4	1/3	3	1

Berdasarkan Tabel III.3, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 50,5%
- (b) A2: 30,6%
- (c) A3: 5,8%
- (d) A4: 13,1%

Pendekatan CNN dengan Grad-CAM (A1) memperoleh bobot tertinggi karena arsitektur CNN, terutama yang menggunakan *transfer learning*, secara konsisten mendominasi performa akurasi dalam analisis citra medis dan terbukti lebih stabil pada *dataset* standar. *Vision Transformer* (A2) masih menghadapi tantangan generalisasi jika data latih terbatas, sedangkan *Naive Bayes*

(A3) memiliki performa paling rendah dengan akurasi sekitar 69% yang dinilai kurang memadai untuk diagnosis kritis.

Tabel III.4 Matriks Perbandingan Berpasangan C2 (Interpretability)

C2: XAI	A1	A2	A3	A4
A1	1	3	2	7
A2	1/3	1	1/3	3
A3	1/2	3	1	7
A4	1/7	1/3	1/7	1

Berdasarkan Tabel III.4, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 47,4%
- (b) A2: 13,9%
- (c) A3: 33,4%
- (d) A4: 5,3%

Metode CNN yang dilengkapi Grad-CAM (A1) unggul karena mampu menghasilkan visualisasi *heatmap* yang menyoroti area tumor berdasarkan gradien lapisan konvolusi terakhir sehingga memberikan transparansi keputusan yang sangat dibutuhkan. *Naive Bayes* (A3) menempati posisi kedua karena sifatnya sebagai model *white-box* yang mudah dijelaskan secara matematis, berbeda dengan *Extra Trees* (A4) yang merupakan model *ensemble (black-box)* yang sulit dilacak alur keputusannya. Sementara itu, peta atensi pada ViT (A2) sering kali menangkap hubungan global yang lebih abstrak dibandingkan fitur fisik tumor sehingga interpretasi visualnya lebih sulit dipahami dibandingkan *heatmap* CNN.

Tabel III.5 Matriks Perbandingan Berpasangan C3 (Efisiensi Komputasi)

C3: Efisiensi	A1	A2	A3	A4
A1	1	3	1/7	1/3
A2	1/3	1	1/9	1/5
A3	7	9	1	3
A4	3	5	1/3	1

Berdasarkan Tabel III.5, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 10,1%

- (b) A2: 4,9%
- (c) A3: 60,7%
- (d) A4: 24,3%

Naive Bayes (A3) mendominasi kriteria ini karena kesederhanaan algoritmanya yang membutuhkan sumber daya komputasi minimal dan waktu pelatihan yang cepat. *Extra Trees* (A4) juga dinilai efisien karena struktur *tree*-nya yang mengurangi redundansi data. Metode berbasis *deep learning* seperti CNN (A1) dan *Vision Transformer* (A2) memiliki beban komputasi yang jauh lebih berat, seperti ViT yang memproses gambar sebagai urutan *patch* dengan mekanisme atensi yang memakan memori besar dan waktu pelatihan yang jauh lebih lama dibandingkan metode konvensional.

Tabel III.6 Matriks Perbandingan Berpasangan C4 (Kebutuhan Data)

C4: Data	A1	A2	A3	A4
A1	1	3	1/5	1/3
A2	1/3	1	1/7	1/5
A3	5	7	1	2
A4	3	5	1/2	1

Berdasarkan Tabel III.6, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 12,2%
- (b) A2: 5,7%
- (c) A3: 52,3%
- (d) A4: 29,8%

Alternatif *Naive Bayes* (A3) dan *Extra Trees* (A4) lebih unggul karena kemampuan mereka untuk bekerja efektif dan tidak mudah *overfitting* pada *dataset* dengan jumlah sampel yang sedikit. Sebaliknya, CNN (A1) membutuhkan jumlah data yang besar atau strategi augmentasi data untuk mencapai generalisasi yang baik, dan *Vision Transformer* (A2) mendapatkan bobot terendah karena arsitekturnya tidak memiliki bias induktif sehingga memerlukan *dataset* berskala besar agar performanya tidak menurun drastis.

Tabel III.7 Matriks Perbandingan Berpasangan C5 (Kompleksitas)

C5: Kompleksitas	A1	A2	A3	A4
A1	1	2	1/7	1/3
A2	1/2	1	1/8	1/4
A3	1/7	8	1	3
A4	3	4	1/3	1

Berdasarkan Tabel III.7, dihasilkan pembobotan dengan menggunakan normalisasi sebagai berikut:

- (a) A1: 9,4%
- (b) A2: 6,0%
- (c) A3: 60,8%
- (d) A4: 23,8%

Dalam aspek kompleksitas arsitektur, *Naive Bayes* (A3) dinilai paling sederhana karena hanya mengandalkan perhitungan probabilitas statistik dasar, diikuti oleh *Extra Trees* (A4). Sementara itu, CNN (A1) memiliki struktur hierarkis yang dalam dengan jutaan parameter yang harus dilatih, dan *Vision Transformer* (A2) dinilai paling kompleks karena mekanisme *multi-head self-attention* yang memiliki kompleksitas kuadrat terhadap jumlah token (*patch* gambar), menjadikannya model yang paling berat secara struktural dibandingkan alternatif lainnya.

4. Perbandingan Berpasangan Setiap Pasangan Alternatif Berdasarkan Setiap Kriteria

Setelah perbandingan dilakukan pada setiap alternatif berdasarkan kriteria, dilakukan penggabungan perbandingan pada setiap pasangan alternatif berdasarkan setiap kriteria dengan hasil yang dapat dilihat pada Tabel III.8. Perhi-

Tabel III.8 Hasil Perhitungan Perbandingan Berpasangan

Alternatif	C1	C2	C3	C4	C5	Hasil Akhir
Bobot Kriteria	35,9%	35,9%	6,4%	15,3%	6,4%	
A1	505	474	101	122	94	382,607
A2	306	139	49	57	60	175,452
A3	58	334	607	523	608	298,507
A4	131	53	243	298	238	142,434

tungan Rinci Skor Akhir:

- (a) A1 (CNN + Grad-CAM): $(0,359 \times 505) + (0,359 \times 474) + (0,064 \times 101) + (0,153 \times 122) + (0,064 \times 94) = 382,607$

$$(b) \text{ A2 (ViT + Attention Map): } (0,359 \times 306) + (0,359 \times 139) + (0,064 \times 49) + (0,153 \times 57) + (0,064 \times 60) = 175,452$$

$$(c) \text{ A3 (Naive Bayes): } (0,359 \times 58) + (0,359 \times 334) + (0,064 \times 607) + (0,153 \times 523) + (0,064 \times 608) = 298,507$$

$$(d) \text{ A4 (Extra Trees): } (0,359 \times 131) + (0,359 \times 53) + (0,064 \times 243) + (0,153 \times 298) + (0,064 \times 238) = 142,434$$

5. Pemilihan Solusi

Dengan mempertimbangkan bobot prioritas dan skor kinerja keseluruhan, model *deep learning* yang menggunakan Grad-CAM (A1) ditetapkan sebagai solusi pada tugas akhir. Metode ini memberikan keseimbangan terbaik antara akurasi tinggi dan interpretabilitas kuat, sejalan dengan tujuan metodologi yang menekankan pada keandalan model sekaligus transparansi keputusan AI.

BAB IV

PERANCANGAN

IV.1 *Data Understanding*

Selain modifikasi arsitektur, penyesuaian juga dilakukan pada *dataset* yang digunakan. *Dataset* yang digunakan dalam tugas akhir ini merupakan gabungan dari dua sumber data yang berbeda untuk menciptakan kumpulan data yang dapat digunakan untuk klasifikasi tumor otak serta segmentasi tumor otak.

1. *Dataset Otak CT Scan tanpa Mask Tumor*

Untuk melatih dan memvalidasi model, Tugas Akhir ini mengumpulkan datast melalui website Radiopaedia. Radiopaedia merupakan repositori kasus pencitraan medis yang mencakup berbagai modalitas, seperti CT-scan dan MRI. Meskipun terbuka dari komunitas medis, seluruh draf artikel dan kasus klinis yang diunggah dapat dilakukan *peer-review* dan harus melewati proses divalidasi oleh para ahli radiologi profesional yang bekerja sama dengan Radiopaedia. Proses verifikasi ini memastikan bahwa setiap data gambar yang tersedia memiliki diagnosis patologi yang akurat dan anotasi klinis yang dapat dipertanggungjawabkan.

Dalam pengumpulan data, dilakukan pencarian secara manual dengan beberapa kata kunci yang dibagi menjadi dua, yaitu normal dan kelas penyakit (glioma dan meningioma). Pada pencarian tersebut, terdapat *filter* modalitas pencitraan berupa CT *scan*) dan dengan bidang *Axial non-contrast*. Setelah dilakukan pencarian, dilakukan pengunduhan secara manual dengan melihat letak tumor dari gambar lain, seperti MRI atau anotasi pada gambar yang lain. Dalam pengunduhan, dilakukan pemisahan folder untuk tempat setiap kelas yang akan dijadikan bahan untuk pelatihan dan tes model.

2. *Dataset Otak CT Scan dengan Tumor dan Mask Tumor*

Untuk *Dataset* Otak dengan Tumor dan *Mask* Tumor, tugas akhir ini menggunakan *dataset Unpaired MR-CT Brain Dataset for Unsupervised Image Translation* (Al-Kadi dkk. 2022). *Dataset* ini digunakan sebagai *ground truth* untuk kebutuhan validasi XAI. Spesifikasi dari *dataset* yang digunakan adalah:

- (a) Sumber: Jordan University Hospital (via Mendeley Data).
- (b) Kondisi Medis: Patologis (tumor otak).
- (c) Format Data: Citra 2D (DICOM).
- (d) Resolusi Citra: 256×256 piksel.
- (e) Representasi Piksel: 8-bit (0-255) yang telah diterapkan filter *smooth* dan *sharp*.
- (f) Ketebalan *Slice*: 7,0 mm.
- (g) Jumlah Sampel: 89 citra CT bidang aksial.

3. Dataset Otak MRI

IV.2 Data Preparation

Dalam melakukan preparasi pada semua dataset, terdapat *preprocessing* yang dilakukan agar data menjadi seragam dan *preprocessing* tambahan yang dilakukan untuk eksperimen agar model bisa mendeteksi tumor lebih baik.

IV.2.1 Preprocessing Umum

Pada penelitian ini, tahap *preprocessing* umum diterapkan pada seluruh citra masukan untuk memastikan kompatibilitas format dasar dengan arsitektur model yang akan digunakan.

1. Standardisasi Format dan Saluran: Citra masukan yang didapatkan dari berbagai sumber memiliki format yang bervariasi (misalnya *grayscale* atau RGB). Seluruh citra diseragamkan menjadi format *Red-Green-Blue* (RGB) dengan 3 saluran (*channels*). Penyesuaian ini diwajibkan karena sebagian besar arsitektur CNN menerima dimensi masukan awal dengan 3 saluran warna.
2. Penyesuaian Dimensi dan *Padding*: Seluruh citra diubah dimensinya menjadi ukuran yang seragam (sebagai contoh 224×224 atau 256×256 piksel). Untuk mencegah distorsi rasio aspek anatomis jaringan otak akibat pemampatan (*squishing*), teknik *padding* digunakan. Piksel bernilai nol (hitam) ditambahkan pada sisi citra yang lebih pendek sehingga citra menjadi berbentuk persegi secara proporsional sebelum dilakukan penyesuaian ukuran. Hasil akhir disimpan sebagai file PNG dalam format *unsigned integer* 8-bit (uint8) dengan rentang nilai piksel $[0, 255]$.
3. Normalisasi Intensitas: Normalisasi intensitas **tidak** dilakukan pada tahap penyimpanan *file* ini. Citra disimpan dalam format uint8 RGB $[0, 255]$ murni guna menjaga informasi kecerahan absolut antar citra. Sebagai gantinya, statistik normalisasi global berupa nilai *mean* dan *standard deviation* (σ) per kanal dihitung secara *streaming* dari seluruh *train set* dan disimpan ke dalam berkas `norm_stats.json`. Statistik ini dihitung **hanya** dari *train set* untuk

mencegah *data leakage* dari data validasi maupun pengujian. Normalisasi kemudian diterapkan oleh *dataloader* pada *notebook* berikutnya menggunakan metode standarisasi (*Z-score normalization*) dengan persamaan matematis berikut:

$$X_{norm} = \frac{X/255,0 - \mu}{\sigma} \quad (IV.1)$$

di mana μ adalah *mean* dan σ adalah *standard deviation* per kanal dari *train set*. Proses ini memastikan normalisasi yang konsisten antara fase pelatihan (*training*) dan inferensi (*inference*), sekaligus menstabilkan pembaruan bobot (*weight updates*) saat proses pelatihan model CNN.

4. Seleksi *Region of Interest* (ROI): Citra MRI umumnya mengandung latar belakang gelap yang tidak berkontribusi pada proses klasifikasi. Mengacu pada metodologi Islam et al. (**islam2024deepfusion**), seleksi ROI dilakukan melalui dua tahap. Pertama, citra dikonversi ke *grayscale* menggunakan persamaan:

$$I_g = 0,299 \cdot I_R + 0,587 \cdot I_G + 0,114 \cdot I_B \quad (IV.2)$$

Kedua, *thresholding* Otsu diterapkan pada citra *grayscale* untuk memisahkan *foreground* dari *background* secara otomatis dengan meminimalkan varian intra-kelas. *Bounding box* terkecil yang mencakup seluruh kontur *foreground* yang valid kemudian dihitung, dan area tersebut di-*crop* dari citra RGB asli sebagai ROI. Pada kasus di mana tidak ditemukan kontur yang valid (ukuran $\text{crop} < 32 \times 32$ piksel), citra penuh digunakan sebagai *fallback*.

IV.2.2 Preprocessing Eksperimen

Preprocessing tambahan dilakukan sesuai dengan beberapa artikel yang tersedia, yaitu sebagai berikut.

1. clahe + Gaussian *denoise* (Putra dkk. (2025))

Pemfilteran Gaussian (*Gaussian filtering*) diterapkan pada tahap *denoising* dengan tujuan utama untuk menekan derau frekuensi tinggi (*high-frequency noise*) pada citra MRI. Penerapan filter ini secara langsung dapat meningkatkan rasio sinyal terhadap derau (*signal-to-noise ratio*) pada tekstur gambar. Melalui pengurangan derau ini, representasi visual dari margin (tepi) tumor menjadi lebih jelas dan tingkat kecerahan di seluruh irisan gambar menjadi lebih seragam, sehingga model *Convolutional Neural Network* (CNN) mampu mengekstraksi fitur-fitur tekstur dengan jauh lebih efektif.

Contrast Limited Adaptive Histogram Equalization (CLAHE) diterapkan pada tahap prapemrosesan (*preprocessing*) untuk meningkatkan kontras lokal pada citra. Teknik algoritma ini berfungsi untuk menonjolkan batas-batas tu-

mor secara efektif tanpa ikut mengamplifikasi derau (*noise*) di sekitarnya. Dengan mengoptimalkan kontras secara lokal, penggunaan CLAHE yang digabungkan dengan normalisasi dan reduksi derau memungkinkan jaringan model *deep learning* untuk menangkap fitur-fitur tekstur tumor yang sangat halus (*fine-grained*) dengan lebih akurat.

2. *clahe + Wavelet denoise* (Flower dan Leo (2025)) Filter Wavelet merupakan sebuah teknik untuk reduksi derau yang bekerja dengan cara mendekomposisi gambar ke dalam berbagai pita frekuensi menggunakan transformasi wavelet. Mekanisme ini memungkinkan dilakukannya analisis lokal pada komponen waktu maupun frekuensi secara bersamaan, sehingga sangat berguna untuk menangkap fitur transien dan mengurangi derau. Metode ini sangat disukai dalam pemrosesan citra karena kemampuannya yang unggul dalam mempertahankan tepi (*edges*) dan struktur penting pada anatomi sekaligus secara efektif menghilangkan derau yang tidak diinginkan.

CLAHE adalah versi tingkat lanjut dari teknik ekualisasi histogram yang berfungsi untuk meningkatkan kualitas visual dan interpretasi citra. Metode ini beroperasi secara lokal dengan cara membagi citra menjadi wilayah-wilayah yang lebih kecil, yang disebut sebagai *tiles*, lalu menerapkan ekualisasi histogram secara spesifik di dalam setiap *tile* tersebut. Mekanisme pembagian wilayah ini membantu mencegah terjadinya amplifikasi derau yang berlebihan (*over-amplification of noise*) dan mampu meningkatkan detail lokal tanpa memunculkan artefak visual. Teknik ini dinilai sangat bermanfaat ketika memproses pemindaian MRI yang memiliki wilayah heterogen, contohnya pada area yang memiliki struktur gelap dan terang secara bersamaan.

IV.2.3 Augmentasi

Berdasarkan (Goceri 2023), menggabungkan beberapa proses augmentasi secara berurutan terbukti memberikan performa klasifikasi yang lebih tinggi dibandingkan dengan augmentasi tunggal. Pada penelitian ini, diterapkan lima metode augmentasi geometris yang dijalankan hanya pada data *training*, dengan setiap gambar asli menghasilkan 10 salinan (2 salinan per metode), sehingga total dataset *training* menjadi 11 kali lipat data asli. Seluruh piksel yang keluar *frame* akibat transformasi diisi menggunakan refleksi tepi (BORDER_REFLECT_101) agar tidak terdapat artefak hitam yang dapat mengganggu fitur medis.

1. *Shearing Tunggal*

Pada metode ini, citra mengalami distorsi sudut pada sumbu x dan y secara independen dengan sudut yang dipilih secara acak dari rentang -15° hingga 15° . Pusat transformasi ditetapkan di tengah citra agar lesi tidak bergeser jauh dari

posisi aslinya. Metode ini merupakan augmentasi tunggal yang paling tidak efisien apabila diaplikasikan secara tersendiri tanpa dikombinasikan dengan transformasi lain (Goceri 2023).

2. Rotasi Tunggal

Citra dirotasi searah atau berlawanan arah jarum jam dengan sudut acak dari rentang -25° hingga 25° , berpusat di tengah citra. Rotasi umumnya aman diterapkan pada citra medis karena lesi dapat muncul pada berbagai orientasi, sehingga model jaringan dapat belajar mengenali fitur yang tidak bergantung pada orientasi tertentu.

3. Rotasi $\rightarrow$ Translasi

Metode ini menerapkan dua transformasi secara berurutan:

- Rotasi: Citra dirotasi terlebih dahulu dengan sudut acak dari rentang -25° hingga 25° untuk mensimulasikan variasi sudut akuisisi pencitraan.
- Translasi (Pergeseran): Hasil rotasi kemudian digeser pada sumbu x dan y dengan nilai acak dari rentang -15 hingga 15 piksel untuk mensimulasikan variasi posisi pasien saat pencitraan.

4. Translasi $\rightarrow$ *Shearing*

Berdasarkan (Goceri 2023), kombinasi translasi dan *shearing* merupakan pendekatan yang terbukti memberikan performa tertinggi dalam klasifikasi citra *CT scan* paru. Kombinasi ini bekerja dengan menerapkan dua transformasi geometris secara berurutan:

- Translasi (Pergeseran): Citra digeser pada sumbu x dan y menggunakan nilai yang diambil secara acak dari rentang -15 hingga 15 piksel. Langkah ini berguna untuk mencegah *bias* posisional, sehingga model tidak terpaku pada properti di satu lokasi spasial tunggal.
- *Shearing* (Distorsi Sudut): Setelah ditranslasi, citra kemudian diberikan efek distorsi pada sumbu x dan y dengan sudut yang dipilih secara acak antara -15° hingga 15° untuk mensimulasikan variasi proyeksional.

Berdasarkan pengujian kuantitatif dalam artikel tersebut, metode ini berhasil menghasilkan tingkat akurasi sebesar 85.74%, sensitivitas 86.16%, dan spesifitas 97.65% pada klasifikasi citra *CT scan* paru.

5. Translasi $\rightarrow$ *Shearing* $\rightarrow$ Rotasi


Metode ini merupakan kombinasi tiga transformasi geometris yang diterapkan secara berurutan, menjadikannya metode augmentasi paling komprehensif dalam penelitian ini:

- Translasi: Citra digeser secara acak dalam rentang -15 hingga 15 piksel pada kedua sumbu untuk mensimulasikan variasi posisi.

- *Shearing*: Citra yang telah digeser kemudian didistorsi dengan sudut acak antara -15° hingga 15° untuk mensimulasikan variasi proyeksional.
 - Rotasi: Terakhir, citra dirotasi dengan sudut acak dari rentang -25° hingga 25° untuk mensimulasikan variasi orientasi akuisisi pemindaian.
- Kombinasi ketiga transformasi ini terbukti menjadi pendekatan paling tepat untuk augmentasi citra *MR* otak dalam meningkatkan klasifikasi kasus HGG dan LGG, dengan akurasi sebesar 88.24%, sensitivitas 90.48%, dan spesifisitas 97.13% (Goceri 2023).

IV.3 Modelling

Penelitian yang dilakukan oleh Woźniak, Siłka, dan Wieczorek (2021) mengusulkan sebuah *Correlation Learning Mechanism* (CLM) yang menggabungkan *Convolutional Neural Network* (CNN) dengan *Artificial Neural Network* (ANN).



Gambar IV.1 Arsitektur Model CNN + ANN

IV.3.1 Explainable CNN

Pada penelitian ini, arsitektur model dirancang melalui beberapa tahapan utama yang mencakup ekstraksi fitur menggunakan lapisan konvolusi, normalisasi, klasifikasi, hingga tahap optimasi komponen jaringan menggunakan metode pemangkasan berbasis *Explainable AI* (XAI).

1. Lapisan Masukan (*Input Layer*): Model ini menerima masukan berupa citra medis *Magnetic Resonance Imaging* (MRI) otak dalam format warna *Red-Green-Blue* (RGB) yang dimensinya telah diseragamkan terlebih dahulu menjadi ukuran $224 \times 224 \times 3$ piksel. Penyeragaman dimensi ini ditujukan untuk memastikan keselarasan seluruh data masukan sebelum memasuki tahapan ekstraksi fitur.
2. Lapisan Konvolusi dan *Max Pooling*: Tahap ekstraksi fitur menggunakan serangkaian lapisan konvolusi dengan jumlah filter yang meningkat secara bertahap, yaitu 8, 16, 32, 64, 128, dan 256 filter. Seluruh lapisan konvolusi ini menerapkan ukuran kernel 3×3 , *padding* 'same' untuk menjaga dimensi spasial, dan fungsi aktivasi *Rectified Linear Unit* (ReLU) untuk menangkap

pola gambar yang kompleks. Setelah setiap lapisan konvolusi, terdapat lapisan *Max Pooling* yang berfungsi untuk memperkecil ukuran peta fitur (*down-sampling*) sebesar faktor 2 guna mengurangi beban komputasi model.

3. Lapisan Normalisasi dan *Average Pooling*: Setelah melewati keseluruhan rangkaian konvolusi dan *max pooling*, arsitektur menambahkan lapisan *Batch Normalization* yang berfungsi untuk menormalkan hasil aktivasi dari fitur yang diekstrak. Kemudian, peta fitur tersebut diturunkan kembali dimensinya dengan dilewatkan pada lapisan *Average Pooling*.
4. Lapisan *Fully Connected* (Klasifikasi): Peta fitur yang masih berupa multi-dimensi diratakan menjadi vektor satu dimensi (1D) oleh lapisan *Flatten*. Vektor ini kemudian diteruskan ke dalam dua lapisan *Dense* secara berurutan, di mana masing-masing lapisan memiliki 512 neuron dan menggunakan fungsi aktivasi *ReLU*. Pada tahap paling akhir, sebuah lapisan *Dense* dengan fungsi aktivasi *Softmax* digunakan untuk mengeluarkan distribusi probabilitas yang mengklasifikasikan citra ke dalam empat kelas: *Meningioma*, *Glioma*, *Pituitary*, dan *NoTumor*.
5. Pemangkasan Arsitektur Berbasis XAI: Sebagai langkah optimasi utama, model yang telah dilatih kemudian dianalisis menggunakan metode *Explainable AI* (XAI) berbasis *Gradient-weighted Class Activation Mapping* (Grad-CAM) untuk mengevaluasi tingkat kepentingan setiap lapisannya. Lapisan-lapisan yang memiliki nilai rata-rata kepentingan di bawah ambang batas (*threshold*) dan dianggap kurang berkontribusi akan dihapus dari arsitektur secara sistematis. Setelah lapisan yang tidak penting dihilangkan, model dilatih kembali (*retraining*) untuk menghasilkan arsitektur akhir yang tidak terlalu kompleks, lebih efisien, dan sangat terfokus pada fitur tumor yang relevan.

IV.3.2 Hybrid model

Pada bagian ini, diuraikan arsitektur model yang menggabungkan fitur *deep learning* dan fitur buatan tangan (*hand-crafted*) untuk proses klasifikasi citra medis.

1. Lapisan Ekstraksi Fitur *Deep Learning*: Lapisan ekstraksi fitur pertama menggunakan dua arsitektur *Convolutional Neural Network* (CNN) yang sudah dilatih sebelumnya (*pre-trained*), yaitu ResNet50 dan AlexNet. Kedua model ini beroperasi sebagai ekstraktor fitur tetap untuk menangkap pola semantik tingkat tinggi dari gambar CT scan. ResNet50 digunakan untuk mengekstraksi 2.048 dimensi fitur, sedangkan AlexNet mengekstraksi 9.216 dimensi fitur.
2. Lapisan Ekstraksi Fitur Buatan Tangan (*Hand-crafted*): Bersamaan dengan fitur *deep learning*, model ini menggunakan lapisan ekstraksi fitur klasik yang berfokus pada detail tekstur dan bentuk lokal. Teknik *Local Binary Pattern*

(LBP) digunakan untuk menghasilkan 65.536 fitur, sementara *Histogram of Oriented Gradients* (HOG) menghasilkan 72.900 fitur. Kedua teknik ini kemudian dilengkapi dengan fitur intensitas median (*median intensity*) untuk meningkatkan ketahanan model terhadap *noise* atau gangguan visual pada gambar.

3. Lapisan Seleksi dan Fusi Fitur: Karena jumlah fitur awal sangat besar, fitur-fitur LBP dan HOG dilewatkan pada lapisan seleksi menggunakan algoritma *SelectKBest*. Algoritma ini menyeleksi 10.000 fitur klasik terbaik untuk mencegah beban komputasi dan *overfitting*. Ke-10.000 fitur terpilih ini kemudian digabungkan (dikonkatenasi) secara langsung dengan fitur intensitas median serta *output* dari ResNet50 dan AlexNet, menghasilkan satu vektor fitur hibrida komprehensif berdimensi 21.265.
4. Lapisan Tersembunyi (*Hidden Layers*) MLP: Vektor fitur gabungan berdimensi 21.265 tersebut kemudian dimasukkan ke dalam jaringan saraf tiruan *Multilayer Perceptron* (MLP) untuk tahap klasifikasi. MLP ini dirancang dengan lima lapisan *Dense* (lapisan tersembunyi) yang ukurannya semakin mengecil. Secara berurutan, lapisan-lapisan ini terdiri dari 1.024 neuron, 512 neuron, 256 neuron, 64 neuron, dan terakhir 4 neuron.
5. Lapisan Aktivasi dan Regularisasi: Pada setiap lapisan tersembunyi MLP, fungsi aktivasi *Rectified Linear Unit* (ReLU) diterapkan agar model mampu mempelajari pola data *non-linear* yang sangat rumit. Untuk menjaga stabilitas model selama masa pelatihan, disematkan 4 lapisan *Batch Normalization*. Model ini juga menggunakan lapisan *Dropout* dengan rasio 0,3 yang secara acak menonaktifkan sebagian neuron guna memastikan model tidak menghafal data (*overfitting*).
6. Lapisan *Output* (Klasifikasi Akhir): Lapisan paling ujung dari keseluruhan arsitektur ini adalah lapisan *output* yang terdiri dari 4 neuron. Lapisan ini menggunakan fungsi aktivasi *Softmax* untuk mengubah hasil perhitungan matematis menjadi distribusi probabilitas. Berdasarkan probabilitas tertinggi tersebut, model akan mengklasifikasikan gambar CT *scan* ke dalam salah satu dari empat kelas: *Glioma*, *Meningioma*, tumor *Pituitary*, atau jaringan otak *Normal*.

IV.3.3 hyperparameter *tuning*

Pemilihan hyperparameter tidak memiliki standar universal yang menjamin hasil optimal untuk setiap tugas klasifikasi. Berdasarkan penelitian Wojciuk dkk. (2024), meskipun learning rate dan ukuran gambar input secara umum memberikan dampak terbesar pada performa model, tingkat signifikansi dari hyperparameter sangat

bervariasi bergantung pada karakteristik dataset yang digunakan. hyperparameter *tuning* yang dilakukan adalah sebagai berikut.

1. *Learning Rate* (0.0001, 0.001, 0.01): Pada penelitian Wojciuk dkk. (2024), *learning rate* yang diuji memiliki nilai antara 0.0001 hingga 0.03. Artikel tersebut mencatat bahwa *learning rate* dengan nilai yang lebih rendah umumnya berkorelasi dengan performa model yang lebih tinggi.
2. *Batch Size* (16, 32, 64): Berdasarkan penelitian Wojciuk dkk. (2024), *batch size* yang dicoba memiliki nilai 16, 32, dan 64. Walaupun artikel menemukan bahwa *batch size* memiliki dampak yang sangat minim pada akurasi, artikel tersebut juga menjelaskan bahwa signifikansi parameter terhadap model bergantung kepada dataset yang digunakan sehingga dapat dilakukan eksperimen terhadap parameter-parameter lain.
3. *Dropout Rate* (0.1, 0.2, 0.3): Di sinilah terdapat perbedaan yang patut dicatat. Artikel Wojciuk dkk. menguji rentang 0.01 hingga 0.4 dan menemukan bahwa performa terbaik biasanya berada di rentang 0.1 hingga 0.3. Namun, nilai yang Anda pilih (terutama 0.5) sebenarnya merupakan standar yang sangat umum digunakan untuk arsitektur klasifikasi citra medis. Untuk tugas dengan kompleksitas fitur yang tinggi seperti deteksi tumor otak pada CT-Scan, *dropout* yang lebih besar sering kali diperlukan agar model tidak *overfitting* terhadap pola spesifik dari data latih.

IV.3.4 Explainable AI

Pada tugas akhir ini, terdapat modifikasi arsitektur terutama dalam *palettes generator*. *Palettes generator* yang terdapat pada sistem saat ini diganti menggunakan XAI yang akan memberikan penjelasan yang lebih baik. Terdapat penambahan arsitektur yang akan dilakukan, yaitu (Cea dkk. 2017):

1. Pengambilan *feature maps* ($A\hat{k}$) dan *output* skor ($y\hat{c}$).
2. Penghitungan Gradien
Bagian ini menghitung gradien dari *output* skor terhadap *feature maps*. Tujuan dihitungnya gradien adalah untuk menentukan seberapa penting setiap piksel di *feature map* untuk menghasilkan skor kelas tersebut.
3. *Global Average Pool Gradient Maps*
Gradien tersebut kemudian dirata-ratakan secara global untuk membuat bobot kepentingan, yaitu bobot yang menandakan seberapa penting fitur tersebut mengenali kelas yang dipilih.
4. *Weighted Combination*
Bobot kepentingan kemudian dikalikan dengan *feature maps* yang dihasilkan CNN untuk memperkuat atau melemahkan *feature maps* berdasarkan sebera-

pa penting *feature maps* tersebut. Setelah itu, dilakukan penjumlahan semua *feature maps* yang sudah dibobot tersebut agar menjadi satu peta tunggal.

5. ReLU

Setelah memiliki satu peta tunggal, aktivasi ReLU diterapkan untuk mempertahankan bagian-bagian yang berpengaruh positif terhadap kelas target. Ini membuat peta Grad-CAM hanya fokus pada fitur yang mendukung kelas tersebut.

6. Grad-CAM Heatmap

Peta tunggal tersebut akan diubah ukurannya ke ukuran spasial yang sama dengan *input* sehingga dapat dilapisi di atas *input*. Peta Grad-CAM akan melapisi gambar asli menggunakan *heatmap*. Hasil peta Grad-CAM akan menyoroti area di dalam gambar yang signifikan untuk prediksi CNN terhadap kelas yang dipilih dan memberikan wawasan tentang apa yang dilihat oleh jaringan sebagai hal penting untuk pengambilan keputusannya.

IV.4 Rancangan Evaluasi

IV.4.1 Evaluasi Model

Untuk menilai kinerja klasifikasi model, penelitian ini menggunakan evaluasi yang sama dengan evaluasi model yang dilakukan oleh penelitian x dan penelitian y, yaitu:

1. Akurasi (*Accuracy*): Mengukur rasio prediksi benar secara keseluruhan dengan membandingkan prediksi positif dan negatif yang benar (*True Positives* dan *True Negatives*) terhadap total seluruh data.
2. Presisi (*Precision*): Mengukur ketepatan prediksi positif yang dihasilkan oleh model.
3. *Recall*: Mengukur kemampuan model dalam menemukan semua sampel positif yang sebenarnya.
4. Spesifisitas (*Specificity*): Mengukur kemampuan model dalam mengidentifikasi hasil negatif dengan benar (tercantum dalam hasil evaluasi di Tabel 5 dan visualisasi metrik).
5. *F1-Score*: Mengukur keseimbangan model menggunakan rata-rata harmonik dari Presisi dan *Recall*.

IV.4.2 Evaluasi XAI

Evaluasi terhadap *Explainable Artificial Intelligence* (XAI) bertujuan untuk memastikan bahwa model tidak hanya akurat, tetapi juga transparan, dapat diinterpretasikan, dan dapat dipercaya untuk adopsi di dunia nyata.

Dalam proyek ini, metode *saliency* berbasis aktivasi, yaitu Grad-CAM (*Gradient-*

weighted Class Activation Mapping), akan digunakan untuk menghasilkan penjelasan (*local explanation*). Evaluasi kualitas dari penjelasan Grad-CAM ini akan dilakukan dengan mengacu pada taksonomi evaluasi (Kadir, Mosavi, dan Sonntag 2023) sebagai berikut:

1. Konsep yang Diuji (Berdasarkan Aplikasi):

Konsep yang diuji adalah *local explanation* dan turunannya, yaitu *attribution* atau *saliency* untuk mengukur sejauh mana masukan memengaruhi keluaran. Tujuannya adalah memastikan bahwa *heatmap* yang dihasilkan secara valid menunjuk pada area tumor yang sebenarnya di citra.

2. Metodologi Evaluasi (Berdasarkan Teknik):

Untuk menilai kualitas *local explanation* dari Grad-CAM, penelitian ini akan berfokus pada pendekatan *ground truth comparison* yang dilakukan secara kuantitatif menggunakan metrik khusus XAI (Kadir, Mosavi, dan Sonntag 2023).

- (a) *Ground Truth Comparison*

Penelitian ini menerapkan metrik XAlign yang diusulkan oleh Muhammad dan Bendeche (2025) dengan penjelasan yang dapat dilihat pada Bab II. Skor XAlign akan dihitung untuk setiap hasil prediksi Grad-CAM menggunakan persamaan:

$$XAlign = \alpha \cdot WRO + \beta \cdot BAS - \gamma \cdot DP \quad (IV.3)$$

Nilai bobot akan diatur mengikuti konfigurasi standar berdasarkan penelitian tersebut, yaitu $\alpha = 0,5$, $\beta = 0,4$, dan $\gamma = 0,1$. Skor XAlign yang mendekati 1,0 akan mengindikasikan bahwa Grad-CAM berhasil menghasilkan penjelasan yang sangat selaras dengan diagnosis klinis. Sebagai kriteria keberhasilan, penelitian ini mengacu pada performa Grad-CAM yang dilaporkan dalam studi literatur pada *dataset* neuro-onkologi (TCGA-LGG). Metode yang digunakan mencatat skor rata-rata XAlign sebesar 64,1% (Muhammad dan Bendeche 2025). Oleh karena itu, tugas akhir ini menargetkan capaian skor $XAlign \geq 0,641$ sebagai batas minimal validitas penjelasan yang dihasilkan model.

- (b) *Visual Validation* (Evaluasi Kualitatif)

Sebagai pelengkap data kuantitatif XAlign, perbandingan visual *side-by-side* tetap akan dilakukan antara citra asli, *ground truth mask*, dan *heatmap* Grad-CAM untuk analisis kasus per kasus, khususnya pada prediksi *false positive*.

BAB V

IMPLEMENTASI

V.1 Lingkungan Implementasi

Bagian ini menjelaskan spesifikasi perangkat keras dan perangkat lunak yang digunakan dalam tahap implementasi penelitian.

V.1.1 Lingkungan Perangkat Keras

Implementasi sistem ini dilakukan menggunakan perangkat keras dengan spesifikasi sebagai berikut:

1. Prosesor: AMD Ryzen 5 6600H with Radeon Graphics (6 Core, 12 Thread)
2. Memori (RAM): 16 GB
3. Penyimpanan: SSD 1 TB

V.1.2 Lingkungan Perangkat Lunak

Perangkat lunak yang digunakan untuk mendukung proses pengembangan adalah:

1. Sistem Operasi: Windows 11
2. Bahasa Pemrograman: Python 3.10+
3. *Library* Utama:
4. *Driver*:

V.2 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini merupakan dataset citra *CT scan* (*Computed Tomography*) tumor otak yang dikumpulkan dari dua sumber berbeda, menghasilkan total 557 gambar yang terbagi ke dalam tiga kelas, yaitu *no tumor* (otak normal), glioma, dan meningioma. Karakteristik pengumpulan dan pembagian data ini dijabarkan sebagai berikut:

1. Sumber Pertama: Platform Radiopaedia (radiopaedia.org)

Sebuah platform referensi radiologi kolaboratif berbasis komunitas yang memuat ribuan kasus pencitraan medis klinis yang dikontribusikan oleh para radiologis di seluruh dunia. Pengumpulan data dari sumber ini dilakukan melalui teknik *web scraping*, yakni pengambilan gambar secara otomatis dari

halaman-halaman kasus *CT scan* otak yang relevan. Citra yang dikumpulkan mencakup tiga kategori: gambar *CT scan* dengan diagnosis glioma, gambar *CT scan* dengan diagnosis meningioma, dan gambar *CT scan* otak normal (*no tumor*). Gambar-gambar dari Radiopaedia memiliki karakteristik klinis yang bervariasi karena berasal dari berbagai institusi dan perangkat pencitraan yang berbeda-beda, sehingga mencerminkan keragaman kondisi akuisisi citra yang realistis.

2. Sumber Kedua: Dataset Publik Mendeley Data

Sumber kedua berasal dari dataset publik yang tersedia di platform Mendeley Data (**NamaPenulisTahun**). Dataset ini menyediakan 80 gambar citra *CT scan* tumor otak beserta *mask* segmentasi tumornya, yaitu citra biner yang menandai secara piksel wilayah tumor pada setiap gambar. Keberadaan *mask* pada dataset ini memperkaya representasi visual kelas tumor dalam dataset keseluruhan, sekaligus memberikan informasi spasial lokasi tumor yang dapat dimanfaatkan untuk keperluan evaluasi XAI yang digunakan.

Gambar-gambar dari kedua sumber tersimpan dalam tiga format file berbeda, yaitu PNG (239 gambar, 42,9%), JPG (221 gambar, 39,7%), dan JPEG (97 gambar, 17,4%), dengan resolusi yang bervariasi mulai dari 205×255 hingga 1.365×1.365 piksel. Setelah dilakukan penggabungan dari kedua sumber, dataset dibagi ke dalam tiga subset, yaitu data latih (*train*) sebanyak 386 gambar (69,3%), data uji (*test*) sebanyak 99 gambar (17,8%), dan data validasi (*val*) sebanyak 72 gambar (12,9%). Pembagian dataset ke dalam tiga subset tersebut dilakukan secara stratifikasi berdasarkan kelas, sehingga proporsi setiap kelas (*no tumor*, glioma, dan meningioma) terjaga secara merata di seluruh subset *train*, *val*, dan *test*.

Mengingat gambar-gambar dari sumber kedua (Mendeley Data) memiliki karakteristik yang berbeda dibandingkan sumber pertama, penelitian ini merancang tiga skenario eksperimen penempatan data sumber kedua untuk mengevaluasi dampaknya terhadap generalisasi model. Ketiga skenario tersebut adalah sebagai berikut:

1. Skenario 1 Data sumber kedua pada subset *test* saja: Seluruh gambar dari sumber kedua ditempatkan eksklusif pada subset *test*. Skenario ini bertujuan untuk mengukur kemampuan generalisasi model yang dilatih sepenuhnya pada data sumber pertama ketika diuji pada distribusi data yang berbeda.
2. Skenario 2 Data sumber kedua pada subset *val* dan *test*: Gambar dari sumber kedua didistribusikan ke dalam subset *val* dan *test*, sementara subset *train* tetap hanya berisi data dari sumber pertama. Skenario ini memungkinkan proses validasi dan pengujian dilakukan pada distribusi yang lebih beragam, sekaligus menjaga proses pelatihan tetap bersih dari data sumber kedua.

3. Skenario 3 Data sumber kedua pada seluruh subset (*train*, *val*, dan *test*): Gambar dari sumber kedua didistribusikan secara proporsional ke seluruh subset *train*, *val*, dan *test*. Skenario ini mencerminkan kondisi pelatihan yang memanfaatkan keseluruhan data yang tersedia dari kedua sumber secara terpadu.

Ketiga skenario ini dirancang untuk mengkaji sejauh mana asal-usul dan penempatan data sumber kedua memengaruhi kinerja model klasifikasi, khususnya dalam konteks perbedaan distribusi (*domain shift*) antara kedua sumber data.

Kondisi dataset mentah yang heterogen ini menjadi dasar dilakukannya proses *preprocessing*.

V.3 Pemrosesan Data

V.3.1 Pemrosesan Umum

Proses *preprocessing* dilakukan untuk menyeragamkan seluruh gambar agar memenuhi standar *input* model jaringan saraf tiruan yang digunakan. Terdapat tiga tahap *preprocessing* yang diterapkan pada keseluruhan 557 gambar dataset:

1. Konversi Mode Warna ke RGB

Seluruh gambar yang tidak berformat RGB dikonversi menjadi mode warna RGB. Proses ini menyasar 263 gambar yang sebelumnya berformat L (*grayscale*), RGBA, dan P. Setelah *preprocessing*, 100% gambar (557 gambar) telah berformat RGB secara seragam, sehingga kompatibel dengan arsitektur model yang mengharapkan *input* tiga kanal warna.

2. Standardisasi Resolusi ke 224×224 Piksel

Seluruh gambar diubah ukurannya (*resize*) menjadi 224×224 piksel, sesuai dengan ukuran *input* standar pada model berbasis arsitektur seperti VGG, ResNet, dan EfficientNet. Sebelum *preprocessing*, tidak ada satu pun gambar yang memiliki resolusi target tersebut. Setelah *preprocessing*, seluruh 557 gambar telah memiliki resolusi yang seragam 224×224 piksel.

3. Konversi Format ke PNG

Seluruh gambar dikonversi ke format PNG untuk memastikan konsistensi format file. Sebelum *preprocessing*, terdapat 318 gambar (57,1%) yang bukan berekstensi PNG. Setelah *preprocessing*, keseluruhan 557 gambar tersimpan dalam format PNG.

Hasil akhir proses *preprocessing* menunjukkan perbaikan yang menyeluruh pada seluruh aspek yang disasar. Ukuran rata-rata file juga berkurang secara signifikan dari 96,52 KB menjadi 30,86 KB per gambar, dengan total ukuran dataset menyusut dari 52,5 MB menjadi 16,79 MB — penghematan sekitar 68% ruang penyimpanan.

Distribusi rata-rata intensitas piksel antarsplit pun relatif konsisten, dengan nilai *test* sebesar 53,47, *train* sebesar 58,56, dan *val* sebesar 64,16 (skala 0–255), yang mengindikasikan tidak adanya bias kecerahan yang signifikan antar subset data. Ringkasan perbandingan kondisi dataset sebelum dan sesudah *preprocessing* disajikan pada Tabel V.1.

Tabel V.1 Perbandingan Kondisi Dataset Sebelum dan Sesudah *Preprocessing*

Aspek	Sebelum	Setelah
Mode warna	RGB, L, RGBA, P (4 varian)	RGB
Resolusi	15 varian berbeda	224×224
Format file	PNG, JPG, JPEG	PNG
Ukuran file rata-rata	96,52 KB	30,86 KB
Total ukuran dataset	52,5 MB	16,79 MB

V.3.2 Pemrosesan Eksperimen

V.3.2.1 Gaussian Denoise dan CLAHE

Berdasarkan hasil analisis statistik, terdapat perbedaan yang terukur antara dataset sebelum dan sesudah diterapkan *preprocessing* Gaussian dan CLAHE, sebagaimana ditunjukkan pada Tabel V.2.

Tabel V.2 Perbandingan Parameter Dataset Sebelum dan Sesudah *Preprocessing*

Parameter	Sebelum	Sesudah	Perubahan
Intensitas minimum	0,0	3,78–3,93	Noise impulsif tereliminasi
Rata-rata intensitas (<i>train</i>)	58,56	64,41	+5,85
Rata-rata intensitas (<i>val</i>)	64,16	69,79	+5,63
Rata-rata intensitas (<i>test</i>)	53,47	59,68	+6,21
Standar deviasi (<i>train</i>)	78,45	77,81	Sedikit turun
Ukuran file rata-rata	30,86 KB	52,32 KB	+69,6%

Pergeseran nilai intensitas minimum dari 0,0 menjadi 3,78–3,93 menunjukkan bahwa Gaussian berhasil menghilangkan piksel terisolasi bernilai nol yang merepresentasikan *noise* impulsif pada citra *CT scan*. Kenaikan rata-rata intensitas sebesar 5,6–6,2 poin secara konsisten di seluruh subset menunjukkan bahwa CLAHE berhasil meningkatkan kontras lokal citra. Selain itu, standar deviasi yang tidak meningkat melainkan sedikit menurun mengindikasikan bahwa peningkatan kontras berlangsung terkontrol tanpa *over-amplification noise*. Hal ini sejalan dengan pernyataan Irwandi Rizki Putra *et al.* (Putra2025) bahwa *Gaussian filtering* berfungsi untuk meredam *noise* frekuensi tinggi, sedangkan CLAHE bertujuan meningkatkan kontras lokal tanpa memperkuat *noise* pada citra medis.

V.3.2.2 Wavelet Denoise dan Intensity Normalization

V.4 Implementasi Arsitektur Model Utama (CLM)

V.4.1 *Convolutional Neural Network* (CNN)

V.4.2 *Artificial Neural Network* (ANN)

V.4.3 Integrasi Model

V.5 *Explainable AI* (Grad-CAM)

V.5.1 Ekstraksi *Feature Maps* dan Gradien

V.5.2 *Global Average Pooling* dan *Weighted Combination*

V.5.3 Pembangkitan *Heatmap* (Aktivasi ReLU)

BAB VI

EVALUASI

asdfasdf

VI.1 Metode Evaluasi

asdfasdf

VI.2 Hasil Evaluasi

asdfasdf

VI.3 Pembahasan Hasil Evaluasi

VI.4 Evaluasi Kesalahan Penulisan yang Sering Terjadi

VI.4.1 Penggunaan Kata "di mana" atau "dimana"

Banyak yang menuliskan kata "di mana" atau "dimana" sebagai pengganti kata "which" dalam bahasa Inggris. Padahal, penggunaan kata "di mana" atau "dimana" tidak tepat dalam konteks tersebut. Demikian juga untuk kata serupa, misalnya "yang mana". Kata "di mana" atau "dimana" ini harus diganti dengan kata lain, seperti "dengan", "tempat", "yang", dan sebagainya tergantung kalimatnya. Penjelasan lengkap dapat dilihat pada (BPBI).

VI.4.2 Penggunaan Kata "sedangkan" dan "sehingga"

Kata "sedangkan" dan "sehingga" adalah kata hubung atau konjungsi. Konjungsi adalah kata atau ungkapan yang menghubungkan satuan bahasa (kata, frasa, klausa, dan kalimat). Konjungsi dapat dibagi menjadi konjungsi intrakalimat dan antarkalimat. Kata "sedangkan" menghubungkan dua klausa yang bersifat kontrasif, sedangkan "sehingga" menghubungkan dua klausa yang bersifat kausal. Dalam ragam formal, kata hubung "sedangkan" dan "sehingga" hanya dapat digunakan sebagai konjungsi intrakalimat sehingga kedua konjungsi itu **tidak dapat diletakkan pada awal kalimat**. Selain itu, penggunaan kata "sedangkan" harus didahului oleh koma (,), sedangkan kata "sehingga" tidak perlu didahului oleh koma (,). Contoh penggunaan yang benar dan salah dapat dilihat pada Tabel VI.1.

Tabel VI.1 Contoh penggunaan kata "sedangkan" dan "sehingga"

Kata	Salah	Benar
sedangkan	Sedangkan sistem lama masih digunakan oleh banyak pengguna.	Sistem lama masih digunakan oleh banyak pengguna, sedangkan sistem baru belum siap.
sehingga	Sehingga sistem lama masih digunakan oleh banyak pengguna.	Sistem lama masih digunakan oleh banyak pengguna sehingga sistem baru belum siap.

VI.4.3 Penggunaan Istilah yang Tidak Baku

Ada beberapa istilah yang sering digunakan dalam pembicaraan sehari-hari, tetapi tidak baku dalam penulisan ilmiah. Beberapa istilah tersebut antara lain:

1. analisa → analisis
2. eksisting atau existing → yang ada atau saat ini
3. bisnis proses → proses bisnis
4. user → pengguna
5. system → sistem
6. database → basis data
7. aktifitas → aktivitas
8. efektifitas → efektivitas
9. sosial media → media sosial

VI.4.4 Pemisah Desimal dan Ribuan

Tanda pemisah desimal dalam bahasa Indonesia adalah tanda koma, contoh:

1. (Salah) Akurasi naik menjadi 50.6%
2. (Benar) Akurasi naik menjadi 50,6%

VI.4.5 Daftar atau *List*

Ada beberapa aturan penulisan daftar atau *list* yang perlu diperhatikan, antara lain:

- a) Jika memungkinkan, hindari penggunaan "bullet points" atau sejenisnya. Sebaiknya, gunakan angka (1, 2, 3, ...) atau huruf (a, b, c, ...). Dengan demikian, pembaca dapat dengan mudah melihat jumlah *item* atau *list*.
- b) Jika dalam daftar hanya ada satu item, tidak perlu menggunakan nomor urut.
- c) Penjelasan atau deskripsi suatu item sebaiknya menyatu dengan judul item tersebut, tidak berbeda halaman. Contoh yang salah: judul item ada di halaman 10, namun deskripsinya di halaman 11. Sebaiknya pindahkan judul tersebut ke halaman 11.
- d) Jika penjelasan atau deskripsi suatu item cukup panjang, misalnya lebih dari

1 halaman atau terdiri atas beberapa paragraf, sebaiknya setiap item tersebut dijadikan judul subbab, kecuali jika level subbab sudah mencapai level 4.

VI.4.6 Penggunaan Kata "masing-masing" dan "setiap"

Kata "masing-masing" digunakan di belakang kata yang diterangkan, misalnya "Setiap proses menggunakan algoritma masing-masing". Kata "tiap-tiap" atau "setiap" ditempatkan di depan kata yang diterangkan, misalnya "Setiap proses menggunakan algoritma tertentu".

BAB VII

PENUTUP

VII.1 Kesimpulan

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

VII.2 Saran

asdfas

DAFTAR PUSTAKA

- 1000minds. 2025. *What is the Analytic Hierarchy Process (AHP)?* Accessed November 13, 2025. <https://www.1000minds.com/decision-making/analytic-hierarchy-process-ahp>.
- Abu Kamesh, Mohammed. 2024. *Brain Tumour - Glioblastoma versus Metastasis*, July. <https://doi.org/10.53347/rid-191766>. <https://doi.org/10.53347/rid-191766>.
- Ali, Sajid, Tamer Abuhmed, Shaker El-Sappagh, Khan Muhammad, Jose M. Alonso-Moral, Roberto Confalonieri, Riccardo Guidotti, Javier Del Ser, Natalia Díaz-Rodríguez, dan Francisco Herrera. 2023. "Explainable Artificial Intelligence (XAI): What We Know and What Is Left to Attain Trustworthy Artificial Intelligence." *Information Fusion* 99:101805. <https://doi.org/10.1016/j.inffus.2023.101805>.
- Asmita dan Praveen Mittal. 2025. "From black box AI to XAI in neuro-oncology: a survey on MRI-based tumor detection." *Discover Artificial Intelligence* 5 (1). <https://doi.org/10.1007/s44163-025-00247-3>. <https://link.springer.com/article/10.1007/s44163-025-00247-3>.
- Budiman, M. Arif, Yayat Suharyat, Sisi Yulianti, dan Abdul Rahman. 2024. "Effectiveness of Using CT Scan in Early Detection of Brain Tumor." *Indonesia Journal of Engineering and Education Technology (IJEET)* 2 (1): 164–172.
- Cea, Donatella, Lisa Barros Andrade e Sousa, Christina Bukas, Helena Pelin, Elisabeth Georgii, Helene Hoffmann, dan Sebastian Starke. 2017. *Introduction to Grad-CAM — XAI Tutorials*. Accessed November 20, 2025. https://xai-tutorials.readthedocs.io/en/latest/_model_specific_xai/Grad-CAM.html.
- Chapman, Pete, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, dan Rüdiger Wirth. 2000. *CRISP-DM 1.0: Step-by-step data mining guide*. Copyright 1999, 2000. Partners: NCR, DaimlerChrysler, SPSS, OHRA. The CRISP-DM consortium, August.

- Chen, Catherine, dan Zhihan Cui. 2025. "Impact of AI-Assisted Diagnosis on American Patients' Trust in and Intention to Seek Help From Health Care Professionals: Randomized, Web-Based Survey Experiment." *Journal of Medical Internet Research* 27 (June): e66083. <https://doi.org/10.2196/66083>. <https://www.jmir.org/2025/1/e66083>.
- Darmiati. 2023. "The impact of artificial intelligence assistance on the diagnostic performance of radiologists in detecting breast cancer on mammograms." *Indonesian Journal of Cancer*; <https://www.indonesianjournalofcancer.or.id/e-journal/index.php/ijoc/article/view/1100/0>.
- Ennab, Mohammad, dan Hamid Mcheick. 2024. "Enhancing Interpretability and Accuracy of AI Models in Healthcare: A Comprehensive Review on Challenges and Future Directions." *Frontiers in Robotics and AI* 11 (November). <https://doi.org/10.3389/frobt.2024.1444763>.
- Farber, Dana. 2025. *How We Diagnose Brain Tumors* | Dana-Farber Cancer Institute. <https://www.dana-farber.org/cancer-care/types/brain-tumors/diagnosis>.
- Flower, X. Little, dan T. Merlin Leo. 2025. "Performance Evaluation of Preprocessing Techniques for Noise Reduction and Enhancement in MRI-based Brain Tumor Detection." 10 (2): b58–b63. https://www.researchgate.net/publication/389133174_Performance_Evaluation_of_Preprocessing_Techniques_for_Noise_Reduction_and_Enhancement_in_MRI-based_Brain_Tumor_Detection.
- GeeksforGeeks. 2019. *Generative Adversarial Network (GAN)*, January. <https://www.geeksforgeeks.org/deep-learning/generative-adversarial-network-gan/>.
- . 2020. *Convolutional Neural Network (CNN) in Machine Learning*, December. <https://www.geeksforgeeks.org/deep-learning/convolutional-neural-network-cnn-in-machine-learning/>.
- Goceri, E. 2023. "Medical image data augmentation: techniques, comparisons and interpretations." *Artificial Intelligence Review*, <https://doi.org/10.1007/s10462-023-10453-z>.
- Hammad, Mohamed, Mohammed ElAffendi, Ahmed A Abd El-Latif, Abdelhamied A Ateya, Gauhar Ali, dan Pawel Plawiak. 2025. "Explainable AI for lung cancer detection via a custom CNN on CT images." *Scientific Reports* 15 (12707): 1–21.

- Hartung, Michael P., dan Mike Cadogan. 2023. *Abdominal CT: Planes*. Life in the Fast Lane • LITFL. Diakses melalui: <https://litfl.com/abdominal-ct-planes/>, February. <https://litfl.com/abdominal-ct-planes/>.
- Hosny, Ahmed, Chintan Parmar, John Quackenbush, Lawrence H. Schwartz, dan Hugo J. W. L. Aerts. 2018. "Artificial Intelligence in Radiology." *Nature Reviews Cancer* 18 (8): 500–510. <https://doi.org/10.1038/s41568-018-0016-5>.
- Hosny, Khalid M., dan Mahmoud A. Mohammed. 2025. "Explainable AI and vision transformers for detection and classification of brain tumor: a comprehensive survey." *Artificial Intelligence Review* 58 (June): 259. <https://doi.org/10.1007/s10462-025-11221-x>.
- Hospetrack. 2020. *Indonesia Hospital Intelligence*. Accessed October 28, 2025. <https://www.hospetrack.com/product/indonesia/>.
- IBM. 2023. *Explainable AI*, March. <https://www.ibm.com/think/topics/explainable-ai>.
- Iftikhar, Shagufta, Nadeem Anjum, Abdul Basit Siddiqui, Masood Ur Rehman, dan Naeem Ramzan. 2025a. "Explainable CNN for Brain Tumor Detection and Classification through XAI Based Key Features Identification." *Brain Informatics* 12 (1). <https://doi.org/10.1186/s40708-025-00257-y>.
- . 2025b. "Explainable CNN for brain tumor detection and classification through XAI based key features identification." *Brain Informatics* 12 (10): 1–19.
- Insights10. 2023. *Indonesia Radiology Service Market Analysis*. Insights10. Diakses melalui: <https://www.insights10.com/report/indonesia-radiology-service-market-analysis/>. <https://www.insights10.com/report/indonesia-radiology-service-market-analysis/>.
- International Agency for Research on Cancer. 2024a. *Brain, Central Nervous System. Fact Sheet*. Technical report. Accessed October 28, 2025. World Health Organization, Global Cancer Observatory (GCO). <https://gco.iarc.who.int/media/globocan/factsheets/cancers/31-brain-central-nervous-system-fact-sheet.pdf>.
- . 2024b. *Indonesia. Fact Sheet*. Technical report. Accessed October 28, 2025. World Health Organization, Global Cancer Observatory (GCO). <https://gco.iarc.who.int/media/globocan/factsheets/populations/360-indonesia-fact-sheet.pdf>.

- Jaffar, Ali, Muhammad Yousaf, Muhammad Hassan, Tayyab Rahim, Sheeza Hus-sain, Adeela Nawaz, dan Kunjshik Jaffar. 2025. "Comparative Analysis of MRI and CT Scan for the Diagnosis of Brain Tumor, Considering MRI as Gold Stan-dard." *Journal of Health, Workforce and Clinical Research*, <https://jhwcr.com/index.php/jhwcr/article/view/106>.
- Al-Kadi, Omar, Israa Almallahi, Alaa Abu-Srhan, Mohammad Abushariah, dan Waleed Mahafza. 2022. *Unpaired MR-CT Brain Dataset for Unsupervised Image Trans-lation*. V. V1. Dataset. <https://doi.org/10.17632/z4wc364g79.1>. <https://doi.org/10.17632/z4wc364g79.1>.
- Kadir, Abdul, Amir Mosavi, dan Daniel Sonntag. 2023. *Evaluation Metrics for XAI: A Review, Taxonomy, and Practical Applications*. Accessed July 1, 2025. https://www.dfki.de/fileadmin/user_upload/import/14708_XAI_Evaluation_Metrics__Taxonomies__Concepts_and_Applications__INES_2023_-7.pdf.
- Li, Mengfang, Yuanyuan Jiang, Yanzhou Zhang, dan Hongtu Zhu. 2023. "Medical Image Analysis Using Deep Learning Algorithms." *Frontiers in Public Health* 11:1273253. <https://doi.org/10.3389/fpubh.2023.1273253>.
- Mamourian, Alexander. 2020. *Recognizing Intra-Axial Tumors on Brain Computed Tomography (CT)*. Medmastery. Diakses melalui: <https://www.medmastery.com/guides/brain-ct-clinical-guide/recognizing-intra-axial-tumors-brain-computed-tomography-ct-and>. <https://www.medmastery.com/guides/brain-ct-clinical-guide/recognizing-intra-axial-tumors-brain-computed-tomography-ct-and>.
- Mayo Clinic. 2019. *Brain Tumor - Diagnosis and Treatment - Mayo Clinic*. May-oclinic.org. Accessed October 28, 2025. <https://www.mayoclinic.org/diseases-conditions/brain-tumor/diagnosis-treatment/drc-20350088>.
- . 2023. *Brain Tumor - Symptoms and Causes*, April. <https://www.mayoclinic.org/diseases-conditions/brain-tumor/symptoms-causes/syc-20350084>.
- Mohale, Vincent Zibi, dan Ibidun Christiana Obagbuwa. 2025. "Evaluating Machine Learning-Based Intrusion Detection Systems with Explainable AI: Enhancing Transparency and Interpretability." *Frontiers in Computer Science* 7 (May). <https://doi.org/10.3389/fcomp.2025.1520741>. <https://doi.org/10.3389/fcomp.2025.1520741>.

- Moreira, Catarina, Yu-Liang Chou, Chihcheng Hsieh, Chun Ouyang, João Madeiras Pereira, dan Joaquim Jorge. 2024. "Benchmarking Instance-Centric Counterfactual Algorithms for XAI: From White Box to Black Box." Diakses melalui: <https://arxiv.org/abs/2203.02399>, *arXiv preprint arXiv:2203.02399* (November): 1–37. <https://arxiv.org/abs/2203.02399>.
- Muhammad, Dost, dan Malika Bendeache. 2025. "More than Just a Heatmap: Elevating XAI with Rigorous Evaluation Metrics." *Frontiers in Medical Technology* 7 (October). <https://doi.org/10.3389/fmedt.2025.1674343>.
- National Institute of Biomedical Imaging and Bioengineering. 2022. *Computed Tomography (CT)*. <https://www.nibib.nih.gov/science-education/science-topics/computed-tomography-ct>.
- National Institute of Biomedical imaging and Bioengineering. 2025. *Magnetic Resonance Imaging (MRI)*. <https://www.nibib.nih.gov/science-education/science-topics/magnetic-resonance-imaging-mri>.
- Nuraini, Ayu. 2024. *Kesulitan Akses Tenaga Radiologi Di Indonesia: Tantangan Untuk Pelayanan Kesehatan Yang Berkualitas*. KOMPASIANA. Kompasiana.com, December. <https://www.kompasiana.com/ayunuraini8527/675999b034777c753314b122/kesulitan-akses-tenaga-radiologi-di-indonesia-tantangan-untuk-pelayanan-kesehatan-yang-berkualitas>.
- Our World in Data. 2025. *Annual Number of Deaths by Cause*. Data source: Institute for Health Metrics and Evaluation (IHME), Global Burden of Disease. Accessed February 26, 2026. <https://ourworldindata.org/grapher/annual-number-of-deaths-by-cause>.
- Permana, Bayu Indra. 2025. *Kelangkaan Helium Global Bisa Ancam Layanan MRI Di Indonesia*. Tribunnews.com. Tribunnews, July. <https://www.tribunnews.com/kesehatan/2025/08/23/kelangkaan-helium-global-bisa-ancam-layanan-mri-di-indonesia>.
- Purnama, Basuki Eka. 2025. *Masih Ada Disparitas MRI Di Berbagai Provinsi Di Indonesia*. Mediaindonesia.com, July. <https://mediaindonesia.com/humaniora/804918/masih-ada-disparitas-mri-di-berbagai-provinsi-di-indonesia>.

- Putra, Irwandi Rizki, Zulrahmadi, Andri Swandi, Yulia, dan Tasya Destria Putri. 2025. "Enhanced Classification of Brain MRI Images for Tumor Detection Using Transfer Learning and Grad-CAM-Based Explainable Convolutional Neural Network (CNN)." *Journal of ICT Application and System (JICTAS)* 4 (2): 76–88. <https://doi.org/10.56313/jictas.v4i2.454>. <https://doi.org/10.56313/jictas.v4i2.454>.
- Radiology Key. 2015. *Brain*. Radiology Key. Diakses melalui: <https://radiologykey.com/brain/>, December. <https://radiologykey.com/brain/>.
- Republik Indonesia, Kementerian Kesehatan. 2025. *Update Tatalaksana Tumor Otak Dan Perawatan Luka Kraniotomi Angkatan 1*. LMS Kemkes. Accessed October 28, 2025. <https://lms.kemkes.go.id/courses/96f54d44-2103-4de0-8728-1fdae57accd4>.
- Stryker, Cole. 2021. *Recurrent Neural Network (RNN)*, October. <https://www.ibm.com/think/topics/recurrent-neural-networks>.
- Syaftahan, Pabila. 2025. *Transformasi Radiologi Dengan Kecerdasan Buatan*. Indonesia Artificial Intelligence Hub. <https://aihub.id/berita/transformasi-radiologi-ai>.
- Tahosin, Mst Sazia, Md Alif Sheakh, Taminul Islam, Rishalatun Jannat Lima, dan Mahbuba Begum. 2023. "Optimizing Brain Tumor Classification through Feature Selection and Hyperparameter Tuning in Machine Learning Models." Accessed via: <https://doi.org/10.1016/j.imu.2023.101414>, *Informatics in Medicine Unlocked* 43 (January): 101414. <https://doi.org/10.1016/j.imu.2023.101414>. <https://doi.org/10.1016/j.imu.2023.101414>.
- Terven, Juan, Diana-Margarita Cordova-Esparza, Julio-Alejandro Romero-González, Alfonso Ramírez-Pedraza, dan E A Chávez-Urbiola. 2025. "A Comprehensive Survey of Loss Functions and Metrics in Deep Learning." *Artificial Intelligence Review* 58 (7). <https://doi.org/10.1007/s10462-025-11198-7>. <https://doi.org/10.1007/s10462-025-11198-7>.
- Varughese, Jobit. 2025. *Generative Adversarial Networks*, May. <https://www.ibm.com/think/topics/generative-adversarial-networks>.

- Vimalasvaran, Kavitha, D. Robert, S. Kumar, A. Kumar, Mariapola Narbone, Rahul Dharmadhikari, M. Harrison, dkk. 2024. "Assessing the effectiveness of artificial intelligence (AI) in prioritising CT head interpretation: study protocol for a stepped-wedge cluster randomised trial (ACCEPT-AI)." *BMJ Open* 14 (6): e078227. <https://doi.org/10.1136/bmjopen-2023-078227>. <https://doi.org/10.1136/bmjopen-2023-078227>.
- Woźniak, Marcin, Jakub Siłka, dan Michał Wieczorek. 2021. "Deep Neural Network Correlation Learning Mechanism for CT Brain Tumor Detection." *Neural Computing and Applications* (March). <https://doi.org/10.1007/s00521-021-05841-x>.
- Xu, Hanhui, dan Kyle Michael James Shuttleworth. 2023. "Medical artificial intelligence and the black box problem – a view based on the ethical principle of 'Do No Harm'." *Intelligent Medicine* 4 (1). <https://doi.org/10.1016/j.imed.2023.08.001>. <https://www.sciencedirect.com/science/article/pii/S2667102623000578>.
- Zhang, Li, Xin Wen, Jianwei Li, Jingyi Xu, Xin Yang, dan Meng Li. 2023. "Diagnostic Error and Bias in the Department of Radiology: A Pictorial Essay." *Insights into Imaging* 14 (1). <https://doi.org/10.1186/s13244-023-01521-7>.

LAMPIRAN A

KODE PROGRAM

Pada umumnya, kode program tidak perlu disertakan di dalam laporan tugas akhir karena kode program biasanya sangat panjang dan sudah disimpan dalam bentuk berkas-berkas elektronik terpisah di repositori daring. Namun, jika ada bagian kode program singkat yang penting untuk ditulis dalam laporan tugas akhir, bagian tersebut dapat disertakan di dalam laporan.

LAMPIRAN B

HASIL SURVEI LAPANGAN

B.1 Foto Survei Lokasi 1

Teks survei lokasi 1.

B.2 Foto Survei Lokasi 2

Teks survei lokasi 2.

B.3 Transkrip Wawancara dengan Narasumber

Teks transkrip wawancara.

